1 · PORTADA

Revisión de Modelos Informados por Física (PIML) para Series de Tiempo y Sistemas Energéticos

Versión matemática — esquema general, diagramas de decisión y modelos matemáticos por familia, previos a la formulación del modelo

Maestría en Ingeniería · Universidad Nacional de Colombia

Basado en: revision_piml_series_tiempo_energia_matematica.md

2026

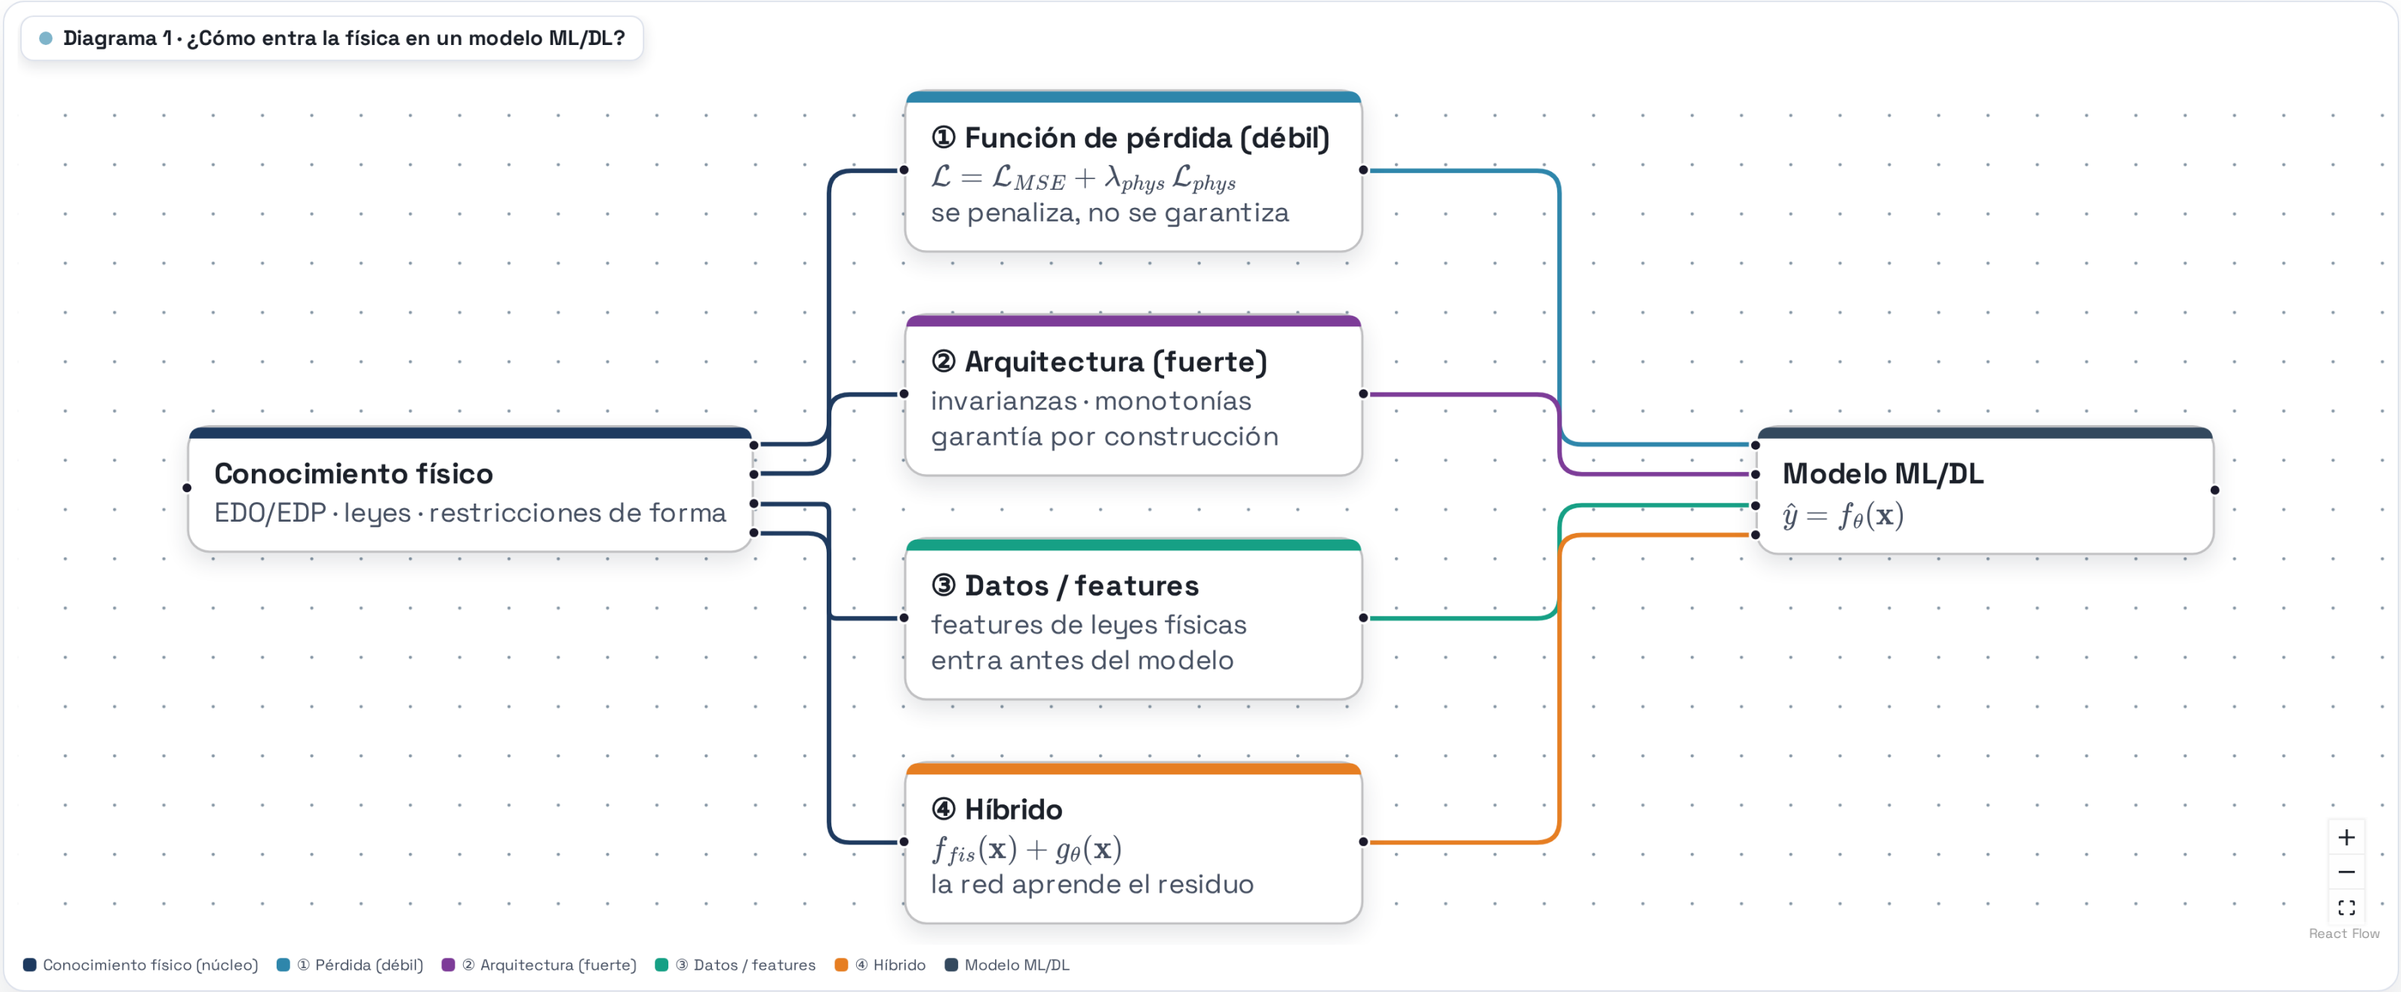
Tabla de notación: grupos, símbolos y su uso

Grupo	Símbolos	Uso
Convención temporal (continuo y discreto)	continuo, paréntesis ( ): $x(t), \dot{x}(t), u(t, \mathbf{x})$; discreto, corchetes [ ] con índice entero: $y[t], \mathbf{z}[t], \mathbf{h}[t-1], \hat{y}[j]$.	Regla transversal: toda magnitud dependiente del tiempo lleva argumento explícito —paréntesis en continuo, corchetes con índice entero en discreto—; los paréntesis con argumento no temporal conservan su sentido.
Series y marco general	$y[t]$ observada, $\hat{\mathbf{y}} \in \mathbb{R}^h$ multi-paso directa, ventana $\mathbf{X} \in \mathbb{R}^{\tau \times d}$, pérdidas $\mathcal{L}_{MSE}, \mathcal{L}_{phys}, \mathcal{L}_{total}$, peso λ_{phys}, residuo $\mathcal{R}_{phys}$, ley $\mathcal{F}[u] = 0$ en dominio Ω_T.	Marco común: series, pérdidas y ley física. Toda penalización es $\lambda_\cdot$ y la rama física se escribe f_{fis}.
Codificador RFF multibanda (artículo guía)	kernel κ, bandas K con ancho $\mathrm{softplus}(\rho_k)$, N_f features por banda, mapeo $\boldsymbol{\phi}_k$ (Ecuación 24), embedding $\mathbf{z}[t] \in \mathbb{R}^F$ con $F = KN_f$, secuencia $\mathbf{Z} = \Phi_{MB}(\mathbf{X})$; pre-set $B = (6, 24, 72)$ h.	Codificador espectral del artículo guía (familia F6): el mapeo RFF canónico es la Ecuación (24) y la densidad espectral, $p(\mathbf{w}) = \mathcal{N}(\mathbf{0}, \rho^{-2}\mathbf{I})$.
TSB y recurrencia	convolución con dilatación $\breve{d}$ y kernel $\breve{k}$, GELU $\breve{\sigma}$, LayerNorm LN, estado $\breve{\mathbf{h}}[t]$, módulo f_{RNN}.	Backbone secuencial del artículo guía (bloque TCN: residual + GELU + LN); en GRU la compuerta de actualización es $\mathbf{u}[t]$ (**no** $\mathbf{z}[t]$, para no colisionar con el embedding espectral).
Física térmica RC (PINN-RC)	temperaturas T_{in}, T_{out}, T_m; capacidades C_{in}, C_m; resistencias R_{ea}, R_{in}, R_{out}.	Variables de estado y parámetros del circuito térmico 2R2C (patrón D, §5b) cuyo residuo penaliza la PINN-RC.
Exógenas y drivers	$I_{sol}, A_w, \dot{Q}_{int}, P_{HVAC}$; drivers de calendario y ocupación.	Forzamientos (entradas exógenas) del modelo RC y covariables de calendario/ocupación del forecasting.
Símbolos locales	$\mathcal{B}$ (E1), $\mathbf{A}, \mathbf{B}, \mathbf{C}$ (E6), instantes t_i, t_j y muestras i, convolución E4 $f[i]$, $s[t]$; E2: $\theta \in \mathbb{R}^d$, $\mathbf{X}$ (matriz de diseño $N \times d$), $\varepsilon_i, \lambda_{reg}, c, (\cdot)_+, \varepsilon_{svr}, \lambda_{svr}$; SVD: $\mathbf{U}, \mathbf{S}, \mathbf{V}$.	Existen solo dentro de su ecuación. t_i son valores de t continuo: paréntesis, $x(t_i)$; i numera muestras, no tiempo: subíndice, nunca corchete. Colisiones: ε_i (ruido), $\varepsilon[t]$ (innovación) y ε_{svr} (tolerancia del tubo) son conceptos distintos; $\mathbf{U}$ es factor del SVD y $\mathbf{U}_i$ compuerta; $\mathcal{N}$ es sólo la normal —la ley física es $\mathcal{F}[u] = 0$—; $\mathbf{X}$ cambia de sentido: diseño en E2, ventana fuera.
Decisiones de unificación	θ parámetros del modelo (único); Θ conjunto de parámetros; $\lambda_{phys}, \lambda_{reg}, \lambda_{svr}, \lambda_{rk}$ penalizaciones; $\mathcal{L}$ pérdida; $\mathbf{u}[t]$ compuerta GRU; f_{fis} rama física.	θ es el **único** símbolo de los parámetros: los coeficientes de una regresión, los pesos de una red y las matrices de compuerta son θ o bloques con nombre de θ; Θ es el conjunto donde vive.

Las cuatro puertas por las que entra la física

- Un solo punto de partida: el modelo ML $\hat{y} = f_\theta(\mathbf{x})$ y el conocimiento físico $\mathcal{F}[u] = 0$.
- De ese binomio **modelo + ley física** salen cuatro canales de entrada, ordenados por fuerza de garantía: **① penalización débil → ② arquitectura → ③ datos/features → ④ híbrido**.

Karniadakis et al., Nature Reviews Physics 3(6), 2021 (DOI: 10.1038/s42254-021-00314-5) · Hao et al., arXiv:2211.08064 · Willard et al., ACM Computing Surveys 2022 · Doumèche, tesis doctoral Sorbonne 2025.



El sistema ejemplar: masa-resorte-amortiguador (MR)

- Un solo sistema físico para comparar las tres puertas: la ley $\mathcal{F}[u] = 0$ instanciada en el MR.

Ecuación de movimiento (residuo físico)

$$\mathcal{F}[x] \;\equiv\; m\,\ddot{x}(t) + c\,\dot{x}(t) + k\,x(t) = 0$$

MR: masa m, rigidez k, amortiguamiento c; la trayectoria $x(t)$ es lo que cada puerta predice.

Estado canónico y energía (Hamiltoniano)

$$q(t) = x(t), \quad p(t) = m\,\dot{x}(t), \quad H(q(t), p(t)) = \frac{p(t)^2}{2m} + \frac{k\,q(t)^2}{2} \quad (c = 0)$$

Conexión: el caso conservativo ($c = 0$) es hamiltoniano puro; es la forma que exige la puerta ② en su variante HNN. $q(t)$ y $p(t)$ son los estados (posición y momento) en cada instante; H se evalúa sobre esa trayectoria. La variante lagrangiana ($L = T - V$) se define en la diapositiva propia de la puerta ② (Lagrangian NN).

Datos disponibles

$$\mathbf{x}_i = (t_i, x(t_i), \dot{x}(t_i)), \qquad i = 1, \ldots, N_d$$

Conexión: las tres puertas consumen el mismo dato básico: trayectoria medida del MR.

Las tres páginas siguientes instancian $\mathcal{F}[u] = 0$ sobre este sistema: misma física, distinto punto de entrada.

Puerta ① — Función de pérdida (PINN)

La física entra en la **función de pérdida (costo)**: se penaliza, no se garantiza.

Modelo

$$\hat{x}(t) = f_\theta(t), \qquad \theta \in \Theta$$

Conexión: la red aproxima la solución del sistema masa-resorte; es el bloque "Modelo ML f_θ" del diagrama.

Residuo físico (diferenciación automática)

$$r_\theta(t_j) = m\,\ddot{\hat{x}}_\theta(t_j) + c\,\dot{\hat{x}}_\theta(t_j) + k\,\hat{x}_\theta(t_j)$$

Conexión: la caja punteada "Diff. automática" produce r_θ en los puntos de colocación t_j; es $\mathcal{F}[\hat{x}_\theta]$ de la ley $\mathcal{F}[u] = 0$.

Función de pérdida

$$\mathcal{L}_{total}(\theta) = \underbrace{\frac{1}{N_d}\sum_{i=1}^{N_d} \left|f_\theta(t_i) - x(t_i)\right|^2}_{\mathcal{L}_{MSE}} + \lambda_{phys} \underbrace{\frac{1}{N_c}\sum_{j=1}^{N_c} \left\|r_\theta(t_j)\right\|^2}_{\mathcal{L}_{phys}}$$

Conexión: la línea inferior del diagrama es exactamente esta suma: la física entra en el segundo término, no en la estructura.

Problema de optimización

$$\theta^* = \arg\min_{\theta \in \Theta} \; \mathcal{L}_{total}(\theta)$$

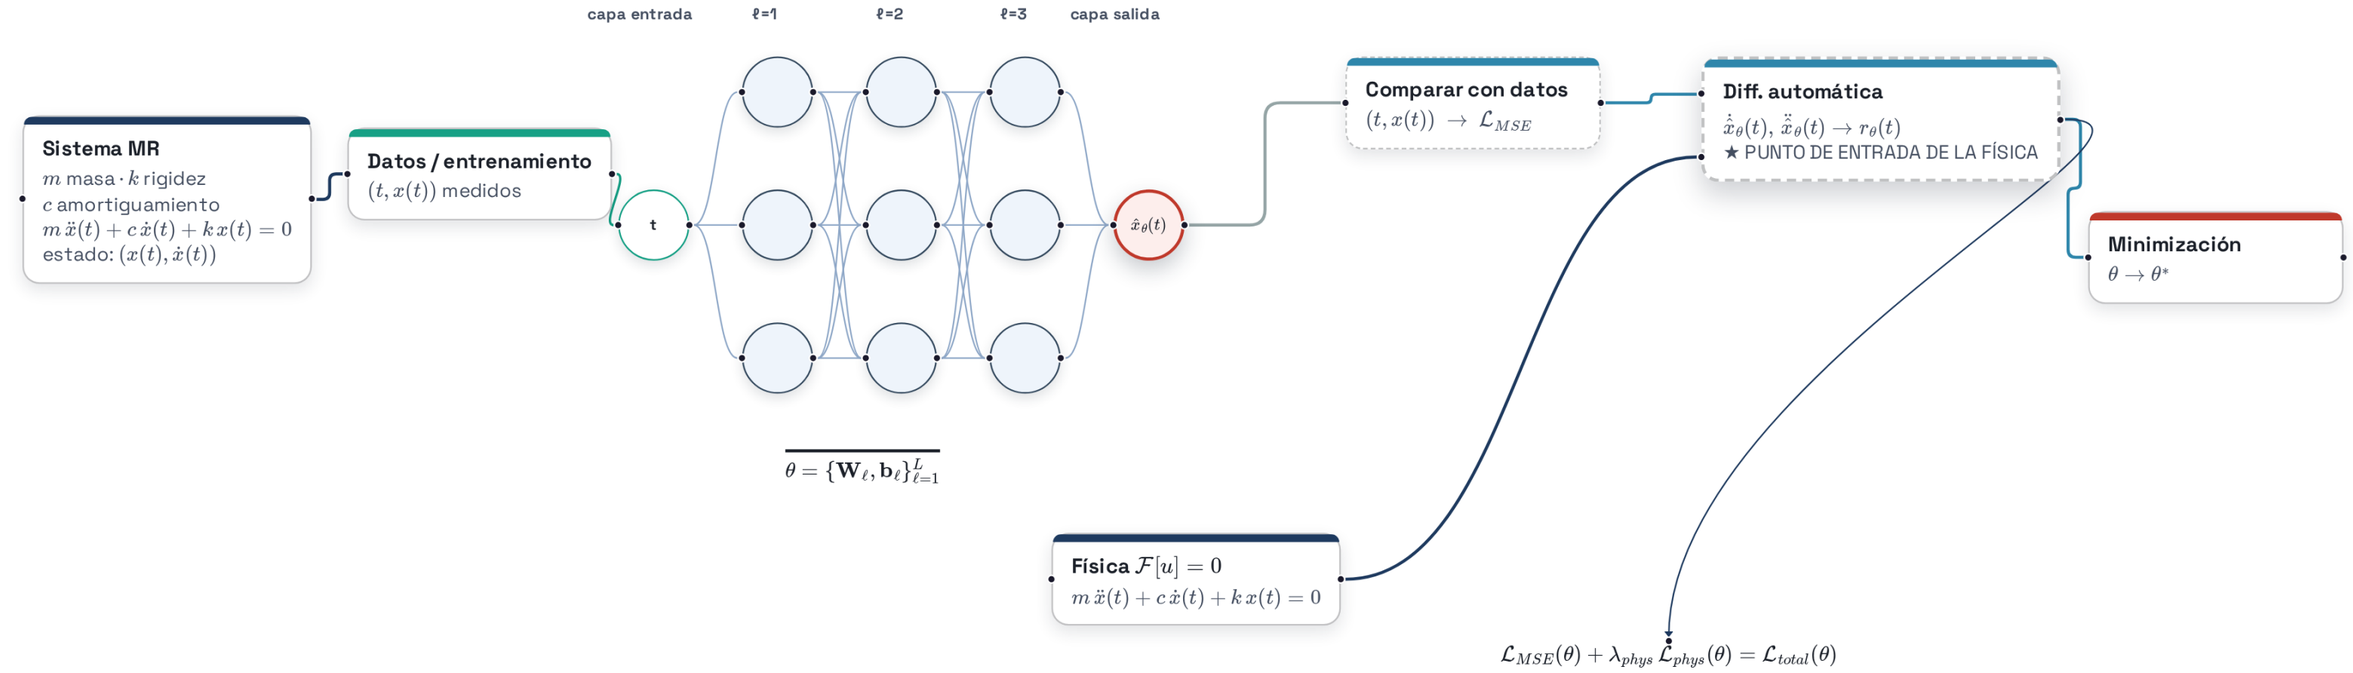
El residuo entra en la pérdida, no en la estructura: el cumplimiento depende de λ_{phys} y del entrenamiento.

Raissi, Perdikaris, Karniadakis. Physics-informed neural networks. J. Comput. Phys. 378, 686–707, 2019.

Karniadakis et al. Physics-informed machine learning. Nat. Rev. Phys. 3(6), 422–440, 2021. DOI: 10.1038/s42254-021-00314-5.

Doumèche. Physics-informed ML: time series forecasting. Tesis Sorbonne, arXiv:2507.08906, 2025.

MR · Puerta ① — la física entra en la función de pérdida



Sistema MR / física · ① Pérdida (débil) · Modelo ML f_θ · Minimización → θ^*

Puerta ② — Arquitectura (Hamiltonian NN)

La física entra en la **estructura del modelo**: se cumple **por construcción** para todo θ.

$(q(t), p(t))$ → f_θ — red neuronal → $H_\theta(q(t), p(t))$ → ∇H_θ (autodiff) → $\mathbb{J}\nabla H_\theta$ → dinámica

Estado canónico y Hamiltoniano físico

$$q(t) = x(t), \qquad p(t) = m\,\dot{x}(t), \qquad H(q(t), p(t)) = \frac{p(t)^2}{2m} + \frac{k\,q(t)^2}{2} \quad (c = 0)$$

Conexión: para el sistema masa-resorte conservativo, el Hamiltoniano representa la energía mecánica total. $q(t)$: posición generalizada · $p(t)$: momento — estados en cada instante t · H: energía total instantánea.

La red aprende el Hamiltoniano (función escalar)

$$f_\theta : \ (q(t), p(t)) \ \longmapsto \ H_\theta(q(t), p(t)) \approx H(q(t), p(t))$$

Conexión: la red **no predice directamente** $q(t)$ ni $p(t)$: aprende una función escalar. H_θ **no se compara necesariamente con etiquetas de energía**: se aprende porque su gradiente debe reproducir la dinámica observada. Entrada de la red $= (q(t), p(t))$ · salida $= H_\theta(q(t), p(t))$.

Autodiff y ecuaciones de Hamilton — ★ PUNTO DONDE ENTRA LA FÍSICA

$$\dot{q}_\theta(t) = \frac{\partial H_\theta}{\partial p}, \qquad \dot{p}_\theta(t) = -\frac{\partial H_\theta}{\partial q}, \qquad \frac{d}{dt}\begin{bmatrix} q(t) \\ p(t) \end{bmatrix} = \mathbb{J}\,\nabla H_\theta$$

$$H_\theta(q(t),\, p(t)) \xrightarrow{\text{Autodiff}} (\partial H_\theta/\partial q,\ \partial H_\theta/\partial p) \xrightarrow{\text{Ecs. de Hamilton}} (\dot{q}_\theta(t),\ \dot{p}_\theta(t))$$

La física NO entra como penalización: entra en la estructura. Las ecs. de Hamilton (con $\mathbb{J} = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}$) no «transforman» mágicamente una derivada en otra: son la regla física que convierte las pendientes de H_θ respecto al estado $(q(t), p(t))$ en las tasas de cambio temporal $(\dot{q}_\theta(t), \dot{p}_\theta(t))$.

Función de pérdida (dinámica) y optimización

$$\mathcal{L}_{HNN}(\theta) = \frac{1}{N}\sum_{n=1}^{N}\Big[\,|\dot{q}_\theta(t_n) - \dot{q}(t_n)|^2 + |\dot{p}_\theta(t_n) - \dot{p}(t_n)|^2\Big], \qquad \theta^* = \arg\min_\theta \mathcal{L}_{HNN}(\theta)$$

Conexión: los objetivos salen de los datos: $\dot{q}(t_n) = \dot{x}(t_n)$ y $\dot{p}(t_n) = m\,\ddot{x}(t_n)$; si no hay aceleración medida, $\dot{p}(t_n)$ se estima por diferencias finitas. Con $\dot{q}_\theta(t) = \partial H_\theta/\partial p$ y $\dot{p}_\theta(t) = -\partial H_\theta/\partial q$, no existe $\mathcal{L}_{phys}$ separado: la física ya está incorporada en la arquitectura.

Mensaje clave: la HNN no aprende directamente la trayectoria — aprende $H_\theta(q(t), p(t))$; las ecuaciones de Hamilton convierten su gradiente en la dinámica y un integrador recupera $(q(t), p(t))$.

Greydanus, Dzamba, Yosinski. Hamiltonian Neural Networks. NeurIPS 2019.
Cranmer et al. Lagrangian Neural Networks. arXiv:2003.04630, 2020.
Chen et al. Neural Ordinary Differential Equations. NeurIPS 2018.

Puerta ② — Del Hamiltoniano a la dinámica del masa-resorte

De dónde salen las ecuaciones que la puerta ② impone como estructura: tres pasos desde la energía hasta la EDO del MR ($c = 0$).

Paso 1 · Construcción del Hamiltoniano

$$q(t) = x(t), \quad p(t) = m\,\dot{x}(t), \quad T = \frac{p(t)^2}{2m}, \quad V = \frac{k\,q(t)^2}{2} \;\Rightarrow\; H = T + V = \frac{p(t)^2}{2m} + \frac{k\,q(t)^2}{2}$$

Conexión: el Hamiltoniano representa la energía total del sistema conservativo: energía cinética más energía potencial del resorte.

Paso 2 · Ecuaciones de Hamilton

$$\dot{q}(t) = \frac{\partial H}{\partial p} = \frac{p(t)}{m}, \qquad \dot{p}(t) = -\frac{\partial H}{\partial q} = -k\,q(t)$$

Conexión: las derivadas del Hamiltoniano determinan cómo cambia el estado del sistema. H no entrega directamente la trayectoria: entrega la regla de evolución del sistema.

Paso 3 · Recuperación de la ecuación física

$$p(t) = m\,\dot{q}(t) \;\Rightarrow\; \dot{p}(t) = m\,\ddot{q}(t) \;\Rightarrow\; m\,\ddot{q}(t) + k\,q(t) = 0 \;\Rightarrow\; m\,\ddot{x}(t) + k\,x(t) = 0$$

Conexión: las ecuaciones de Hamilton recuperan exactamente la ecuación original del masa-resorte (identificación $q(t) \equiv x(t)$ del Paso 1): la dinámica sale de H por derivación, no se aprende.

Conservación de energía (por construcción)

$$\frac{dH}{dt} = \nabla H^{\top}\,\mathbb{J}\,\nabla H = 0 \quad \Rightarrow \quad H(t) = \text{constante a lo largo de la trayectoria}$$

Destacado: la conservación de energía aparece por construcción debido a la estructura Hamiltoniana — aplica al caso conservativo $c = 0$ y sin fuerza externa; en la HNN, vale para todo θ.

Nota: la formulación alternativa basada en Euler–Lagrange, la Lagrangian Neural Network (§F3 del documento), se desarrolla en las dos diapositivas siguientes.

Greydanus, Dzamba, Yosinski. Hamiltonian Neural Networks. NeurIPS 2019.
Cranmer et al. Lagrangian Neural Networks. arXiv:2003.04630, 2020.
Chen et al. Neural Ordinary Differential Equations. NeurIPS 2018.

Puerta ② — Arquitectura (Lagrangian NN)

La física entra en la **estructura del modelo**: se cumple **por construcción** para todo θ, ahora a través del principio de acción.

$(q(t), \dot{q}(t))$ → f_θ — red neuronal → $L_\theta(q(t), \dot{q}(t))$ → ∂L_θ (autodiff) → Euler–Lagrange → dinámica

Estado generalizado y Lagrangiano físico

$$q(t) = x(t), \qquad \dot{q}(t) = \dot{x}(t), \qquad L(q(t), \dot{q}(t)) = T - V = \frac{m\dot{q}(t)^2}{2} - \frac{k\,q(t)^2}{2} \quad (c = 0)$$

Conexión: para el sistema masa-resorte conservativo, el Lagrangiano es energía cinética menos energía potencial — misma notación $q(t)$, $\dot{q}(t)$ y los mismos m, k del bloque hamiltoniano ($H = T + V$, $L = T - V$). L: función escalar.

La red aprende el Lagrangiano (función escalar)

$$f_\theta : \ (q(t), \dot{q}(t)) \ \longmapsto \ L_\theta(q(t), \dot{q}(t)) \approx L(q(t), \dot{q}(t))$$

Conexión: igual que la HNN, la LNN **no predice directamente** $q(t)$: aprende una función escalar. L_θ **no se compara con etiquetas de energía:** se aprende porque sus derivadas deben reproducir la dinámica observada. Entrada de la red $= (q(t), \dot{q}(t))$ · salida $= L_\theta(q(t), \dot{q}(t))$.

Autodiff y ecuación de Euler–Lagrange — ★ PUNTO DONDE ENTRA LA FÍSICA

$$\frac{d}{dt}\frac{\partial L_\theta}{\partial \dot{q}} - \frac{\partial L_\theta}{\partial q} = 0$$

$$L_\theta(q(t),\, \dot{q}(t)) \xrightarrow{\text{Autodiff}} (\partial L_\theta/\partial q,\ \partial L_\theta/\partial \dot{q}) \xrightarrow{\text{Ecs. de Euler-Lagrange}} \ddot{q}_\theta(t) \Rightarrow \text{dinámica}$$

La física NO entra como penalización: entra en la estructura. La ec. de Euler–Lagrange (principio de acción) es la regla física que convierte las derivadas parciales de L_θ respecto al estado $(q(t), \dot{q}(t))$ en la aceleración $\ddot{q}_\theta(t)$: el análogo lagrangiano de $\mathbb{J}\nabla H_\theta$, con ∂L_θ en lugar de ∇H_θ.

Función de pérdida (dinámica) y optimización

$$\mathcal{L}_{LNN}(\theta) = \frac{1}{N}\sum_{n=1}^{N} \left|\ddot{q}_\theta(t_n) - \ddot{q}(t_n)\right|^2, \qquad \theta^* = \arg\min_\theta \ \mathcal{L}_{LNN}(\theta)$$

Conexión: los objetivos salen de los datos: $\ddot{q}(t_n) = \ddot{x}(t_n)$ (diferencias finitas si solo hay posición medida); $\ddot{q}_\theta(t_n)$ se obtiene resolviendo la ec. de Euler–Lagrange para L_θ. No existe $\mathcal{L}_{phys}$ separado: la física ya está incorporada en la arquitectura, igual que en la HNN.

Mensaje clave: la LNN tampoco aprende directamente la trayectoria — aprende $L_\theta(q(t), \dot{q}(t))$; la ecuación de Euler–Lagrange convierte sus derivadas en la aceleración y un integrador recupera $(q(t), \dot{q}(t))$.

Cranmer et al. Lagrangian Neural Networks. arXiv:2003.04630, 2020.
Greydanus, Dzamba, Yosinski. Hamiltonian Neural Networks. NeurIPS 2019.
Chen et al. Neural Ordinary Differential Equations. NeurIPS 2018.

Puerta ② — Del Lagrangiano a la dinámica del masa-resorte

De dónde sale la regla de evolución que la LNN impone como estructura: tres pasos desde $L = T - V$ hasta la EDO del MR ($c = 0$), y su equivalencia con la formulación hamiltoniana.

Paso 1 · Construcción del Lagrangiano

$$q(t) = x(t), \quad \dot{q}(t) = \dot{x}(t), \quad T = \frac{m\dot{q}(t)^2}{2}, \quad V = \frac{k\,q(t)^2}{2} \;\Rightarrow\; L = T - V = \frac{m\dot{q}(t)^2}{2} - \frac{k\,q(t)^2}{2}$$

Conexión: el Lagrangiano usa las mismas m, k y la misma trayectoria $x(t)$ que el Hamiltoniano: energía cinética menos potencial en lugar de más.

Paso 2 · Ecuación de Euler–Lagrange

$$\frac{\partial L}{\partial \dot{q}} = m\,\dot{q}(t), \qquad \frac{\partial L}{\partial q} = -k\,q(t) \;\Rightarrow\; \frac{d}{dt}\frac{\partial L}{\partial \dot{q}} - \frac{\partial L}{\partial q} = m\,\ddot{q}(t) + k\,q(t) = 0$$

Conexión: las derivadas del Lagrangiano determinan cómo cambia el estado del sistema. L no entrega directamente la trayectoria: entrega la regla de evolución (principio de acción), igual que H en la formulación anterior.

Paso 3 · Recuperación de la ecuación física

$$m\,\ddot{q}(t) + k\,q(t) = 0 \;\Rightarrow\; m\,\ddot{x}(t) + k\,x(t) = 0$$

Conexión: la ecuación de Euler–Lagrange recupera exactamente la ecuación original del masa-resorte (identificación $q(t) \equiv x(t)$ del Paso 1): la dinámica sale de L por derivación, no se aprende.

Equivalencia con la formulación hamiltoniana (transformada de Legendre)

$$p(t) = \frac{\partial L}{\partial \dot{q}} = m\,\dot{q}(t) \;\Rightarrow\; H = p(t)\,\dot{q}(t) - L = \frac{p(t)^2}{2m} + \frac{k\,q(t)^2}{2} = T + V$$

Destacado: para el MR conservativo ($c = 0$) las dos puertas ② son equivalentes: la transformada de Legendre lleva de L a H y recupera exactamente el Hamiltoniano del bloque anterior, con su conservación de energía incluida.

Nota: misma estructura de tres pasos que el desglose hamiltoniano — cambia la variable de partida ($L = T - V$ en lugar de $H = T + V$) y la regla de evolución (Euler–Lagrange en lugar de las ecs. de Hamilton).

Cranmer et al. Lagrangian Neural Networks. arXiv:2003.04630, 2020.
Greydanus, Dzamba, Yosinski. Hamiltonian Neural Networks. NeurIPS 2019.
Chen et al. Neural Ordinary Differential Equations. NeurIPS 2018.

Hamiltoniano vs Lagrangiano: cuándo usar una u otra

Criterio	Hamiltoniano $H(q,p)$	Lagrangiano $L(q,\dot{q})$
Variables de estado	Coordenadas canónicas $(q(t), p(t))$: el momento $p = m\,\dot{q}(t)$ hay que construirlo.	Coordenadas generalizadas $(q(t), \dot{q}(t))$ directas de los datos; el momento se deriva después: $p = \partial L / \partial \dot{q}$.
Función escalar	$H = T + V$ — energía total (cinética + potencial).	$L = T - V$ — densidad de acción (cinética - potencial).
Regla de evolución	Dos ecuaciones de primer orden: $\dot{q}(t) = \partial H/\partial p$, $\dot{p}(t) = -\partial H/\partial q$ (forma matricial $\mathbb{J}\,\nabla H$).	Una ecuación de Euler-Lagrange de segundo orden: $\frac{d}{dt}\frac{\partial L}{\partial \dot{q}} - \frac{\partial L}{\partial q} = 0$.
Marco y conservación	Espacio de fases simpléctico; $H(t) =$ constante por construcción (integradores simplécticos).	Principio de acción (extremizar la acción); la conservación se hereda de la simetría temporal.
Red equivalente (puerta ②)	HNN: $f_\theta(q(t), p(t)) \mapsto H_\theta$; pérdida sobre $(\dot{q}, \dot{p})$ en t_n.	LNN: $f_\theta(q(t), \dot{q}(t)) \mapsto L_\theta$; pérdida sobre las aceleraciones $\ddot{q}(t_n)$.
Paso de una a otra (Legendre)	$H(q,p) = p\,\dot{q} - L(q,\dot{q})$ con $p = \partial L/\partial \dot{q}$ (inversa: $\dot{q} = \partial H/\partial p$).	Para el MR ($c = 0$): $p = m\,\dot{q}(t) \Rightarrow L = T - V \Leftrightarrow H = T + V$ — misma trayectoria.
Cuándo recomendarla	Sistema conservativo con (q,p) a mano o construibles; predicción a largo plazo donde importa la energía exacta (órbitas, osciladores, estructura simpléctica).	Datos en $(q,\dot{q})$ o coordenadas generalizadas con restricciones/vínculos; cuando los momentos deben derivarse y no se miden.

- **Regla práctica:** si necesitas momento y espacio de fases explícitos → **hamiltoniano**; si trabajas con posiciones y velocidades (o coordenadas con vínculos) → **lagrangiano**.
- **Advertencia:** las dos formas estándar asumen $c = 0$ (sin disipación); con amortiguamiento hay que añadir fuerzas generalizadas o disipación de Rayleigh — fuera del alcance de la puerta ② en este deck.

Paso de una a otra: transformada de Legendre

$$p = \frac{\partial L}{\partial \dot{q}} \iff \dot{q} = \frac{\partial H}{\partial p}, \qquad H(q,p) = p\,\dot{q} - L(q,\dot{q})$$

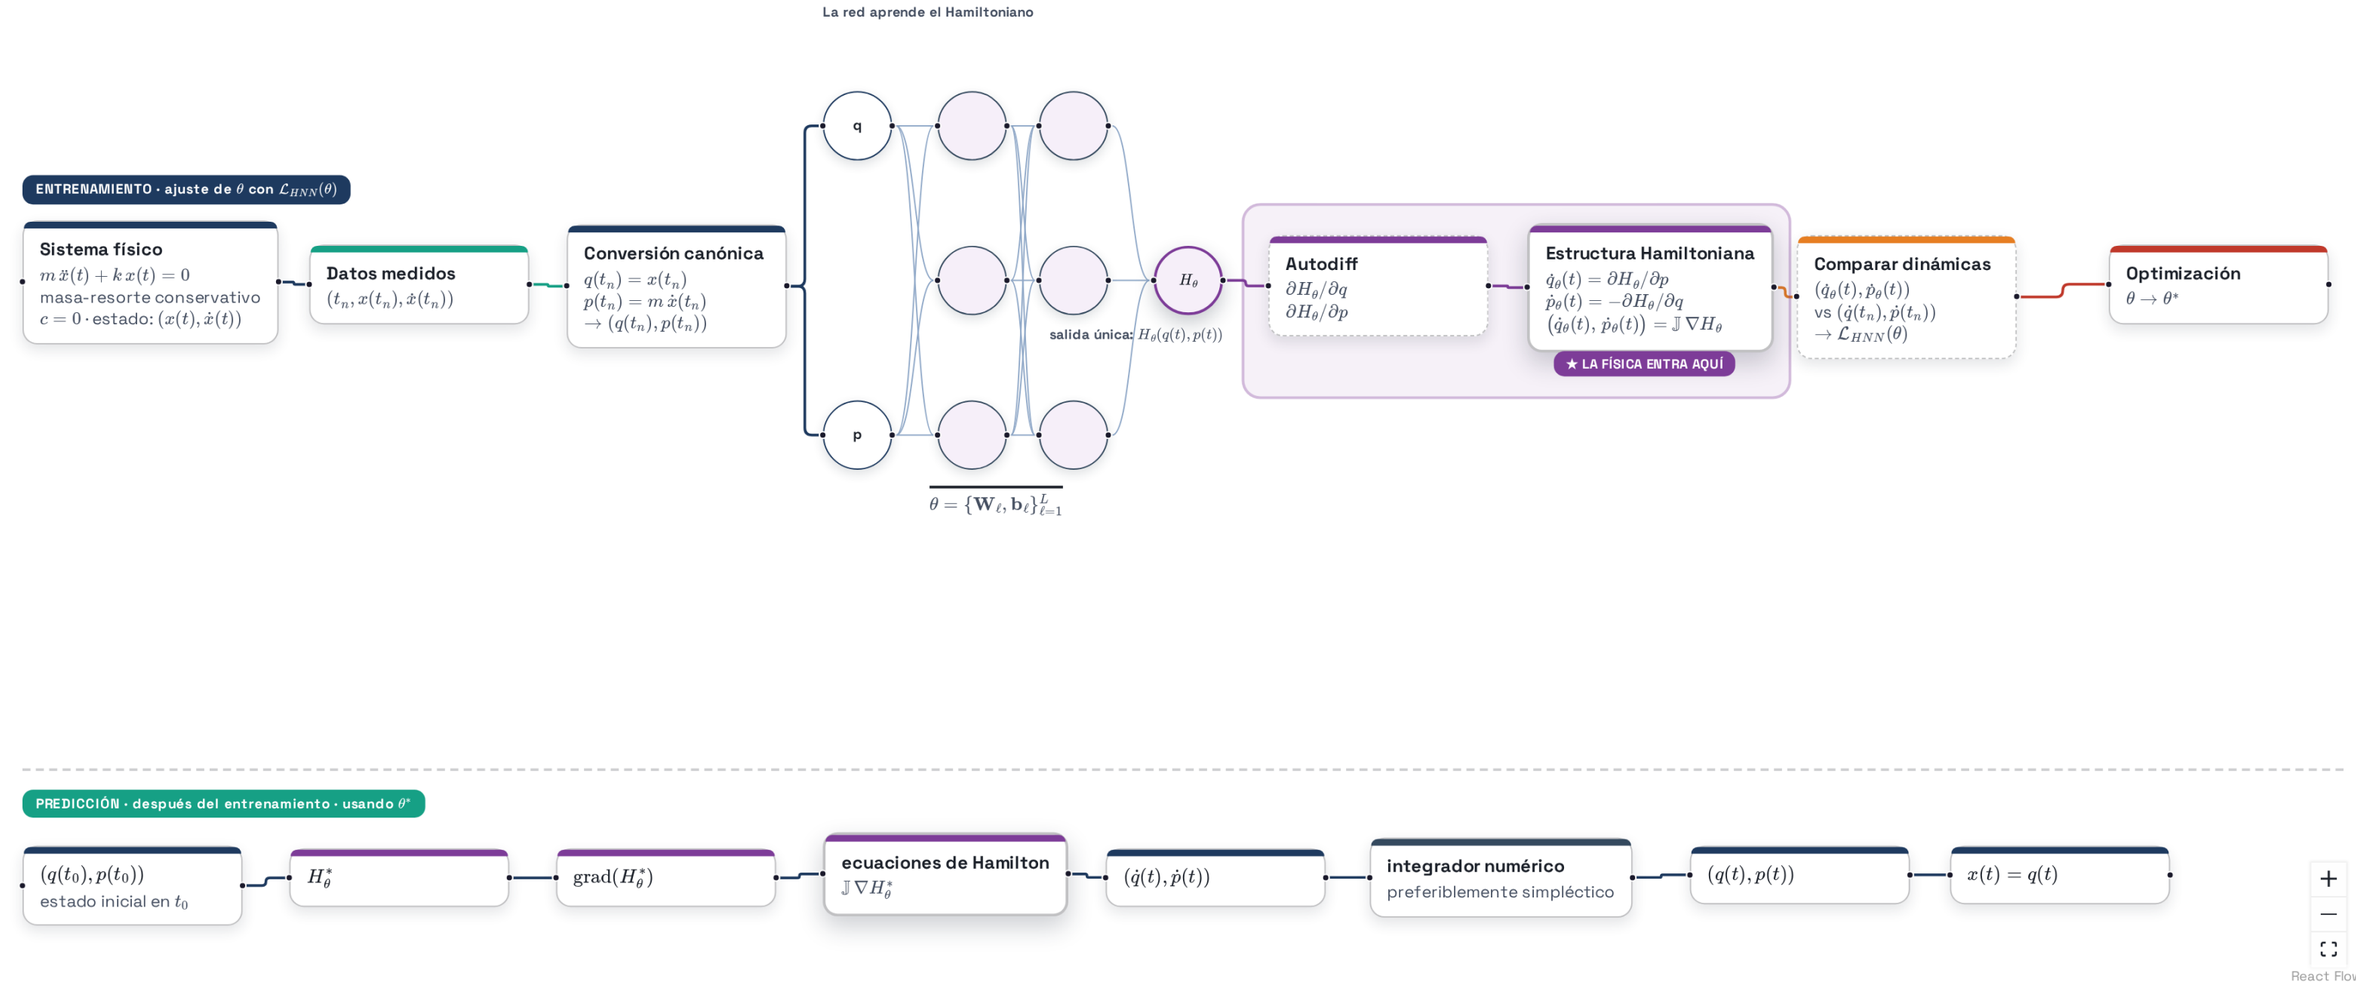
Conexión: puente exacto entre las dos columnas — para el MR ($c = 0$), $p = m\,\dot{q}(t)$ lleva de $L = T - V$ a $H = T + V$ y ambas producen la misma trayectoria $x(t)$.

Greydanus, Dzamba, Yosinski. Hamiltonian Neural Networks. NeurIPS 2019.

Cranmer et al. Lagrangian Neural Networks. arXiv:2003.04630, 2020.

Goldstein, Poole, Safko. Classical Mechanics — coordenadas canónicas y transformada de Legendre.

MR · Puerta ② — flujo de una HNN · la física entra en la estructura



Puerta ③ — Física en los datos / features

La física entra **en los datos/features**: indirectamente, antes del modelo.

Modelo (entrada aumentada)

$$\tilde{\mathbf{x}} = [\mathbf{x},\ \psi_{fis}(\mathbf{x})], \qquad \psi_{fis} = [\,x(t),\ \dot{x}(t),\ E(t)\,], \qquad E(t) = \tfrac{1}{2} m \dot{x}(t)^2 + \tfrac{1}{2} k\, x(t)^2$$

Conexión: para el MR las features son el espacio de fases y la energía; el bloque "Features ψ_fis" transforma la entrada antes de f_θ.

Función de pérdida (sobre datos aumentados)

$$\mathcal{L}_{MSE}(\theta) = \frac{1}{N_d} \sum_{i=1}^{N_d} |f_\theta(\tilde{\mathbf{x}}_i) - y(t_i)|^2$$

Conexión: la física no aparece como término de penalización: vive en la entrada aumentada $\tilde{\mathbf{x}}$ y en las features ψ_{fis}.

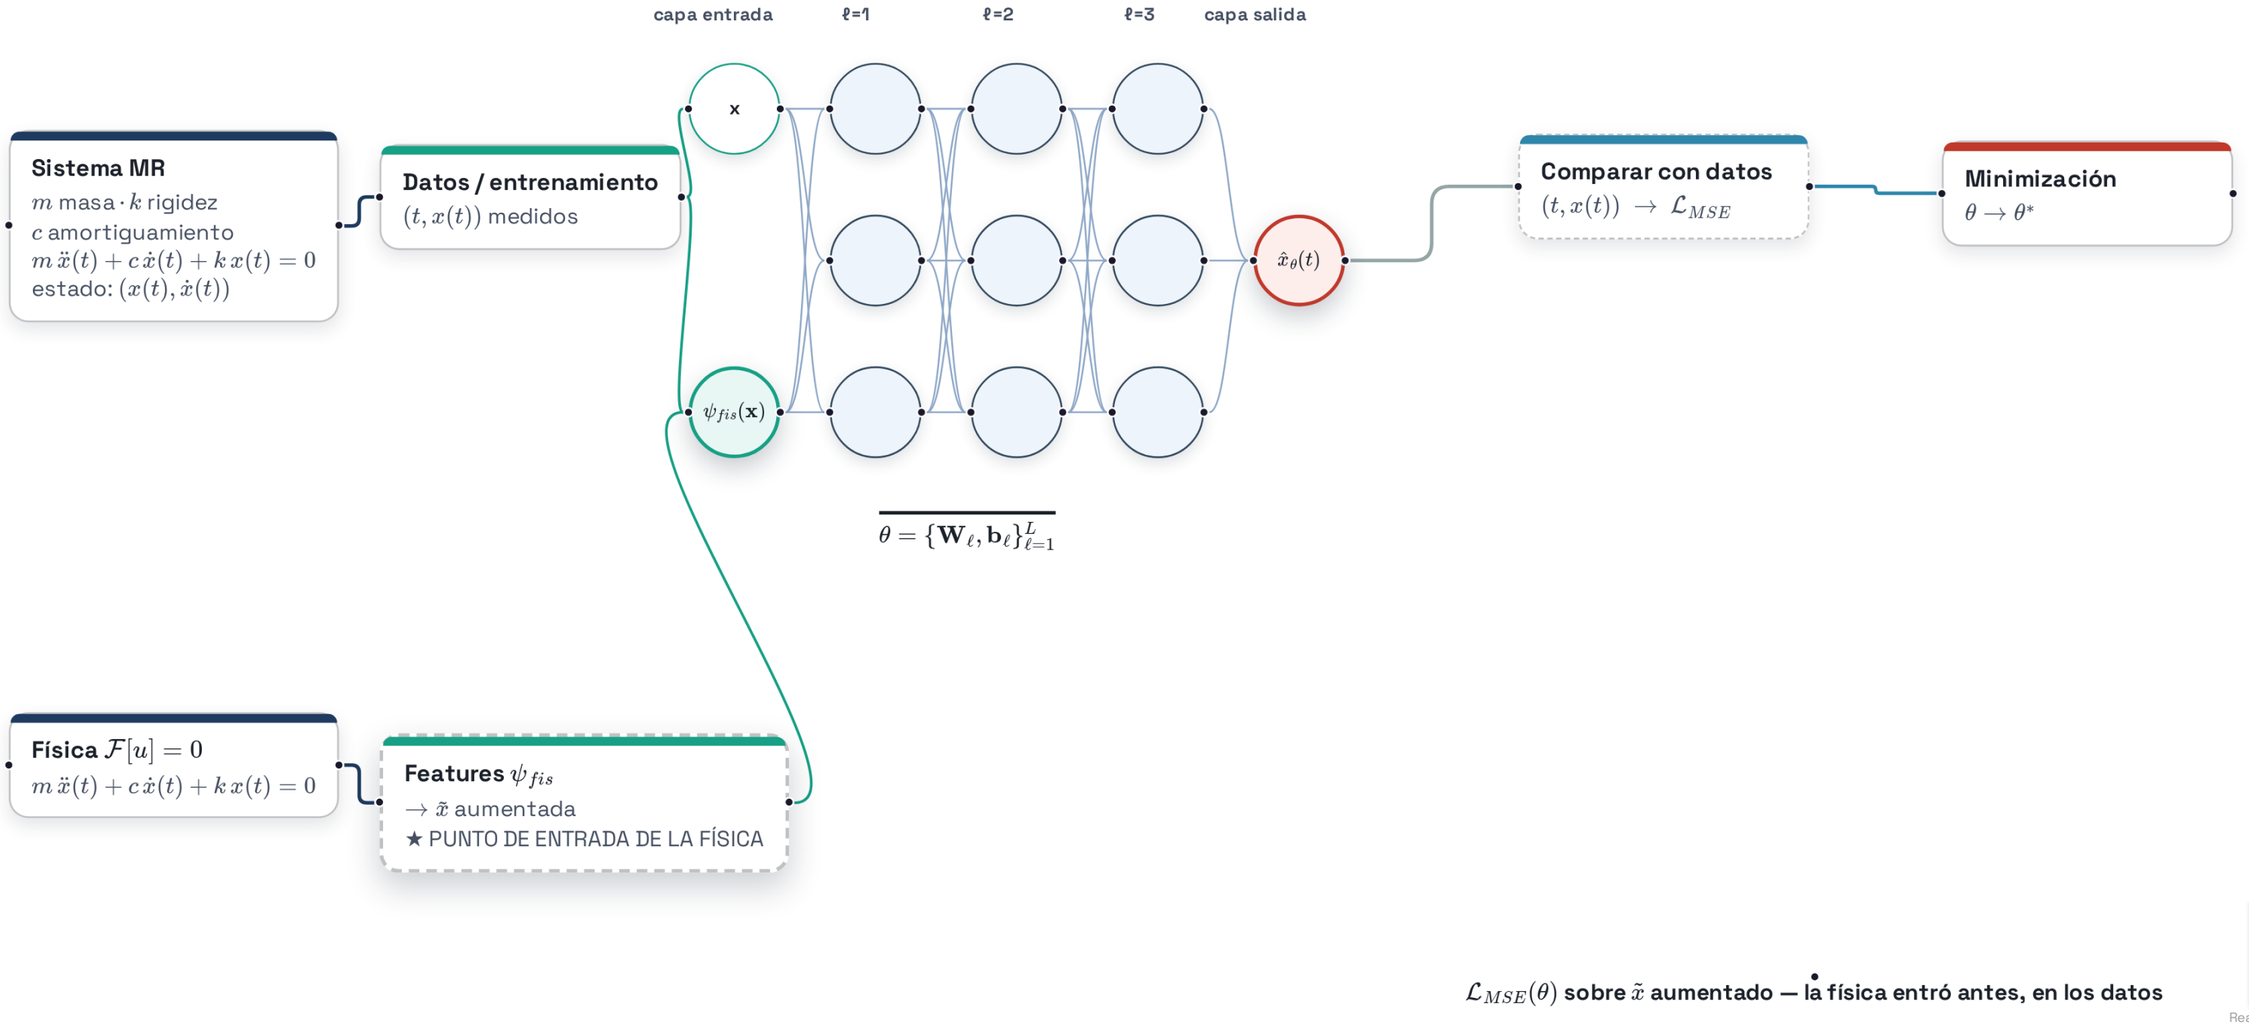
Problema de optimización (sobre $\tilde{\mathbf{x}}$ aumentado, + bottleneck)

$$\theta^* = \arg\min_{\theta \in \Theta}\ \mathcal{L}_{MSE}(\theta; \tilde{\mathbf{x}}), \qquad \mathbf{z}_{bot} = E(t)$$

Conexión: el problema se plantea sobre la entrada aumentada $\tilde{\mathbf{x}}$; en la variante con bottleneck la latente $\mathbf{z}_{bot}$ queda restringida a un significado físico explícito (Hao 2022).

Hao et al. PIML: A Survey on Problems, Methods and Applications. arXiv:2211.08064, 2022.
Willard et al. ACM Computing Surveys, 2022.
Machine Learning with Physics Knowledge for Prediction: A Survey. arXiv:2408.09840.

MR · Puerta ③ — la física entra en los datos / features



$\mathcal{L}_{MSE}(\theta)$ sobre $\tilde{x}$ aumentado — la física entró antes, en los datos

Sistema MR / física · ③ Datos / features · Modelo ML f_θ · Minimización → θ^*

Puerta ④ — Híbrido simulador + red (grey-box)

- **¿Por qué existen?:** un simulador confiable **subvenciona** a la red: f_{fis} da la predicción base —interpretable y físicamente correcta— y g_θ aprende solo el residuo.
- **¿Cuándo se eligen sobre la PINN pura?:** cuando existe un simulador/ley confiable y el riesgo de soluciones no físicas del entrenamiento PINN es alto; hereda la tradición grey-box de identificación de parámetros.

④ Híbrido simulador + red (grey-box)

$$\hat{y} = \underbrace{f_{fis}(\mathbf{x})}_{\text{predicción base física}} + \underbrace{g_\theta(\mathbf{x})}_{\text{residuo aprendido}} \quad \text{o} \quad \hat{y} = g_\theta\big(\mathbf{x},\, f_{fis}(\mathbf{x})\big)$$

Conexión: residual learning y feature stacking; tradición grey-box (Bacher & Madsen 2011).

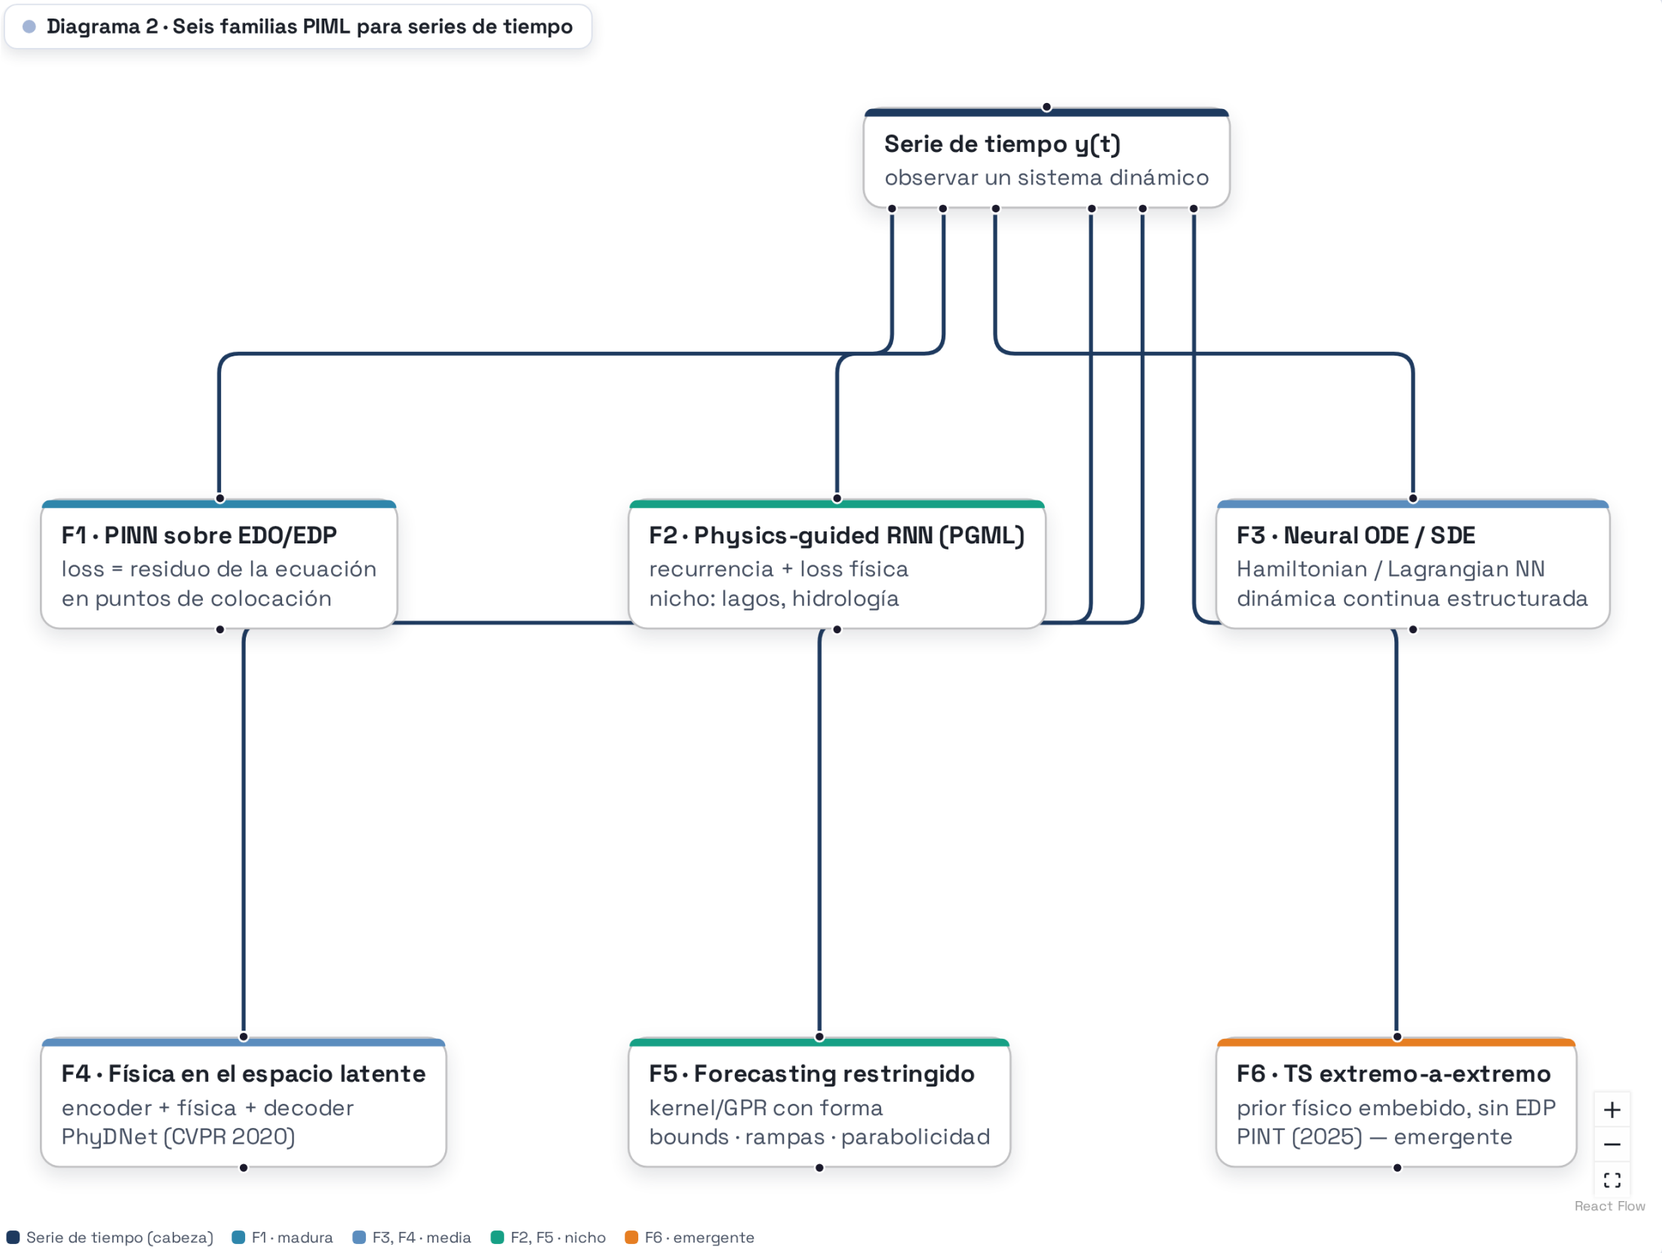
Bacher & Madsen. Identifying suitable models for the heat dynamics of buildings. Energy and Buildings 43, 2011.

4 · DIAGRAMA 2

Familias PIML para series de tiempo (todas las aplicaciones)

- Punto de partida común: la serie $y[t]$ observa un sistema dinámico gobernado por una ley $\mathcal{F}[u] = 0$ total o parcialmente conocida.
- **F1** PINN · **F2** PG-RNN · **F3** Neural ODE/SDE · **F4** física latente (PhyDNet) · **F5** kernel/GPR · **F6** física embebida (PINT/RFF).

Raissi et al., J. Comp. Physics 378, 2019 (F1) · Karpatne et al., arXiv:1710.11431 (F2) · Greydanus NeurIPS 2019 / Chen NeurIPS 2018 (F3) · Le Guen & Thome, CVPR 2020 (F4) · Doumèche 2025 / Tartakovsky IJF 2023 (F5) · PINT, arXiv:2502.04018 (F6).



4 · MATEMÁTICA DEL DIAGRAMA 2

F1 — PINN sobre EDO/EDP · F2 — Physics-guided RNN

F1 · La red aproxima la solución del sistema dinámico

$$\partial_t u + \mathcal{F}[u] = 0 \ \text{ en } \Omega_T, \qquad r_\theta(t,\mathbf{x}) = \partial_t u_\theta + \mathcal{F}[u_\theta]$$

Conexión: "la red aprende LA SOLUCIÓN" ↔ $u_\theta(t,\mathbf{x})$; el residuo se evalúa en los N_c puntos de colocación $(t_j,\mathbf{x}_j)$.

F1 · Pérdida con puntos de colocación

$$\mathcal{L}(\theta) = \frac{1}{N_d}\sum_{i=1}^{N_d} \left|u_\theta(t_i,\mathbf{x}_i) - u(t_i,\mathbf{x}_i)\right|^2 + \lambda_{phys}\,\frac{1}{N_c}\sum_{j=1}^{N_c} \left\|r_\theta(t_j,\mathbf{x}_j)\right\|^2$$

F2 · Recurrencia estándar + término físico

$$\mathbf{h}[t] = f_{RNN}(\mathbf{x}[t],\mathbf{h}[t-1];\Theta_r), \qquad \hat{y}[t] = g(\mathbf{h}[t])$$

Conexión: "recurrencia estándar" ↔ f_{RNN}; "consistencia temporal" ↔ $\mathcal{L}_{EC}$ (línea PGML de Karpatne).

F2 · Pérdida de consistencia temporal

$$\mathcal{L} = \mathcal{L}_{MSE} + \lambda_{phys}\,\mathcal{L}_{EC}, \qquad \mathcal{L}_{EC} = \sum_t \left\|r_{EC}(\hat{y}[t],\hat{y}[t-1],\mathbf{x}[t])\right\|^2$$

4 · MATEMÁTICA DEL DIAGRAMA 2

F3 — Neural ODE/SDE informados · F4 — Física en el espacio latente

F3 · Dinámica continua integrada con solver diferenciable

$$\frac{d\mathbf{h}(t)}{dt} = f_\theta(\mathbf{h}(t), t), \qquad \mathbf{h}(t_1) = \mathbf{h}(t_0) + \int_{t_0}^{t_1} f_\theta(\mathbf{h}(t), t)\, dt$$

Conexión: "estructura física parcial" ↔ forma hamiltoniana (puerta ② del D1) o lagrangiana Euler–Lagrange (siguiente ecuación); variante estocástica con dW_t.

F3 · Lagrangian NN (Euler–Lagrange)

$$\frac{d}{dt}\frac{\partial L_\theta}{\partial \dot{q}} - \frac{\partial L_\theta}{\partial q} = 0$$

Conexión: $q = q(t)$ y $\dot{q} = \dot{q}(t)$ dependen del tiempo; las derivadas parciales son respecto a esas variables (puerta ②, formulación lagrangiana).

F4 · PhyDNet: latente descompuesta física + residual

$$\mathbf{z}[t] = \mathbf{z}[t]^{phys} + \mathbf{z}[t]^{res}, \qquad \hat{y}[t] = \mathrm{Dec}(\mathbf{z}[t]), \qquad \mathbf{z}[t]^{phys} = \mathrm{PhyCell}(\mathbf{z}[t-1]^{phys})$$

Conexión: "encoder → latente donde actúa la física → decoder" ↔ Enc, PhyCell, Dec; "física + residual" ↔ $\mathbf{z}[t]^{phys} + \mathbf{z}[t]^{res}$.

4 · MATEMÁTICA DEL DIAGRAMA 2

F5 — Forecasting restringido · F6 — TS con física embebida

F5 · Kernel ridge con restricciones de forma

$$\hat{f}_\theta(\mathbf{x}) = \sum_{i=1}^{N} \theta_i \, \kappa(\mathbf{x}, \mathbf{x}_i), \qquad \theta = (\mathbf{K}_{GP} + \lambda_{rk}\mathbf{I})^{-1}\mathbf{y}$$

Conexión: "bounds, rampas, parabolicidad, estacionalidad" ↔ las restricciones sobre f; GPR con prior físico (formulación de Doumèche 2025 / PhI-GPR).

F6 · Prior físico cableado, sin EDP explícita

$$\hat{\mathbf{y}} = g_\theta\big(\mathbf{X};\, \mathcal{P}_{fis}\big)$$

Conexión: "inductive biases específicas" ↔ $\mathcal{P}_{fis}$ dentro de g_θ; el RFF multibanda (Ecuación 24) es una instancia con prior espectral.

F6 · RFF multibanda del artículo guía (Ecuación 24)

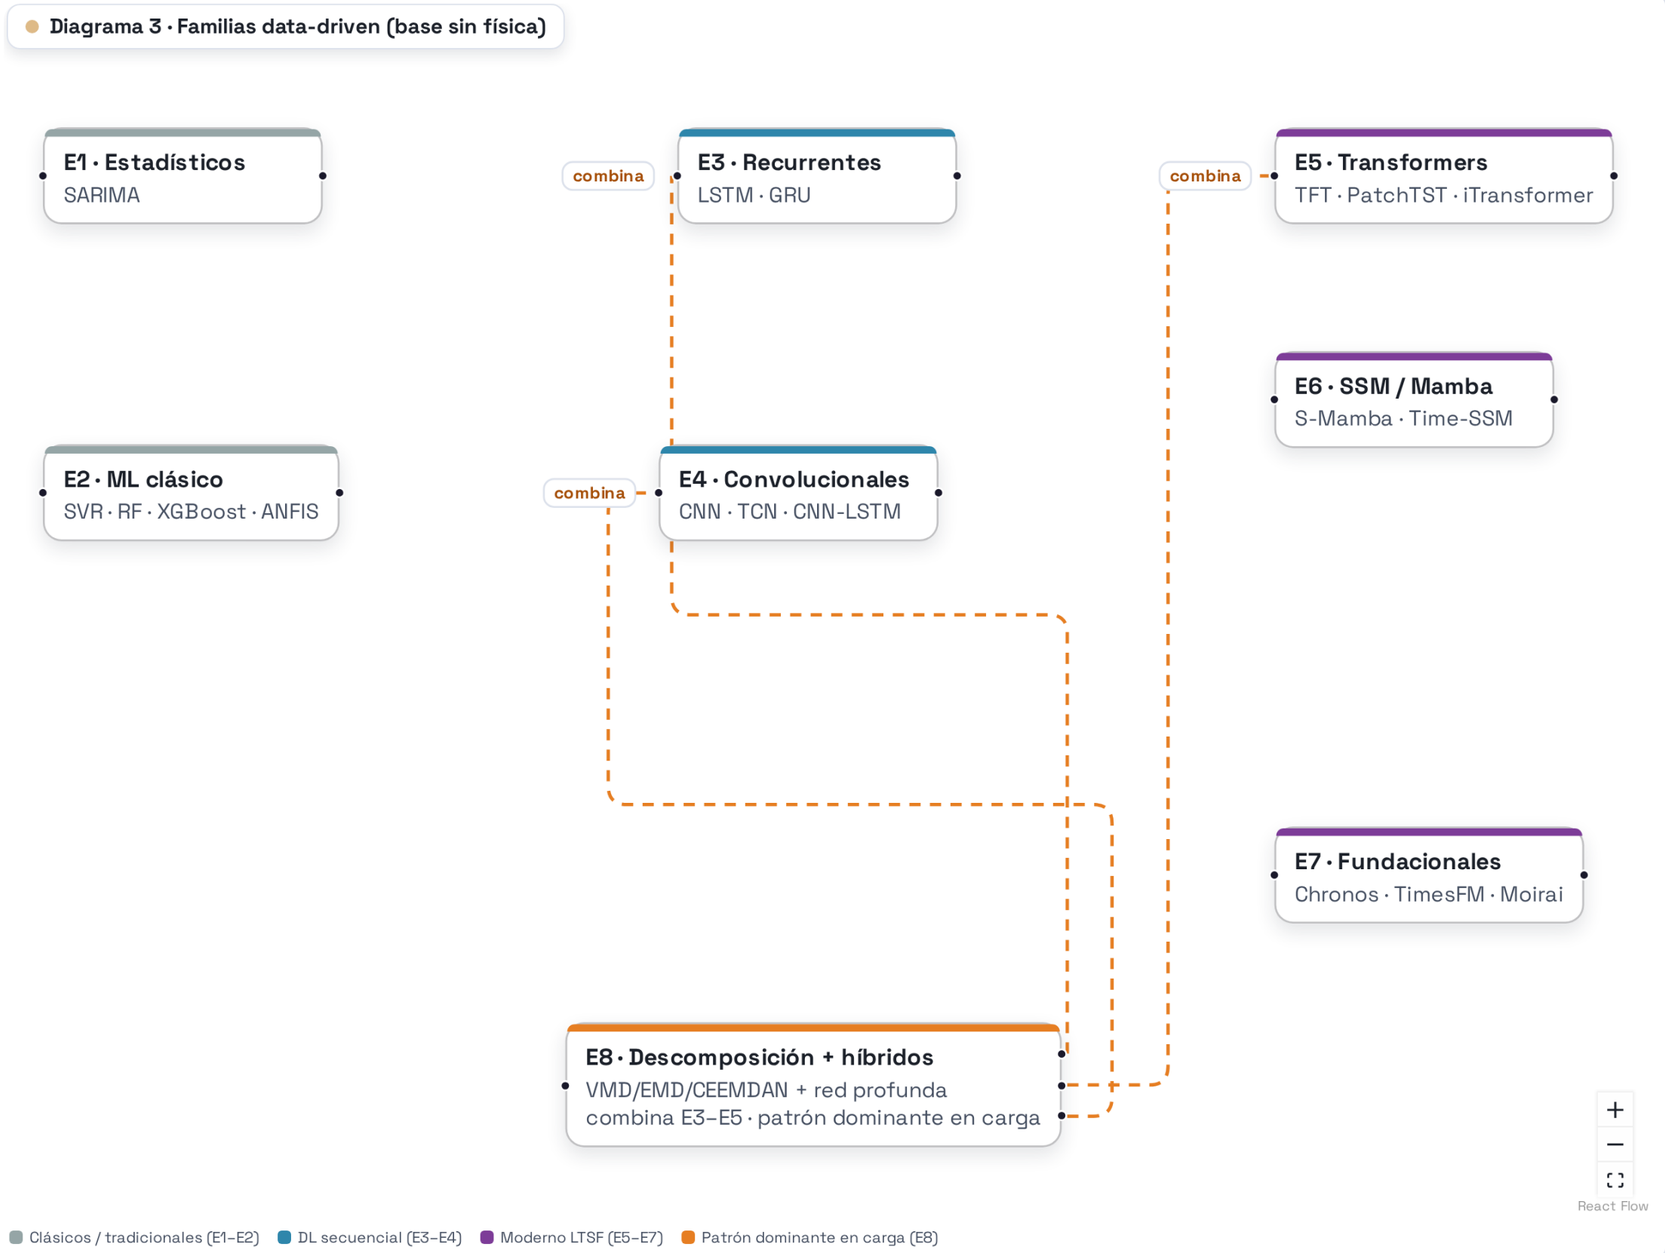
$$\boldsymbol{\phi}_k(\mathbf{x}[t]) = \sqrt{\frac{2}{N_f}}\, \cos\big(\text{softplus}(\rho_k)\, \mathbf{W}_k^\top \mathbf{x}[t] + \mathbf{b}_k\big)$$

5A · DIAGRAMA 3

Familias data-driven en sistemas energéticos (SIN física)

- El contraste necesario: la base contra la que se mide todo PIML energético — las 8 familias de la matriz SOTA 2022–2026.
- **E1** Estadísticos · **E2** ML clásico · **E3** Recurrentes · **E4** TCN · **E5** Transformers LTSF · **E6** SSM/Mamba · **E7** Fundacionales · **E8** Descomposición + híbridos (patrón dominante en carga).

Matriz interna (32 papers ≥2022; hoja "Matriz Energia" con 25) · Kim et al., arXiv:2411.05793 · Kong et al., IJMLC 16, 2025 · Benchmark KIT-IAI, arXiv:2607.15705, 2026.



5A · MATEMÁTICA DEL DIAGRAMA 3

E1 — Estadísticos clásicos (SARIMA)

- **Definición:** SARIMA$(p,d,q)(P,D,Q)_s$ — modelo autorregresivo integrado de medias móviles estacional: la serie se diferencia d veces —y D veces en el rezago estacional s— antes de modelarla con una parte autorregresiva (p, P) y una de medias móviles (q, Q).
- Es el único método estadístico clásico nombrado en esta sección y la línea base de comparación: la familia **E2** —SVR, árboles y ensambles, y los lineales regularizados— comienza en la diapositiva siguiente.

Ecuación general (Box–Jenkins)

$$\phi_p(\mathcal{B})\,\Phi_P(\mathcal{B}^s)\,(1-\mathcal{B})^d\,(1-\mathcal{B}^s)^D\,y[t] = c + \theta_q(\mathcal{B})\,\Theta_Q(\mathcal{B}^s)\,\varepsilon[t], \qquad \varepsilon[t] \sim \mathcal{N}(0,\sigma_\varepsilon^2)$$

Conexión: a la izquierda, la parte AR —simple $\phi_p(\mathcal{B})$ y estacional $\Phi_P(\mathcal{B}^s)$— junto con las diferenciaciones $(1-\mathcal{B})^d$ (tendencia) y $(1-\mathcal{B}^s)^D$ (estacionalidad); a la derecha, la parte MA —$\theta_q(\mathcal{B})$ y $\Theta_Q(\mathcal{B}^s)$— más la constante c y la innovación gaussiana $\varepsilon[t]$.

Operadores de rezago y parámetros

$$\mathcal{B}\,y[t] = y[t-1], \qquad \mathcal{B}^s\,y[t] = y[t-s]$$

Parámetros: p, P: orden AR (simple, estacional) · d, D: diferencias (simple, estacional) · q, Q: orden MA (simple, estacional) · s: período estacional (24 h diario, 168 h semanal). Los símbolos $\mathcal{B}, s, d, D, c$ son **locales** de esta diapositiva.

Ejemplo reducido: AR(1) con constante

$$\hat{y}[t] = c + \phi_1\,y[t-1]$$

Ejemplo: con $c = 20$, $\phi_1 = 0.9$ y $y[t-1] = 140$ kWh, el pronóstico es $\hat{y}[t] = 20 + 0.9\,(140) = 146$ kWh. Corresponde al caso SARIMA$(1,0,0)(0,0,0)_s$: sin diferenciación ni parte estacional.

Box, Jenkins, Reinsel, Ljung. Time Series Analysis: Forecasting and Control. Wiley, 5ª ed., 2015.
Hyndman & Athanasopoulos. Forecasting: Principles and Practice. OTexts, 3ª ed., 2021.

5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — Regresión lineal por mínimos cuadrados

- **Límites:** se rompe con colinealidad o con $d > N$; de esas dos fallas nacen ridge y lasso.

E2 · El modelo lineal

$$f_\theta(\mathbf{x}) = \mathbf{x}^\top \theta, \qquad \mathbf{y} = \mathbf{X}\theta + \boldsymbol{\varepsilon}$$

Conexión: el sesgo θ_0 va absorbido en $\mathbf{x}_i$, así que $\theta \in \mathbb{R}^d$; $\mathbf{X} \in \mathbb{R}^{N \times d}$ es la matriz de diseño: la minúscula $\mathbf{x}_i$ es su fila i (la muestra) y $\mathbf{x}_j$ su columna j (la variable); fuera de E2, $\mathbf{X}$ es la ventana de entrada $\tau \times d$. Cada θ_j es el **efecto marginal** de la variable j con el resto fijo: de ahí la interpretabilidad del modelo lineal frente a las familias E3–E7.

E2 · El criterio: residuo cuadrático mínimo

$$\hat{\theta} = \arg\min_\theta \sum_{i=1}^{N} \left(y_i - \mathbf{x}_i^\top \theta\right)^2$$

Conexión: i numera muestras y no es tiempo, por eso va como subíndice y nunca con corchetes. El criterio tampoco es arbitrario: es la pérdida $\mathcal{L}_{MSE}$ sin normalizar, equivalente a $\arg\min_\theta \|\mathbf{y} - \mathbf{X}\theta\|_2^2$, la misma que el resto del deck usa para comparar predicciones. Y sobrevive intacto cuando se le añade la penalización de ridge y lasso en las tres slides siguientes: lo único que cambia es el término que se suma.

E2 · La solución: ecuación normal

$$\hat{\theta} = \left(\mathbf{X}^\top \mathbf{X}\right)^{-1} \mathbf{X}^\top \mathbf{y}$$

Conexión: igualar a cero el gradiente $-2\mathbf{X}^\top(\mathbf{y} - \mathbf{X}\theta)$ da la ecuación normal $\mathbf{X}^\top\mathbf{X}\hat{\theta} = \mathbf{X}^\top\mathbf{y}$; con ella el residuo $\mathbf{e} = \mathbf{y} - \mathbf{X}\hat{\theta}$ queda ortogonal a las columnas ($\mathbf{X}^\top\mathbf{e} = \mathbf{0}$). Solución única sii $\operatorname{rango}(\mathbf{X}) = d$.

Idea central: mínimos cuadrados no elige el modelo, elige los coeficientes: la solución cerrada sale de igualar a cero el gradiente y deja el residuo ortogonal a las columnas de $\mathbf{X}$. Todo lo que sigue —verosimilitud, ridge, lasso— cambia el criterio o le añade un término, pero conserva esta lectura. Ojo con el vocabulario: $\mathbf{e}$ es residuo (observable), $\boldsymbol{\varepsilon}$ es error (no observable), y $R^2 = 1 - \|\mathbf{e}\|_2^2 / \|\mathbf{y} - \bar{y}\mathbf{1}\|_2^2$ crece siempre al añadir variables, por eso se reporta el ajustado.

5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — Máxima verosimilitud con ruido gaussiano

- La verosimilitud convierte un supuesto sobre el **ruido** en un criterio de ajuste.
- Añade dos cosas: la varianza $\hat{\sigma}^2$ —y con ella la inferencia— y la lectura bayesiana de ridge y lasso.
- No valida la linealidad del modelo: sólo describe el error.

E2 · El modelo generativo y la verosimilitud

$$p(\mathbf{y} \mid \mathbf{X}, \theta, \sigma^2) = \left(2\pi\sigma^2\right)^{-N/2} \exp\left(-\|\mathbf{y} - \mathbf{X}\theta\|_2^2 / (2\sigma^2)\right)$$

Conexión: el modelo generativo es $y_i = \mathbf{x}_i^\top \theta + \varepsilon_i$ con $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ **iid**, donde ε_i es el ruido **por muestra** (subíndice porque i no es tiempo): no confundirlo con la innovación $\varepsilon[t]$ de SARIMA, que sí va con corchete. El paso de «iid» al producto es todo lo que hace la verosimilitud: multiplica las densidades porque las muestras son independientes. Y al ser lineal-gaussiano, la densidad conjunta queda en **forma cerrada** — sin optimización numérica, a diferencia de E3–E7.

E2 · Log-verosimilitud negativa: el puente con mínimos cuadrados

$$-\log p(\mathbf{y} \mid \mathbf{X}, \theta, \sigma^2) = \propto \ \|\mathbf{y} - \mathbf{X}\theta\|_2^2$$

Conexión: con σ^2 fijo, ni la constante $\frac{N}{2}\log(2\pi\sigma^2)$ ni el factor $\frac{1}{2\sigma^2}$ afectan al óptimo sobre θ: queda una **proporcionalidad** con el residuo cuadrático. Por tanto **maximizar la verosimilitud es minimizar el error cuadrático**: el criterio de mínimos cuadrados de la slide anterior no era una elección estética, es lo que produce suponer ruido gaussiano iid. Con otra distribución la equivalencia se rompe y la pérdida óptima puede no ser la cuadrática.

E2 · Los estimadores y su dispersión

$$\hat{\theta} = \left(\mathbf{X}^\top \mathbf{X}\right)^{-1} \mathbf{X}^\top \mathbf{y}, \qquad \hat{\sigma}^2_{MLE} = \frac{1}{N} \|\mathbf{y} - \mathbf{X}\hat{\theta}\|_2^2$$

Conexión: el estimador de θ coincide con OLS, y con él llega la **matriz de covarianza** $\mathrm{Var}(\hat{\theta}) = \sigma^2 \left(\mathbf{X}^\top \mathbf{X}\right)^{-1}$: de ahí salen los errores estándar, los contrastes t y los intervalos de confianza. Cuidado con $\hat{\sigma}^2_{MLE}$: divide por N y es **sesgado**; el insesgado divide por $N - d$. La verosimilitud no mejora el estimador puntual, le añade la incertidumbre.

Idea central: MLE no cambia a $\hat{\theta}$; justifica el criterio, da varianza e inferencia, y abre el punto de vista bayesiano. **Puente:** un prior sobre θ más esta verosimilitud produce un estimador MAP —gaussiano da ridge, Laplace da lasso—; regularizar es declarar una creencia previa.

5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — Ridge: penalización cuadrática y contracción

- Añade un castigo cuadrático al ajuste: ℓ_2 contrae los coeficientes hacia cero **sin anularlos**.
- Gana cuando $\mathbf{X}^\top\mathbf{X}$ está mal condicionada: la penalización vuelve el problema invertible.
- Es el estimador **MAP** con prior gaussiano sobre θ: regularizar es imponer una creencia previa.
- El precio es sesgo deliberado, y λ_{reg} se elige por validación cruzada.

E2 · El objetivo penalizado

$$\mathcal{L}_{ridge}(\theta) = \|\mathbf{y} - \mathbf{X}\theta\|_2^2 + \lambda_{reg}\|\theta\|_2^2$$

Conexión: $\hat{\theta}_{ridge} = \arg\min_\theta \mathcal{L}_{ridge}(\theta)$. Aquí $\lambda_{reg} \geq 0$ es la fuerza de penalización y lleva símbolo propio: no es λ_{phys} (el peso físico de las puertas ① y ④) ni λ_{rk} (kernel ridge, familia F5). Con $\lambda_{reg} = 0$ se recupera OLS exactamente. La forma es idéntica a la pérdida compuesta $\mathcal{L}_{MSE} + \lambda_{phys}\mathcal{L}_{phys}$: cambia qué se castiga, no la estructura. (Hoerl & Kennard, 1970.)

E2 · Solución cerrada y buen planteamiento

$$\hat{\theta}_{ridge} = \left(\mathbf{X}^\top\mathbf{X} + \lambda_{reg}\mathbf{I}\right)^{-1}\mathbf{X}^\top\mathbf{y}, \qquad \mathbf{X}^\top\mathbf{X} + \lambda_{reg}\mathbf{I} \succ 0$$

Conexión: para todo $\lambda_{reg} > 0$, sumar $\lambda_{reg}\mathbf{I}$ desplaza todos los autovalores a $\mu_k + \lambda_{reg} > 0$, así que la matriz es definida positiva —y por tanto invertible— **siempre**. El problema queda bien puesto incluso en los dos casos que dejan a OLS sin solución única: colinealidad perfecta y $d > N$.

E2 · Contracción espectral, vía la SVD de $\mathbf{X}$

$$\hat{\theta}_{ridge} = \sum_k \kappa_k \, \mathbf{v}_k \mathbf{u}_k^\top \mathbf{y}, \qquad \mathbf{X} = \mathbf{U}\mathbf{S}\mathbf{V}^\top$$

Conexión: con la SVD $\mathbf{X} = \mathbf{U}\mathbf{S}\mathbf{V}^\top$, cada dirección singular k se contrae por el factor $\kappa_k = s_k^2/(s_k^2 + \lambda_{reg}) \in (0, 1)$, que **nunca llega a cero**. De ahí las dos propiedades que definen a ridge: ninguna dirección se elimina, y la contracción es más fuerte precisamente donde s_k es pequeño, es decir, en las direcciones peor condicionadas. La suma de esos factores es el número efectivo de parámetros $\mathrm{df}(\lambda_{reg})$, que decrece con λ_{reg}.

Sesgo–varianza: OLS es insesgado y de varianza mínima dentro de su clase lineal; ridge acepta sesgo a cambio de menos varianza, y por eso gana cuando $\mathbf{X}^\top\mathbf{X}$ está mal condicionada. **Lo que lo separa de lasso:** reparte el peso entre variables correlacionadas y nunca produce un modelo esparso: un coeficiente puede quedar diminuto, pero no exactamente cero.

5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — Lasso: penalización en valor absoluto y selección

- Cambia la norma: ℓ_1 en vez de ℓ_2, y con ella la penalización deja de ser diferenciable en el origen.
- Consecuencia: anula coeficientes **exactamente**. Selecciona variables, no sólo las contrae.
- Es el estimador **MAP** con prior Laplace: la masa del prior en cero produce la esparsidad.

E2 · El objetivo penalizado y su forma restringida

$$\mathcal{L}_{lasso}(\theta) = \|\mathbf{y} - \mathbf{X}\theta\|_2^2 + \lambda_{reg}\|\theta\|_1$$

Conexión: $\hat{\theta}_{lasso} = \arg\min_\theta \mathcal{L}_{lasso}(\theta)$. Misma familia que ridge, con $\|\theta\|_1 = \sum_j |\theta_j|$; pero la norma ℓ_1 no es diferenciable en el origen y por eso **no tiene solución cerrada general**. λ_{reg} tiene aquí una lectura distinta y directamente interpretable: es el umbral por debajo del cual un coeficiente se anula, no una simple contracción. Su forma restringida equivalente es $\min\|\mathbf{y} - \mathbf{X}\theta\|_2^2$ sujeto a $\|\theta\|_1 \leq c$, con c decreciente en λ_{reg}. (Tibshirani, 1996.)

E2 · Condiciones KKT: por qué anula coeficientes

$$\mathbf{x}_j^\top (\mathbf{y} - \mathbf{X}\theta) = \lambda_{reg}\,\text{sign}(\theta_j) \text{ si } \theta_j \neq 0, \qquad \left|\mathbf{x}_j^\top (\mathbf{y} - \mathbf{X}\theta)\right| \leq \lambda_{reg} \text{ si } \theta_j = 0$$

Conexión: $j = 1 \ldots d$ indexa variables, ni muestras ni tiempo. Mientras la correlación de la variable j con el residuo no supere λ_{reg} en valor absoluto, su coeficiente queda **exactamente** en cero — así es como ℓ_1 selecciona. Con diseño ortonormal el sistema se resuelve a mano y aparece el operador de umbral suave de la ecuación siguiente.

E2 · Umbral suave (ortonormal) y geometría del politopo

$$\hat{\theta}_j^{lasso} = \text{sign}(\hat{\theta}_j^{OLS}) \max\left(|\hat{\theta}_j^{OLS}| - \lambda_{reg},\ 0\right)$$

Conexión: $(\cdot)_+ = \max(\cdot, 0)$; la forma cerrada vale con diseño ortonormal, y en general se resuelve por programación convexa (descenso por coordenadas, LARS). La restricción ℓ_1 es un politopo —un rombo en dos dimensiones— con **vértices sobre los ejes**, y el óptimo cae en un vértice: ahí la mayoría de las coordenadas son cero. La bola ℓ_2 de ridge, al ser lisa, sólo contrae. Ésa es toda la diferencia entre **seleccionar** y **repartir**.

Puente a la siguiente slide: las cuatro comparten el esqueleto —ajuste más castigo— y ese esqueleto reaparece en $\mathcal{L}_{MSE} + \lambda_{phys}\mathcal{L}_{phys}$. **Límites de lasso:** con $d > N$ selecciona a lo sumo N variables y ante variables correlacionadas elige de forma inestable; la red elástica ($\ell_1 + \ell_2$) corrige ambos casos.

Referencias: Hoerl & Kennard, Technometrics 12(1), 1970 (ridge) · Tibshirani, JRSS-B 58(1), 1996 (lasso) · Zou & Hastie, JRSS-B 67(2), 2005 (red elástica) · Hastie, Tibshirani & Friedman, The Elements of Statistical Learning, 2.ª ed., 2009, cap. 3.

5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — ElasticNet: penalización $\ell_1 + \ell_2$

- Suma los dos castigos: la contracción de ridge y la selección de lasso.
- Resuelve el punto débil de lasso: con variables correlacionadas deja de elegir una al azar.
- No tiene forma cerrada: se resuelve por programación convexa.

E2 · El objetivo penalizado

$$\mathcal{L}_{EN}(\theta) = \|\mathbf{y} - \mathbf{X}\theta\|_2^2 + \lambda_{reg}\left[(1-\rho_{en})\|\theta\|_2^2 + \rho_{en}\|\theta\|_1\right]$$

Conexión: $\hat{\theta}_{EN} = \arg\min_\theta \mathcal{L}_{EN}(\theta)$, con $\rho_{en} \in [0,1]$ la **mezcla** (local: no es el ancho espectral ρ_k del RFF) y λ_{reg} la fuerza única de la familia penalizada. Los extremos son conocidos: $\rho_{en} = 0$ devuelve **ridge** exactamente y $\rho_{en} = 1$ devuelve **lasso**. Es el regularizador del benchmark del proyecto, donde los rezagos están correlacionados de forma cíclica (24 h y 168 h). (Zou & Hastie, 2005.)

E2 · Condiciones KKT: selección con agrupamiento

$$\mathbf{x}_j^\top(\mathbf{y} - \mathbf{X}\theta) = \lambda_{reg}\rho_{en}\,\mathrm{sign}(\theta_j) + \lambda_{reg}(1-\rho_{en})\,\theta_j \text{ si } \theta_j \neq 0, \qquad \left|\mathbf{x}_j^\top(\mathbf{y} - \mathbf{X}\theta)\right| \leq \lambda_{reg}\rho_{en} \text{ si } \theta_j = 0$$

Conexión: la condición de anulación es la de lasso —umbral $\lambda_{reg}\rho_{en}$— y el término $\lambda_{reg}(1-\rho_{en})\theta_j$ es el que aporta ridge. Ese término **reparte** el peso entre variables correlacionadas: si dos rezagos son casi idénticos, sus coeficientes crecen juntos en vez de que uno anule al otro. Ésa es la corrección que el cierre de lasso anunciaba; la ℓ_1 no diferenciable en el origen impide una forma cerrada general.

E2 · Umbral suave encogido (diseño ortonormal)

$$\hat{\theta}_j^{EN} = \frac{\mathrm{sign}\left(\hat{\theta}_j^{OLS}\right)\max\left(\left|\hat{\theta}_j^{OLS}\right| - \lambda_{reg}\rho_{en},\ 0\right)}{1 + \lambda_{reg}(1-\rho_{en})}$$

Conexión: con diseño ortonormal el operador se lee en dos pasos: **umbral** con $\lambda_{reg}\rho_{en}$ —igual que lasso, y de ahí la esparsidad— y **encogimiento** por el factor $1/(1+\lambda_{reg}(1-\rho_{en}))$ —la herencia de ridge—. El resultado interpola entre los dos estimadores: no anula tan agresivamente como lasso ni reparte tan suavemente como ridge.

Cierre del bloque penalizado: OLS, MLE, ridge, lasso y ElasticNet comparten un solo esqueleto —ajuste más castigo— y se distinguen por el término que se suma; ese mismo esqueleto reaparece en $\mathcal{L}_{MSE} + \lambda_{phys}\mathcal{L}_{phys}$ de la puerta ①. **En el protocolo:** Ridge y ElasticNet comparten el espacio de búsqueda de λ_{reg}, con ρ_{en} como dimensión extra.

Referencias: Zou & Hastie, JRSS-B 67(2), 301–320, 2005 · Hastie, Tibshirani & Friedman, The Elements of Statistical Learning, 2.ª ed., 2009, cap. 3.

5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — DLinear: descomposición lineal y baseline obligatorio

- Separa la ventana en **tendencia** y **resto** con un promedio móvil.
- Proyecta cada componente con su propia capa lineal: dos proyecciones, no una.
- El protocolo del proyecto lo resuelve por mínimos cuadrados: determinista, sin semillas.

E2 · Descomposición de la ventana

$$x_\tau^{tend} = \frac{1}{p_{ma}} \sum_{s=-\lfloor (p_{ma}-1)/2 \rfloor}^{\lfloor p_{ma}/2 \rfloor} x_{\tau+s}, \qquad x_\tau^{rem} = x_\tau - x_\tau^{tend}$$

Conexión: p_{ma} es el período del promedio móvil (24 h en el protocolo) y los bordes se rellenan. La descomposición es la clásica tendencia más resto: x^{tend} captura el nivel lento y x^{rem} la estacionalidad y el ruido de alta frecuencia. Símbolos locales: p_{ma} (local: no es el momento $p(t)$ del MR), x^{tend}, x^{rem}, $\mathbf{W}_{tend}$, $\mathbf{W}_{rem}$.

E2 · El modelo: dos proyecciones lineales

$$\hat{\mathbf{y}} = \mathbf{W}_{tend}\, x^{tend} + \mathbf{b}_{tend} + \mathbf{W}_{rem}\, x^{rem} + \mathbf{b}_{rem}, \qquad \mathbf{W}_{tend}, \mathbf{W}_{rem} \in \mathbb{R}^{h \times \tau}$$

Conexión: cada componente tiene su propia proyección $\mathbb{R}^\tau \to \mathbb{R}^h$: la tendencia se proyecta a la tendencia del horizonte, el resto al resto, y luego se suman. Los pesos son bloques de θ por S2: $\theta = \{\mathbf{W}_{tend}, \mathbf{b}_{tend}, \mathbf{W}_{rem}, \mathbf{b}_{rem}\}$. **La ventaja no es la capacidad** — unos 18.7 k parámetros con $\tau = h = 96$— sino el sesgo inductivo de separar tendencia de alta frecuencia.

E2 · El ajuste: mínimos cuadrados directos

$$\hat{\theta} = \arg\min_\theta \; \|\mathbf{Y} - \hat{\mathbf{Y}}(\theta)\|_F^2$$

Conexión: el artículo original entrena con descenso de gradiente; el protocolo del proyecto resuelve cada proyección con **mínimos cuadrados cerrados** (SVD y pseudo-inversa), que es la solución exacta del problema cuadrático. De ahí dos consecuencias: es **determinista** —sin semillas ni épocas— y es la cota lineal moderna del benchmark. $\|\cdot\|_F$ es la norma de Frobenius.

Por qué está en el deck: es el baseline obligatorio: ningún modelo nuevo se reporta sin superarlo. **Su tesis:** un modelo lineal bien descompuesto iguala o supera a los Transformers en LTSF. **Contraste:** extrapola (es lineal) y es determinista; no modela interacciones no lineales.

Referencias: Zeng, Chen, Zhang & Xu, Are Transformers Effective for Time Series Forecasting?, AAAI 2023 · protocolo interno del benchmark de regresión (§1, Tabla A).

5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — SVR: pérdida ε_{svr}-insensible y margen máximo

- No penaliza todo error: sólo el que excede un tubo de tolerancia ε_{svr}.
- Margen y violaciones conviven en un problema **convexo** con óptimo único.
- El dual sólo necesita productos internos: de ahí el **truco del kernel**.

E2 · El modelo y la pérdida ε_{svr}-insensible

$$f_\theta(\mathbf{x}) = \langle \theta, \varphi(\mathbf{x}) \rangle, \qquad \ell_{\varepsilon_{svr}}\big(y_i, f_\theta(\mathbf{x}_i)\big) = \max\left(0,\ |y_i - f_\theta(\mathbf{x}_i)| - \varepsilon_{svr}\right)$$

Conexión: $\varphi(\mathbf{x})$ es el mapa al espacio de características y ε_{svr} el radio del tubo: los errores menores que ε_{svr} no cuestan nada, así que es robusto al ruido pequeño —a diferencia del residuo cuadrático de $\mathcal{L}_{MSE}$—. Símbolos locales: φ, $\xi_i^{(*)}$, $\alpha_i^{(*)}$.

E2 · El problema de optimización (primal)

$$\min_{\theta,\, \boldsymbol{\xi},\, \boldsymbol{\xi}^*} \ \frac{1}{2}\|\theta\|_2^2 + \lambda_{svr} \sum_{i=1}^{N} (\xi_i + \xi_i^*) \quad \text{s.a. } |y_i - f_\theta(\mathbf{x}_i)| \le \varepsilon_{svr} + \xi_i^{(*)}, \quad \xi_i^{(*)} \ge 0$$

Conexión: $\xi_i^{(*)}$ son las holguras por debajo y por encima del tubo. El objetivo minimiza dos cosas a la vez: la norma $\|\theta\|_2^2$ —el **margen**, que controla la capacidad— y la suma de violaciones. λ_{svr} pesa el error frente al margen, con el mismo papel que λ_{reg} en ridge y lasso. Es un primal **convexo**: el óptimo es único.

E2 · El dual y el truco del kernel

$$\hat{f}_\theta(\mathbf{x}) = \sum_{i=1}^{N} (\alpha_i - \alpha_i^*)\kappa(\mathbf{x}, \mathbf{x}_i), \qquad \kappa(\mathbf{x}, \mathbf{x}_i) = \langle \varphi(\mathbf{x}), \varphi(\mathbf{x}_i) \rangle, \qquad 0 \le \alpha_i^{(*)} \le \lambda_{svr}$$

Conexión: el dual sólo usa productos internos κ, así que φ nunca se calcula explícitamente: ése es el **truco del kernel**. Se cumple $\alpha_i^{(*)} = 0$ para los puntos dentro del tubo; sólo los que lo violan —los **vectores de soporte**— definen la solución.

Idea central: SVR no minimiza el error cuadrático; minimiza margen más violaciones del tubo. **Puente:** es el mismo esqueleto ajuste más castigo de OLS, ridge y lasso, con la pérdida ε_{svr}-insensible. **Contraste:** es programación cuadrática, no una ecuación normal: no hay forma cerrada general.

Referencias: Vapnik, The Nature of Statistical Learning Theory, 2.ª ed., 2000 · Smola & Schölkopf, Statistics and Computing 14, 199–222, 2004 · Hastie, Tibshirani & Friedman, The Elements of Statistical Learning, 2.ª ed., 2009, cap. 12.

5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — Árbol de regresión (CART): partición recursiva

- No supone linealidad: aproxima f con **cajas** del espacio de entrada.
- Dentro de cada hoja la predicción es constante: la media de sus muestras.
- Buscar el árbol óptimo es NP-duro; en la práctica se crece **greedy** y se poda.

E2 · El modelo: función escalón sobre una partición

$$\hat{y}(\mathbf{x}) = \sum_{j=1}^{J_{arb}} c_j \, \mathbb{1}[\mathbf{x} \in R_j], \qquad c_j = \frac{1}{|R_j|} \sum_{\mathbf{x}_i \in R_j} y_i$$

Conexión: R_j es la caja (región) de la hoja j, J_{arb} el número de hojas (local: no son los modos J de la familia E8) y c_j la **media** de las muestras que caen en ella (local: no es el término constante c del SARIMA). La predicción es una función escalón: constante por caja y discontinua en los cortes. Símbolos locales de esta slide: J_{arb}, R_j, c_j, k, s; i sigue siendo el índice de muestra y nunca tiempo.

E2 · El criterio del split (búsqueda greedy)

$$\min_{k,\,s} \left[\min_{c_1} \sum_{\mathbf{x}_i \in R_1(k,s)} (y_i - c_1)^2 + \min_{c_2} \sum_{\mathbf{x}_i \in R_2(k,s)} (y_i - c_2)^2 \right]$$

Conexión: k es la variable (un rezago) y s el umbral del corte que parte el nodo en $R_1(k,s)$ y $R_2(k,s)$. El criterio es la **suma de cuadrados intra-hoja**, equivalente a maximizar la suma de cuadrados entre los dos grupos: en cada paso se busca el par (k,s) que más reduce el error de ajuste, con las medias c_1, c_2 recalculadas. Optimizar la partición completa es **NP-duro** y el árbol **no extrapola**: su predicción queda dentro del rango de y de sus hojas.

Sesgo–varianza: un árbol profundo tiene varianza alta y sesgo bajo; uno poco profundo, lo contrario. Ése es el compromiso que atacan los dos ensambles siguientes: **bagging** para la varianza y **boosting** para el sesgo. El árbol es determinista; lo estocástico llega con los ensambles.

Referencias: Breiman, Friedman, Olshen & Stone, Classification and Regression Trees, 1984 · Hastie, Tibshirani & Friedman, The Elements of Statistical Learning, 2.ª ed., 2009, cap. 9.

5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — Random Forest: bagging sobre árboles

- Promedia M_{arb} árboles entrenados sobre **muestras bootstrap**.
- Cada split considera sólo m_{try} variables al azar: así baja la correlación entre árboles.
- No reduce el sesgo del árbol base: su objetivo es la **varianza**.

E2 · El modelo: promedio de árboles bootstrap

$$\hat{y}(\mathbf{x}) = \frac{1}{M_{arb}} \sum_{m=1}^{M_{arb}} T_m(\mathbf{x}), \qquad T_m \sim \text{bootstrap}\,(\mathbf{X}, N) \quad \text{con } m_{try} \text{ variables por split}$$

Conexión: cada T_m es un árbol CART completo, entrenado sobre una **remuestra con reemplazo** de las N filas de $\mathbf{X}$ (bootstrap) y decidido con sólo m_{try} variables candidatas en cada split (en regresión, típicamente $d/3$). El promedio reduce la varianza sin cambiar la forma del modelo por árbol. Símbolos locales: M_{arb}, T_m, m_{try}, ρ_{arb} (local: no es el ancho espectral ρ_k), σ^2_{arb}.

E2 · Por qué promediar reduce la varianza

$$\text{Var}\left(\hat{y}(\mathbf{x})\right) = \rho_{arb}\,\sigma^2_{arb} + \frac{1-\rho_{arb}}{M_{arb}}\,\sigma^2_{arb}$$

Conexión: si cada árbol tiene varianza σ^2_{arb} y la correlación media entre pares es ρ_{arb}, el promedio elimina **sólo** la parte no correlacionada: el segundo término desaparece con $M_{arb} \to \infty$, pero el primero se queda. De ahí el **piso** $\rho_{arb}\sigma^2_{arb}$ y el papel de m_{try}: bajar ρ_{arb} a cambio de algo de sesgo.

Bagging frente a boosting: el bosque promedia en paralelo para bajar varianza; el boosting suma en serie para bajar sesgo. **Multi-salida:** el criterio del split puede sumar el RSS de las h componentes, así que un solo bosque predice todo el horizonte. **Protocolo:** `n_estimators` en 200/500/1000 y `max_depth` en None/8/16/32; al ser estocástico, se reporta media y desviación sobre semillas.

Referencias: Breiman, Machine Learning 45(1), 5–32, 2001 · Hastie, Tibshirani & Friedman, The Elements of Statistical Learning, 2.ª ed., 2009, cap. 15.

5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — Gradient Boosting (XGBoost): ajustar el residuo

- Construye el modelo **aditivamente**: cada árbol corrige lo que dejó el anterior.
- Cada T_m ajusta el **gradiente negativo** de la pérdida, no y directamente.

E2 · El modelo aditivo y los pseudo-residuos

$$F_0(\mathbf{x}) = \bar{y}, \qquad F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \nu\, T_m(\mathbf{x}), \qquad r_{im} = -\left.\frac{\partial \ell\left(y_i, F(\mathbf{x}_i)\right)}{\partial F(\mathbf{x}_i)}\right|_{F=F_{m-1}} = y_i - F_{m-1}(\mathbf{x}_i)$$

Conexión: el ensamble arranca en la media $\bar{y}$ y cada paso suma un árbol escalado por el **shrinkage** $\nu \in (0, 1]$. r_{im} es el **pseudo-residuo**: el gradiente negativo de la pérdida por muestra, evaluado en el modelo anterior.

E2 · El objetivo del ensamble y su aproximación por iteración

$$\mathcal{L}\left(F\right) = \sum_{i=1}^{N} \ell\left(y_i, F(\mathbf{x}_i)\right) + \sum_{m=1}^{M_{arb}} \Omega\left(T_m\right), \qquad \text{Obj}^{(m)} = \sum_{i=1}^{N} \left[g_i\, T_m(\mathbf{x}_i) + \frac{1}{2}\, \eta_i\, T_m(\mathbf{x}_i)^2 \right] + \Omega\left(T_m\right)$$

Conexión: el objetivo global es pérdida de datos **más** castigo por complejidad de cada árbol. Como minimizar $\mathcal{L}$ directamente es intratable, XGBoost expande $\mathcal{L}$ a **segundo orden** alrededor de F_{m-1} y minimiza $\text{Obj}^{(m)}$, con g_i el gradiente y η_i la curvatura (segunda derivada) por muestra. Símbolo local: η_i **no** es el horizonte h.

E2 · Peso óptimo de hoja y ganancia del split

$$\Omega\left(T\right) = \gamma_{arb}\, J_{arb} + \frac{1}{2}\, \lambda_{arb} \sum_{j=1}^{J_{arb}} w_j^2, \qquad w_j^{*} = -\frac{G_j}{E_j + \lambda_{arb}}$$

Conexión: con $G_j = \sum_{i \in R_j} g_i$ y $E_j = \sum_{i \in R_j} \eta_i$ (sumas de gradiente y curvatura en la hoja), el peso óptimo sale **cerrado**: w_j^{*} es el paso de Newton regularizado y λ_{arb} lo encoge. La **ganancia** del split se mide con esos mismos términos y γ_{arb} exige un mínimo para crear la hoja: es una poda automática. λ_{arb} y γ_{arb} son locales.

Contraste: el bosque reduce **varianza** promediando en paralelo; el boosting reduce **sesgo** sumando en serie, y puede sobreajustar: lo controlan ν, M_{arb} y la parada temprana. **LightGBM** cambia la implementación, no la matemática. **Sin extrapolación:** sus hojas son constantes.

Referencias: Friedman, Annals of Statistics 29(5), 1189–1232, 2001 (gradient boosting) · Chen & Guestrin, KDD 2016 (XGBoost) · Ke et al., NeurIPS 2017 (LightGBM) · Hastie, Tibshirani & Friedman, The Elements of Statistical Learning, 2.ª ed., 2009, cap. 10.

5A · MATEMÁTICA DEL DIAGRAMA 3

E3 — LSTM: memoria celular y compuertas

- La LSTM mantiene dos estados: memoria celular $\mathbf{c}[t]$ y estado oculto $\mathbf{h}[t]$.
- Las compuertas de olvido, entrada y salida controlan qué información conserva, incorpora y expone en cada paso.

Compuertas de olvido y entrada

$$\mathbf{f}[t] = \sigma(\mathbf{W}_f \mathbf{x}[t] + \mathbf{U}_f \mathbf{h}[t-1] + \mathbf{b}_f), \qquad \mathbf{i}[t] = \sigma(\mathbf{W}_i \mathbf{x}[t] + \mathbf{U}_i \mathbf{h}[t-1] + \mathbf{b}_i)$$

Candidato y actualización de memoria

$$\tilde{\mathbf{c}}[t] = \tanh(\mathbf{W}_c \mathbf{x}[t] + \mathbf{U}_c \mathbf{h}[t-1] + \mathbf{b}_c), \qquad \mathbf{c}[t] = \mathbf{f}[t] \odot \mathbf{c}[t-1] + \mathbf{i}[t] \odot \tilde{\mathbf{c}}[t]$$

Compuerta de salida y estado expuesto

$$\mathbf{o}[t] = \sigma(\mathbf{W}_o \mathbf{x}[t] + \mathbf{U}_o \mathbf{h}[t-1] + \mathbf{b}_o), \qquad \mathbf{h}[t] = \mathbf{o}[t] \odot \tanh(\mathbf{c}[t])$$

Cada compuerta usa la entrada actual y el estado oculto anterior; $\odot$ es el producto elemento a elemento. La ruta de memoria $\mathbf{c}[t]$ permite conservar información a través de muchos pasos.

5A · MATEMÁTICA DEL DIAGRAMA 3

E3 — GRU: actualización y reinicio del estado

- La GRU mantiene un solo estado oculto; combina memoria y representación sin una celda separada.
- La actualización mezcla el estado anterior con un candidato, mientras el reinicio regula qué pasado entra en ese candidato.

Compuertas de actualización y reinicio

$$\mathbf{u}[t] = \sigma(\mathbf{W}_u \mathbf{x}[t] + \mathbf{U}_u \mathbf{h}[t-1] + \mathbf{b}_u), \qquad \mathbf{r}[t] = \sigma(\mathbf{W}_r \mathbf{x}[t] + \mathbf{U}_r \mathbf{h}[t-1] + \mathbf{b}_r)$$

Candidato: reinicio del estado previo

$$\tilde{\mathbf{h}}[t] = \tanh\big(\mathbf{W}_h \mathbf{x}[t] + \mathbf{U}_h (\mathbf{r}[t] \odot \mathbf{h}[t-1]) + \mathbf{b}_h\big)$$

Mezcla del estado anterior y el candidato

$$\mathbf{h}[t] = (1 - \mathbf{u}[t]) \odot \mathbf{h}[t-1] + \mathbf{u}[t] \odot \tilde{\mathbf{h}}[t]$$

Con la convención de esta diapositiva, $\mathbf{u}[t]$ pondera el candidato nuevo y $1 - \mathbf{u}[t]$ conserva el estado anterior. El backbone recurrente aplica esta celda paso a paso a la secuencia.

5A · MATEMÁTICA DEL DIAGRAMA 3

E4 — Convolucionales/TCN · E5 — Transformers LTSF

E4 · Convolución causal dilatada (campo receptivo exponencial en $\breve{d}$)

$$(\mathbf{s} *_{\breve{d}} \mathbf{f})[t] = \sum_{i=0}^{\breve{k}-1} f[i]\, s[t - \breve{d}\, i]$$

Conexión: "CNN, TCN, híbridos CNN-LSTM" ↔ la convolución dilatada compuesta con una recurrencia E3; el TSB del artículo guía es un bloque TCN (residual + GELU + LN).

E5 · Atención escalada y multi-cabeza

$$\mathrm{Att}(\mathbf{Q},\mathbf{K},\mathbf{V}) = \mathrm{softmax}\!\left(\frac{\mathbf{Q}\mathbf{K}^{\top}}{\sqrt{d_k}}\right)\mathbf{V}, \qquad \mathrm{MHA}(\mathbf{X}) = \mathrm{Concat}(\mathrm{head}_1,\ldots,\mathrm{head}_{n_{cab}})\,\mathbf{W}^{O}$$

Conexión: "TFT, Informer, PatchTST, iTransformer, TimeXer" ↔ variantes de Att con distinta tokenización; PatchTST trocea cada canal en parches (channel-independence).

5A · MATEMÁTICA DEL DIAGRAMA 3

E6 — SSM/Mamba · E7 — Fundacionales · E8 — Descomposición

E6 · Espacio de estados continuo y discretización (recurrencia lineal)

$$\mathbf{h}'(t) = \mathbf{A}\,\mathbf{h}(t) + \mathbf{B}\,x(t), \qquad y(t) = \mathbf{C}\,\mathbf{h}(t)$$

Discretización → recurrencia $\mathbf{h}[t] = \bar{\mathbf{A}}\,\mathbf{h}[t-1] + \bar{\mathbf{B}}\,x[t]$; Mamba (selective scan) vuelve los parámetros dependientes de la entrada: $\mathcal{O}(\tau)$ frente al $\mathcal{O}(\tau^2)$ de la atención.

E7 · Distribución predictiva pre-entrenada (zero/few-shot)

$$p_\theta\big(y[\tau+1], \ldots, y[\tau+h] \mid \mathbf{X}\big) \quad \text{con } \theta \text{ fijado en pre-entrenamiento masivo externo}$$

Conexión: "zero/few-shot" ↔ evaluar p_θ sin re-entrenar θ (Chronos tokeniza valores; TimesFM parches; Moirai any-variate).

E8 · Descomposición (EMD: IMFs + residuo) y VMD variacional

$$y(t) = \sum_{j=1}^{J} c_j(t) + r(t)$$

Conexión: "VMD/EMD/CEEMDAN + red profunda" ↔ $\hat{c}_j = g_{\theta_j}(\mathbf{X}_j)$ por componente y $\hat{y} = \sum_j \hat{c}_j + \hat{r}$; la descomposición se implementa sobre la serie muestreada $y[t]$; preprocesamiento externo.

E8 · Problema variacional de la VMD

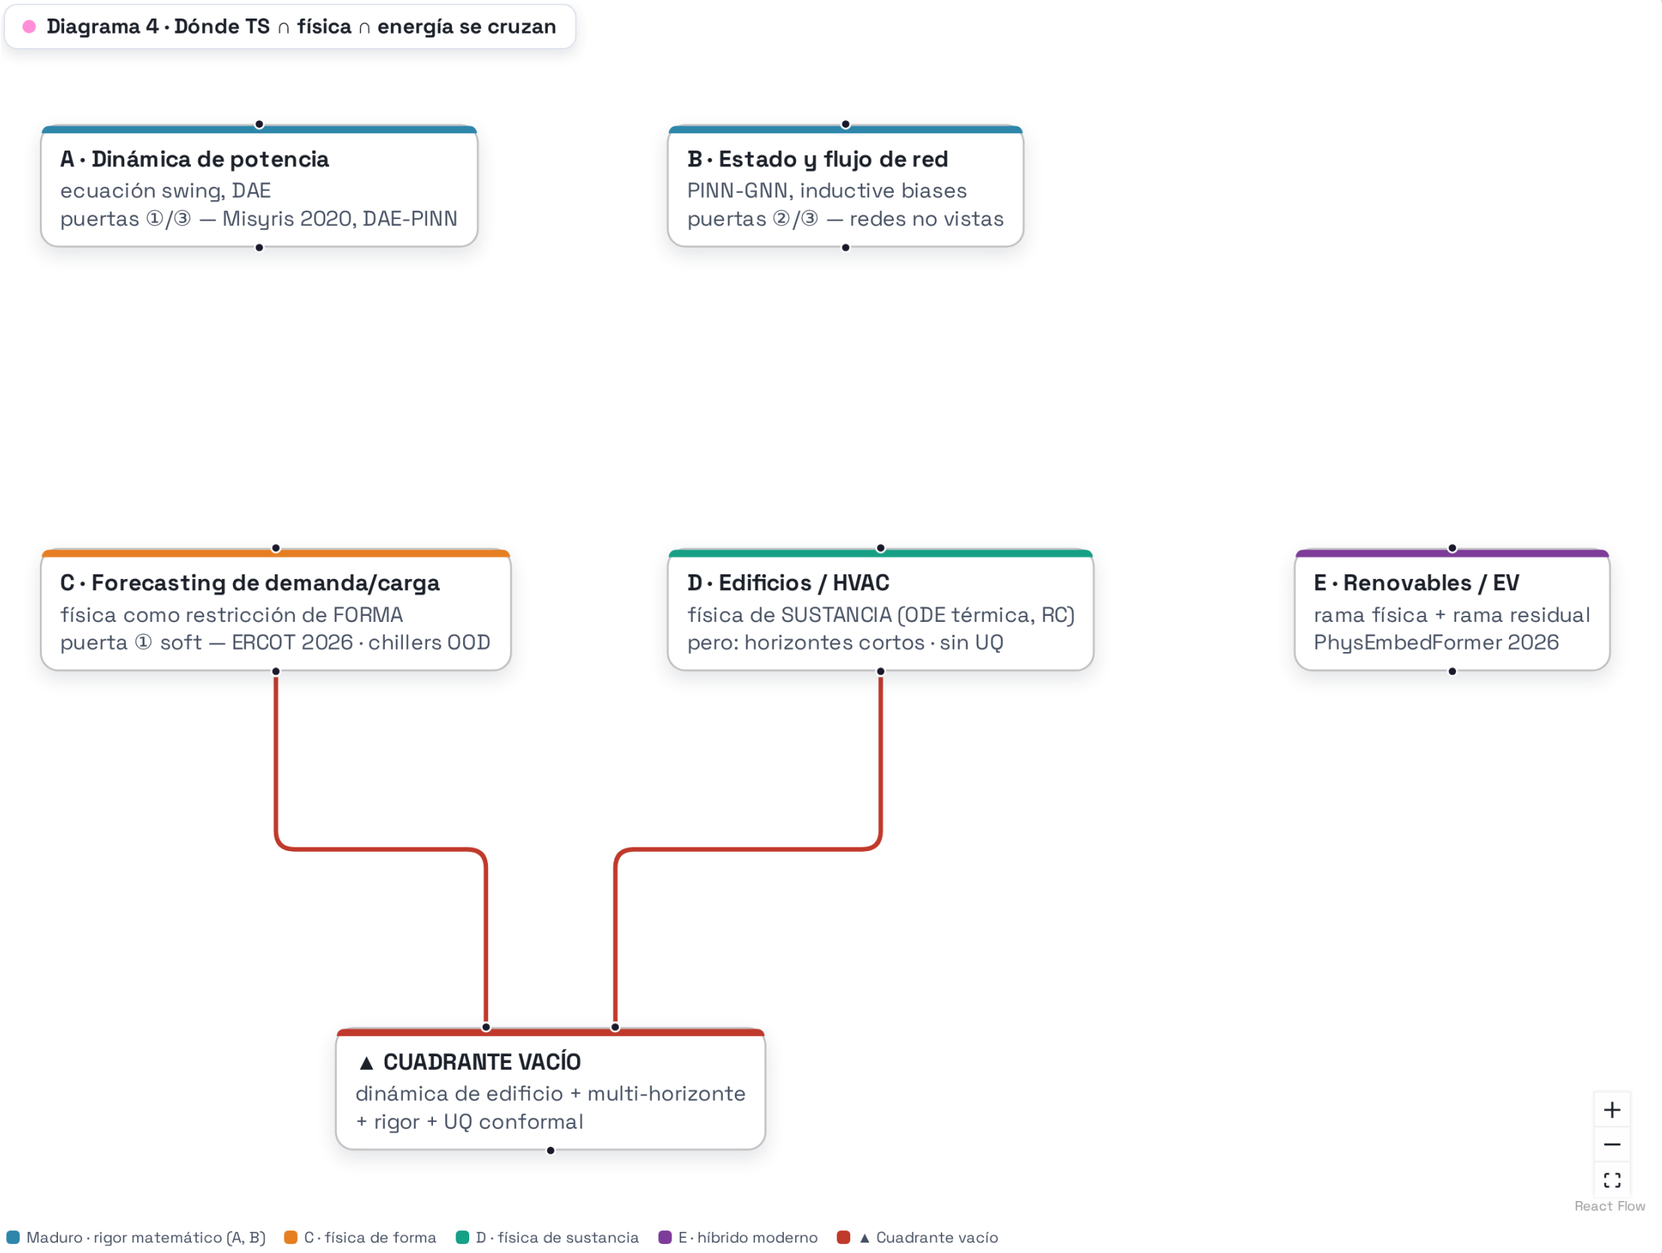
$$\min_{\{u_j\},\{\omega_j\}} \sum_{j=1}^{J} \left\| \partial_t \left[\left(\delta(t) + \frac{i}{\pi t}\right) * u_j(t) \right] e^{-i\omega_j t} \right\|_2^2 \qquad \text{s.a.} \sum_{j=1}^{J} u_j(t) = y(t)$$

5B · DIAGRAMA 4

La intersección: TS + física en sistemas energéticos

- Dónde se cruzan las familias E1–E8 con las puertas ①–④: cinco patrones (A–E).
- **A** Dinámica de potencia (swing) · **B** Flujo de red · **C** Demanda (física de forma) · **D** Edificios (RC) · **E** Renovables (física + residual).
- **El cuadrante "dinámica de edificio + multi-horizonte + rigor + UQ conformal" está VACÍO.**

Misyris et al., IEEE PES GM 2020 (A) · Huang & Wang, IEEE TPS 38(1), 2023 (review A) · Tang et al., E&B 2026, DOI: 10.1016/j.enbuild.2026.117299 (C) · Loffa et al., ACM e-Energy 2025 (D) · PhysEmbedFormer, Sci. Reports 2026 (E).



5B · MATEMÁTICA DEL DIAGRAMA 4

Patrón A — Dinámica de potencia · Patrón B — Flujo de red

A · Ecuación de oscilación del generador síncrono

$$\dot{\delta}(t) = \omega(t) - \omega_s, \qquad M\,\dot{\omega}(t) = P_m - P_e(\delta) - D\left(\omega(t) - \omega_s\right)$$

Conexión: puerta ① — la PINN (Misyris 2020) penaliza el residuo $r_\theta(t)$ (ecuación siguiente); en modo inverso estima M y D; DAE-PINN añade $0 = g(\mathbf{x}_{dif}, \mathbf{y}_{alg})$.

A · Residuo físico sobre la trayectoria estimada

$$r_\theta(t) = M\,\frac{d\hat{\omega}(t)}{dt} - \left[P_m - P_e(\hat{\delta}) - D\left(\hat{\omega} - \omega_s\right)\right]$$

B · Ecuaciones nodales de flujo de potencia

$$P_i = \sum_{j=1}^{N_{bus}} |V_i||V_j|\left(G_{ij}\cos\theta_{ij} + B_{ij}\sin\theta_{ij}\right), \qquad Q_i = \sum_{j=1}^{N_{bus}} |V_i||V_j|\left(G_{ij}\sin\theta_{ij} - B_{ij}\cos\theta_{ij}\right)$$

Conexión: "voltajes, ángulos" ↔ $(|V_i|, \theta_i)$; las PINN-GNN usan el residuo de estas ecuaciones sobre el grafo de admitancias (puertas ②+①), con biases que generalizan a redes no vistas.

5B · MATEMÁTICA DEL DIAGRAMA 4

Patrón C — Demanda: física como restricción de forma

- No hay EDO del activo: la física entra como **regularizadores cualitativos** sobre $\hat{\mathbf{y}} \in \mathbb{R}^h$ (puerta ①, o ② si se cablea).

Penalización de rampas y de parabolicidad (ERCOT 2026)

$$\mathcal{L}_{rampa} = \sum_{j=1}^{h-1} \max\big(0,\ |\hat{y}[j+1] - \hat{y}[j]| - r_{max}\big), \qquad \mathcal{L}_{par} = \sum_{j=2}^{h-1} \big(\hat{y}[j-1] - 2\hat{y}[j] + \hat{y}[j+1]\big)^2$$

Conexión: "loss parabólica/ramp" ↔ $\mathcal{L}_{par}$, $\mathcal{L}_{rampa}$; monotonía para chillers (Tang 2026): $\frac{\partial \hat{y}}{\partial x_m} \geq 0$ penalizada con $\mathcal{L}_{mono}$.

Pérdida total del patrón C

$$\mathcal{L}_{total} = \mathcal{L}_{MSE} + \lambda_{phys}\left(\mathcal{L}_{rampa} + \mathcal{L}_{par} + \mathcal{L}_{mono}\right)$$

Ninguna contiene una EDO del activo: es el "REGULARIZADOR DE FORMA" del diagrama aplicado al forecast de demanda.

Patrón D — Física de sustancia (circuito RC) · Patrón E — rama física + residual

D · Circuito térmico equivalente 2R2C (formulación PINN-RC del proyecto)

$$C_{in}\frac{dT_{in}(t)}{dt} = \frac{T_{out}(t) - T_{in}(t)}{R_{ea}} + \frac{T_m(t) - T_{in}(t)}{R_{in}} + A_w I_{sol}(t) + \dot{Q}_{int}(t) + P_{HVAC}(t)$$

Segundo nodo (masa de la envolvente): $C_m\frac{dT_m(t)}{dt} = \frac{T_{in}(t)-T_m(t)}{R_{in}} + \frac{T_{out}(t)-T_m(t)}{R_{out}}$; "Modelos RC" ↔ $(R_{ea}, R_{in}, R_{out}, C_{in}, C_m)$.

D · Residuo físico y pérdida compuesta

$$\mathcal{R}_{phys}(t) = C_{in}\frac{d\hat{T}_{in}(t)}{dt} - \left[\frac{T_{out}(t) - \hat{T}_{in}(t)}{R_{ea}} + \frac{T_m(t) - \hat{T}_{in}(t)}{R_{in}} + A_w I_{sol}(t) + \dot{Q}_{int}(t) + P_{HVAC}(t)\right]$$

La pérdida $\mathcal{L}_{phys} = \frac{1}{\tilde{N}\cdot h}\sum_{n,j}\|\mathcal{R}_{phys}(t_{n,j};\Theta)\|^2$ con $\mathcal{L}_{total}$ estándar (puerta ①); sin evaluación multi-horizonte en la literatura ("horizontes cortos").

E · Rama física + rama residual + contexto (PhysEmbedFormer)

$$\hat{y} = \underbrace{f_{fis}(\mathbf{x}_{met})}_{\text{rama física}} + \underbrace{g_\theta(\mathbf{x}, \mathbf{c}_{met})}_{\text{rama residual + contexto}}$$

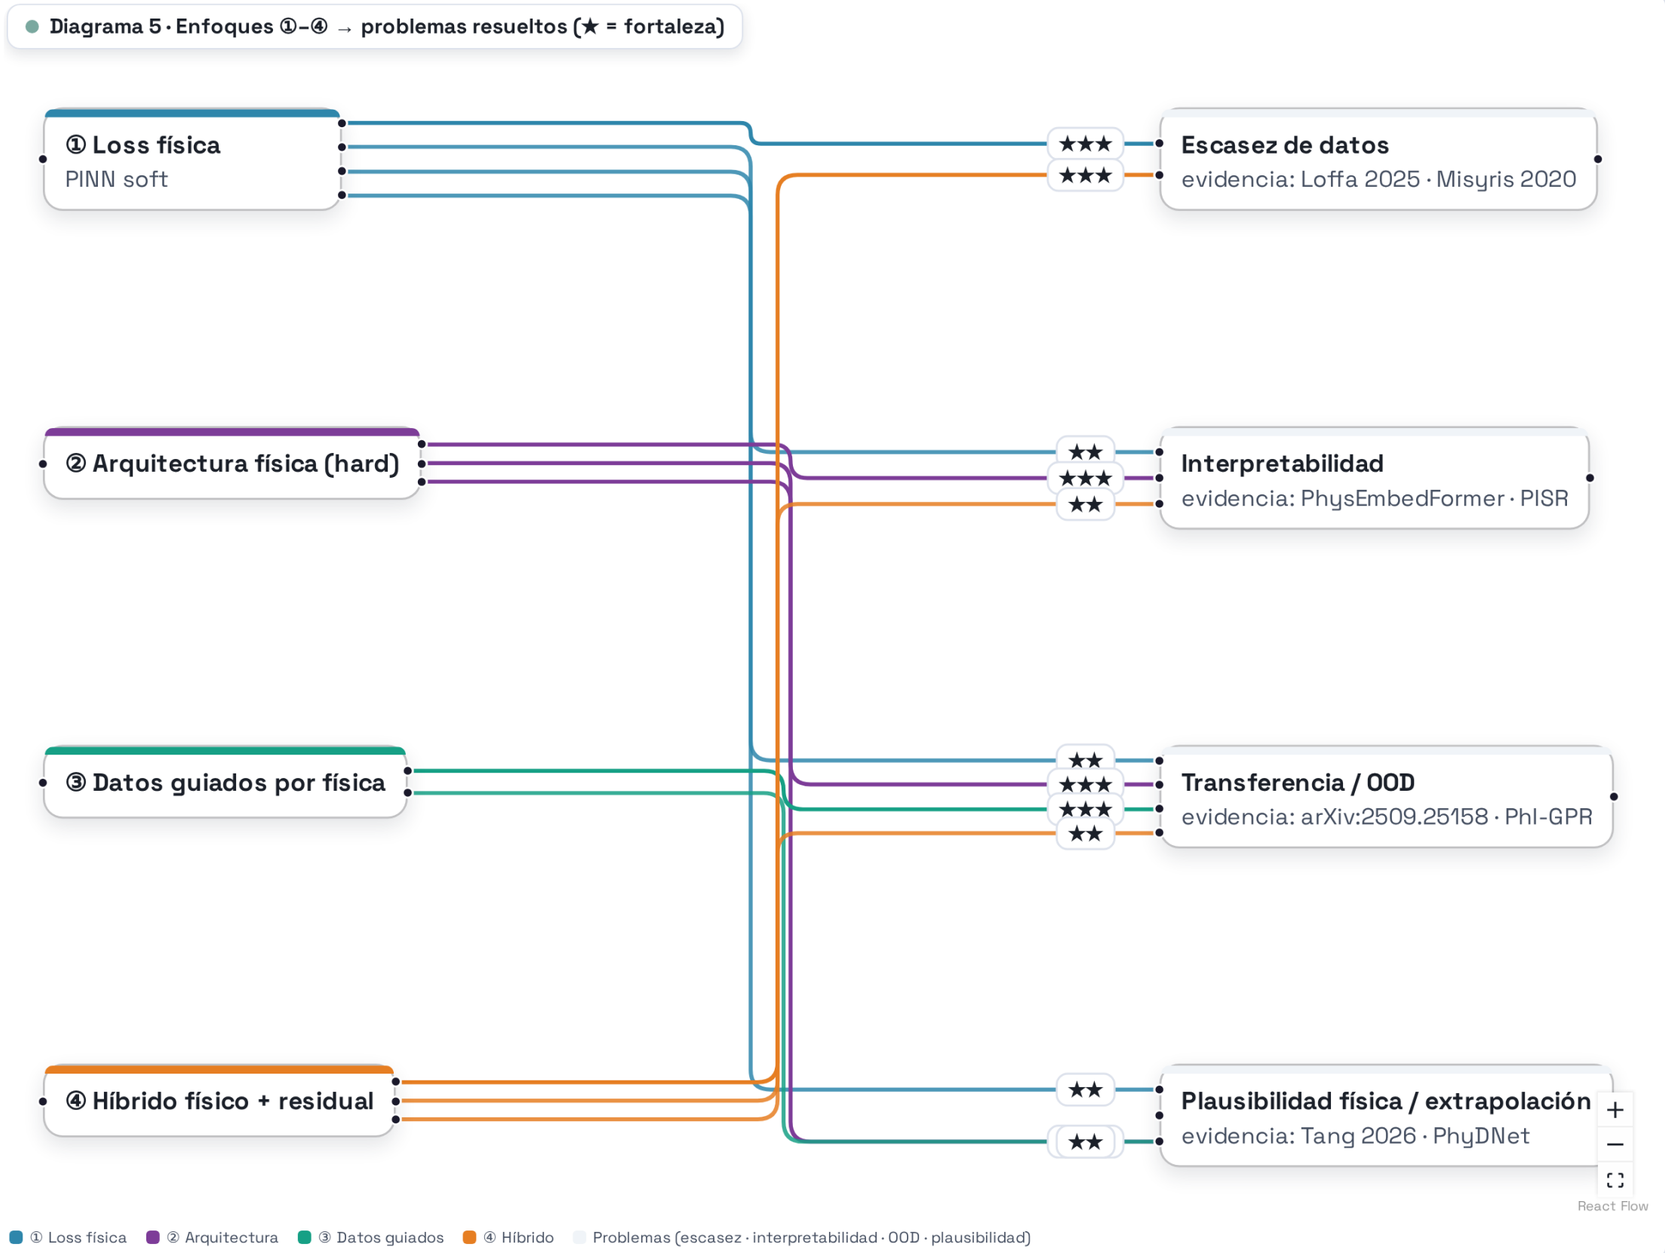
Conexión: puerta ④ con sabor de ② (rama física explícita e interpretable); la variante "PV con corrección de temperatura PINN" penaliza el residuo de $P_{pv}(t)$ (puerta ①).

6 · DIAGRAMA 5

¿Qué problema resuelve cada enfoque PIML en energía?

- Cada puerta ataca preferentemente un problema distinto: la decisión informativa del documento.
- Laterales abiertos (ninguna puerta los resuelve): **UQ**, eventos extremos, cómputo/escalabilidad.

Escasez ↔ Loffa et al. 2025 (DOI: 10.1145/3679240.3734642) y Misyris et al. 2020 · Extrapolación ↔ Tang et al. 2026 · Transferencia ↔ arXiv:2509.25158 · UQ ↔ Yang, Meng & Karniadakis, B-PINN, J. Comp. Physics 425, 2021.



6 · MATEMÁTICA DEL DIAGRAMA 5

Lectura matemática de las filas ①–④

- **① vs escasez:** $\lambda_{phys}\,\mathcal{L}_{phys}$ restringe las funciones admisibles a las que casi satisfacen $\mathcal{F}[u] = 0 \rightarrow$ aumenta la muestra efectiva; la ganancia aparece "EXACTAMENTE con pocos datos" (Loffa 2025).
- **② y ④:** con $\hat{y} = f_{fis}(\mathbf{x}_{met}) + g_\theta(\mathbf{x}, \mathbf{c}_{met})$ cada término es inspeccionable, y fuera del dominio g_θ puede fallar pero f_{fis} sigue correcta (error acotado por el componente físico).

③ vs estados no observables: posterior del GP con prior físico

$$\bar{f}(\mathbf{x}) = \mathbf{k}(\mathbf{x})^\top (\mathbf{K}_{GP} + \sigma_n^2 \mathbf{I})^{-1} \mathbf{y}$$

Conexión: puerta ③ — con prior físico $f \sim \mathcal{GP}(m_{fis}, \kappa_{fis})$ (PhI-GPR), la posterior reconstruye estados no medidos si el modelo dinámico está bien especificado.

6 · MATEMÁTICA DEL DIAGRAMA 5

Problemas laterales: UQ, eventos extremos y escalabilidad

- **Eventos extremos:** particionar el test en $\mathcal{E}$ y su complemento, reportando $\mathcal{L}_{MSE}|_{\mathcal{E}}$ por separado — ERCOT 2026: $\mathcal{L}_{par} + \mathcal{L}_{rampa}$ mejora la forma durante $\mathcal{E}$, no la magnitud del pico.
- **Cómputo:** evaluar $\mathcal{L}_{phys}$ crece con N_c y el orden de $\mathcal{N}$; no hay PINNs energéticas sobre datasets de $\sim 10^6$–10^7 muestras.

UQ bayesiana (B-PINN): posterior sobre parámetros y predictiva marginal

$$p(\Theta \mid \mathcal{D}) = \frac{p(\mathcal{D} \mid \Theta)\, p(\Theta)}{p(\mathcal{D})}, \qquad p(y^* \mid \mathbf{x}^*, \mathcal{D}) = \int p(y^* \mid \mathbf{x}^*, \Theta)\, p(\Theta \mid \mathcal{D})\, d\Theta$$

Muestreada con HMC o variacional: costo prohibitivo para forecasting operativo; alternativa barata: **cuantiles conformales**.

Cuantiles conformales: cobertura $\geq 1-\alpha$ sin supuestos distribucionales

$$\hat{q} = \text{Quantile}\left(\{s_i\}_{i=1}^{n};\ \frac{\lceil (n+1)(1-\alpha) \rceil}{n} \right), \qquad C(\hat{y}) = \left[\hat{y} - \hat{q},\ \hat{y} + \hat{q} \right]$$

Con puntajes $s_i = |y_i - \hat{y}_i|$ sobre calibración de tamaño n: $\mathbb{P}\{y \in C(\hat{y})\} \geq 1-\alpha$ — el hueco más claro del mapa energético.

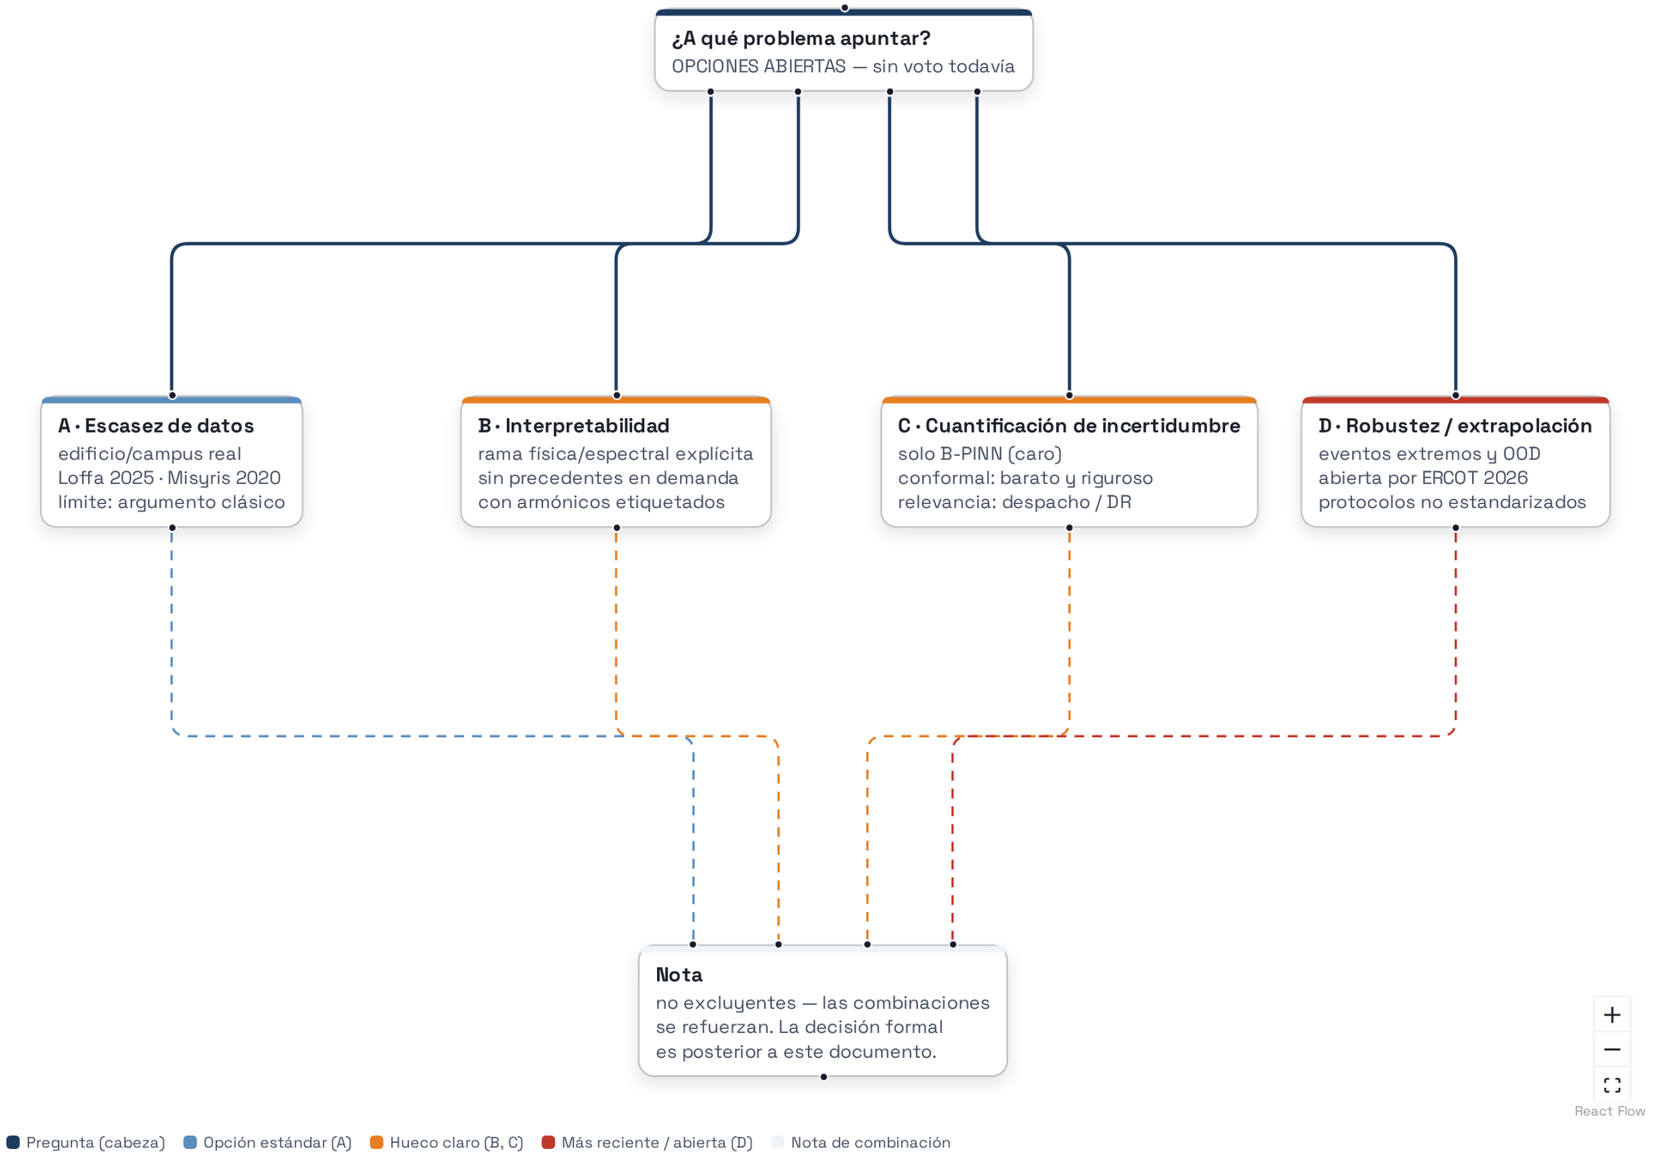
7 · DIAGRAMA 6

Árbol de opciones de problema (NO vinculado a ningún modelo)

- Opciones de problema que la tesis podría abarcar — **sin votar todavía**; la decisión es posterior.
- **A** Escasez de datos · **B** Interpretabilidad etiquetada · **C** UQ (conformal) · **D** Extremos/OOD.
- Las opciones **no son excluyentes**: las combinaciones se refuerzan.

Anclajes de evidencia por opción en §7 ("Matemática del Diagrama 6"); decisión informativa: Tabla 5 (§6) y opciones (§7); resolución posterior a este documento.

Diagrama 6 · ¿A qué problema apuntar? — opciones abiertas



7 · MATEMÁTICA DEL DIAGRAMA 6

Anclajes A y B — régimen de escasez y bandas etiquetadas

- **Opción A (escasez de datos):** con $\tilde{N}$ pequeño domina $\lambda_{phys}\,\mathcal{L}_{phys}$; existe un umbral donde el residuo RC (§5b-D) supera a $\mathcal{L}_{MSE}$ sola (Loffa 2025).

B · Descomposición por bandas espectralmente etiquetadas

$$\mathbf{z}[t] = [\boldsymbol{\phi}_1(\mathbf{x}[t]), \ldots, \boldsymbol{\phi}_K(\mathbf{x}[t])] \in \mathbb{R}^F, \qquad F = K\,N_f$$

Conexión: cada banda $\boldsymbol{\phi}_k$ queda *etiquetada* con su escala temporal ($B = (6, 24, 72)$ h o $(4, 24, 168)$ h): el análogo **aprendible** de la descomposición E8, dentro del modelo.

Anclajes C y D — conformal y evaluación por régimen

- **Opción C (UQ):** conformal — $C(\hat{y}) = [\hat{y} - \hat{q},\ \hat{y} + \hat{q}]$ con cobertura $\geq 1 - \alpha$ sobre cualquier predictor; B-PINN es prohibitivo en forecasting.
- **Opción D (robustez/extremos):** evaluación por régimen — $\mathcal{L}_{MSE}|_{\mathcal{E}}$ por separado, más $\mathcal{L}_{rampa}$ y $\mathcal{L}_{par}$ (§5b-C) durante el evento.

8 · LECTURA CONJUNTA

Los seis diagramas en una tabla

Diagrama	Pregunta que responde	Matemática asociada
1	Cómo entra la física (4 puertas)	$\mathcal{L}_{total}$, $\mathbb{J}\nabla H_\theta$, ψ_{fis}, $f_{fis} + g_\theta$ (§3)
2	Qué familias PIML existen para TS (general)	F1–F6: PINN, PG-RNN, Neural ODE/SDE, PhyDNet, kernel/GPR, PINT/RFF (§4)
3	Qué familias data-driven hay en energía (base)	E1–E8: SARIMA, SVR/XGBoost, LSTM/GRU, TCN, atención, SSM, fundacionales, VMD (§5a)
4	Dónde TS ∩ física ∩ energía (patrones A–E)	swing, flujo de potencia, pérdidas de forma, RC 2R2C + $\mathcal{R}_{phys}$, rama física+residual (§5b)
5	Qué problema resuelve cada enfoque	regularizador físico, posterior B-PINN, cuantiles conformales (§6)
6	Opciones de problema (sin conectar a modelo)	anclajes A–D: régimen de escasez, bandas etiquetadas, conformal, evaluación por régimen (§7)

10 · CIERRE

Gracias

Preguntas y discusión — el siguiente paso del documento es la formulación del modelo





Revisión PIML — Versión matemática · Series de tiempo y sistemas energéticos

Universidad Nacional de Colombia

2026