1 · PORTADA

Revisión de Modelos Informados por Física (PIML) para Series de Tiempo y Sistemas Energéticos

Versión matemática — esquema general, diagramas de decisión y modelos matemáticos por familia, previos a la formulación del modelo

Maestría en Ingeniería · Universidad Nacional de Colombia

Basado en: revision_piml_series_tiempo_energia_matematica.md

2026

Tabla de notación: grupos, símbolos y su uso

Grupo	Símbolos	Uso
Convención temporal (continuo y discreto)	continuo, paréntesis ( ): $x(t), \dot{x}(t), u(t, \mathbf{x})$; discreto, corchetes [ ] con índice entero: $y[t], \mathbf{z}[t], \mathbf{h}[t-1], \hat{y}[j]$.	Regla transversal: toda magnitud dependiente del tiempo lleva argumento explícito —paréntesis en continuo, corchetes con índice entero en discreto—; los paréntesis con argumento no temporal conservan su sentido.
Series y marco general	$\mathbf{x}_n \in \mathbb{R}^P, \mathbf{y}_n \in \mathbb{R}^\tau$; $\mathbf{X} \in \mathbb{R}^{N \times P}, \mathbf{Y} \in \mathbb{R}^{N \times \tau}$ y $\hat{\mathbf{Y}} = f_\theta(\mathbf{X})$. N: muestras; P: características; τ: horizonte futuro. La ventana histórica tiene longitud L y se denota $\mathbf{X}_n^{win} \in \mathbb{R}^{L \times P}$.	θ son parámetros, $\hat{\theta}$ su estimador; f_θ predictor. τ es horizonte, no ventana, orden ni capas. Para una muestra, $\mathbf{x}_n$ puede representar la ventana aplanada o sus características derivadas; los modelos dinámicos conservan su secuencia explícita.
Codificador RFF multibanda (artículo guía)	kernel κ, bandas K con ancho $\mathrm{softplus}(\rho_k)$, N_f features por banda, mapeo $\boldsymbol{\phi}_k$ (Ecuación 24), embedding $\mathbf{z}[t] \in \mathbb{R}^F$ con $F = KN_f$, secuencia $\mathbf{Z} = \Phi_{MB}(\mathbf{X})$; pre-set $B = (6, 24, 72)$ h.	Codificador espectral del artículo guía (familia F6): el mapeo RFF canónico es la Ecuación (24) y la densidad espectral, $p(\mathbf{w}) = \mathcal{N}(\mathbf{0}, \rho^{-2}\mathbf{I})$.
TSB y recurrencia	convolución con dilatación $\breve{d}$ y kernel $\breve{k}$, GELU $\breve{\sigma}$, LayerNorm $\mathbf{LN}$, estado $\breve{\mathbf{h}}[t]$, módulo f_{RNN}.	Backbone secuencial del artículo guía (bloque TCN: residual + GELU + LN); en GRU la compuerta de actualización es $\mathbf{u}[t]$ (**no** $\mathbf{z}[t]$, para no colisionar con el embedding espectral).
Física térmica RC (PINN-RC)	temperaturas T_{in}, T_{out}, T_m; capacidades C_{in}, C_m; resistencias R_{ea}, R_{in}, R_{out}.	Variables de estado y parámetros del circuito térmico 2R2C (patrón D, §5b) cuyo residuo penaliza la PINN-RC.
Exógenas y drivers	$I_{sol}, A_w, \dot{Q}_{int}, P_{HVAC}$; drivers de calendario y ocupación.	Forzamientos (entradas exógenas) del modelo RC y covariables de calendario/ocupación del forecasting.
Símbolos locales	$\mathcal{B}$ (E1), $\mathbf{A}, \mathbf{B}, \mathbf{C}$ (E6), instantes t_i, t_j y muestras i, convolución E4 $f[i]$, $s[t]$; E2: $\mathbf{W} \in \mathbb{R}^{P \times \tau}, \mathbf{X} \in \mathbb{R}^{N \times P}$, ventana $\mathbf{X}_n^{win} \in \mathbb{R}^{L \times P}, \varepsilon_i, \lambda_1, \lambda_2, c, (\cdot)_+, \varepsilon_{svr}, \lambda_{svr}$; SVD: $\mathbf{U}, \mathbf{S}, \mathbf{V}$.	Los símbolos de operadores y estructuras son locales a su familia. t_i son valores de t continuo: paréntesis, $x(t_i)$; i numera muestras, no tiempo: subíndice, nunca corchete. Colisiones: ε_i (ruido), $\varepsilon[t]$ (innovación) y ε_{svr} (tolerancia del tubo) son conceptos distintos; $\mathbf{U}$ es factor del SVD y $\mathbf{U}_i$ compuerta; $\mathcal{N}$ es sólo la normal —la ley física es $\mathcal{F}[u] = 0$—. $\mathbf{X}$ denota la matriz muestras-características y las secuencias usan $\mathbf{X}_n^{win}$.
Decisiones de unificación	θ parámetros del modelo; $\hat{\theta}$ estimador; Θ conjunto de parámetros; $\lambda_{phys}, \lambda_{reg}, \lambda_1, \lambda_2, \lambda_{svr}, \lambda_{rk}$ pesos de penalización; $\mathcal{L}$ pérdida; $\mathbf{u}[t]$ compuerta GRU; f_{fis} rama física.	θ es el **único** símbolo de los parámetros: los coeficientes de una regresión, los pesos de una red y las matrices de compuerta son θ o bloques con nombre de θ; Θ es el conjunto donde vive.

Riesgo esperado, aproximación empírica y optimización

- La estructura compartida organiza la comparación, pero no reemplaza los criterios propios de cada modelo probabilístico o dinámico.
- El promedio muestral estima el riesgo bajo la distribución empírica; no es idéntico en general al riesgo poblacional.

Aprendizaje regularizado (riesgo poblacional)

$$\hat{\theta} = \arg\min_{\theta \in \Theta} \left[\mathbb{E}_{(\mathbf{x},\mathbf{y})\sim p_{\text{datos}}} \{ \mathcal{L}(\mathbf{y}, f_\theta(\mathbf{x})) \} + \lambda \mathcal{R}(\theta, f_\theta) \right]$$

La esperanza se toma bajo la distribución poblacional de datos. $\mathcal{R}$ puede penalizar parámetros o comportamiento; en PIML puede ser un residuo físico, que no es una penalización paramétrica.

Aproximación empírica

$$\widehat{\mathcal{E}}_N(\theta) = \frac{1}{N} \sum_{n=1}^{N} \mathcal{L}(\mathbf{y}_n, f_\theta(\mathbf{x}_n))$$

Este promedio es una esperanza respecto de la distribución empírica que asigna masa $1/N$ a cada muestra; aproxima el riesgo poblacional bajo condiciones de muestreo, no por identidad universal.

PIML/PINN: la penalización física actúa sobre el residuo

$$\hat{\theta} = \arg\min_{\theta} \left[\mathbb{E}_{(\mathbf{x},\mathbf{y})\sim p_{\text{datos}}} \mathcal{L}(\mathbf{y}, f_\theta(\mathbf{x})) + \lambda_{phys} \mathbb{E}_{\mathbf{z}\sim p_{phys}} \|r_\theta(\mathbf{z})\|_2^2 \right]$$

La regularización convencional penaliza parámetros; la formulación informada por física penaliza el residuo de una ley en puntos $\mathbf{z}$. La estructura de optimización es semejante, pero los objetos penalizados son distintos.

Derivadas: objetos distintos

$$\nabla_\theta \mathcal{L} \quad \text{(optimización)}, \qquad \nabla_{\mathbf{x}} f_\theta \quad \text{(sensibilidad a entradas)}, \qquad \frac{\partial f_\theta}{\partial t}, \frac{\partial^2 f_\theta}{\partial t^2} \quad \text{(dinámica temporal)}$$

El operador nabla denota gradientes respecto de variables vectoriales; las derivadas temporales de una trayectoria se escriben explícitamente y no se sustituyen por ∇.

3 · DIAGRAMA 1

Las cuatro puertas por las que entra la física

- Un solo punto de partida: el modelo ML $\hat{y} = f_\theta(\mathbf{x})$ y el conocimiento físico $\mathcal{F}[u] = 0$.
- De ese binomio **modelo + ley física** salen cuatro canales de entrada, ordenados por fuerza de garantía: **① penalización débil → ② arquitectura → ③ datos/features → ④ híbrido**.

Karniadakis et al., Nature Reviews Physics 3(6), 2021 (DOI: 10.1038/s42254-021-00314-5) · Hao et al., arXiv:2211.08064 · Willard et al., ACM Computing Surveys 2022 · Doumèche, tesis doctoral Sorbonne 2025.

Diagrama 1 · ¿Cómo entra la física en un modelo ML/DL?



El sistema ejemplar: masa-resorte-amortiguador (MR)

- Un solo sistema físico para comparar las tres puertas: la ley $\mathcal{F}[u] = 0$ instanciada en el MR.

Operador temporal y ecuación de movimiento

$$\nabla_t := \frac{d}{dt}, \quad \nabla_t^2 := \frac{d^2}{dt^2}, \qquad \mathcal{F} = m\,\nabla_t^2 + c\,\nabla_t + k\,\mathcal{I}$$

$$\mathcal{F}[q](t) = m\,\nabla_t^2 q(t) + c\,\nabla_t q(t) + k\,q(t) = 0$$

∇_t es una convención para la derivada temporal **unidimensional** y $\mathcal{I}$ el operador identidad; $\mathcal{F}$ es el operador diferencial del MR. La trayectoria $q(t)$ es la variable física que cada puerta predice: no es la matriz de características $\mathbf{X}$ de los modelos de aprendizaje.

Estado canónico y energía (Hamiltoniano)

$$q(t), \quad p(t) = m\,\nabla_t q(t), \qquad H(q(t), p(t)) = \frac{p(t)^2}{2m} + \frac{k\,q(t)^2}{2} \quad (c = 0)$$

Conexión: el caso conservativo ($c = 0$) es hamiltoniano puro; es la forma que exige la puerta ② en su variante HNN. $q(t)$ y $p(t)$ son posición y momento en cada instante, no entradas del modelo. La variante lagrangiana se define en la diapositiva propia de la puerta ②.

Datos disponibles

$$\mathbf{x}_n = (t_n, q(t_n), \nabla_t q(t_n)), \qquad \mathbf{y}_n = q(t_n) \quad (\tau = 1), \qquad n = 1, \ldots, N$$

Las tres puertas consumen la misma trayectoria medida del MR. La puerta ① (PINN) usará **sólo** t como entrada de la red; los rezagos y las derivadas son material de las otras puertas.

Las tres páginas siguientes instancian $\mathcal{F}[u] = 0$ sobre este sistema: misma física, distinto punto de entrada.

Puerta ① — Función de pérdida (PINN)

La física entra como **penalización del residuo**: se busca que la red la respete, sin garantizar su cumplimiento exacto.

Entrada, salida y modelo

$$t \in \mathbb{R}, \qquad y(t) = q(t) \in \mathbb{R}, \qquad \hat{y}(t) = f_\theta(t), \quad \theta \in \Theta$$

La red aproxima el desplazamiento del MR a partir **únicamente del tiempo**: la entrada es t, no una matriz de características.

Residuo físico (diferenciación automática)

$$r_\theta(t) = \mathcal{F}[f_\theta](t) = m\,\nabla_t^2 f_\theta(t) + c\,\nabla_t f_\theta(t) + k\,f_\theta(t)$$

La caja punteada "Diff. automática" produce r_θ en los puntos de colocación: $\mathcal{F}$ y ∇_t son los definidos en la página del sistema.

Función de costo: riesgo esperado y aproximación empírica

$$J(\theta) = \mathbb{E}_{(t,y)\sim p_{\text{datos}}}\left[\left(y - f_\theta(t)\right)^2\right] + \lambda_{phys}\,\mathbb{E}_{t\sim p_c}\left[r_\theta(t)^2\right]$$

$$\widehat{J}(\theta) = \frac{1}{N_d}\sum_{i=1}^{N_d}\left(q_i - f_\theta(t_i)\right)^2 + \frac{\lambda_{phys}}{N_c}\sum_{j=1}^{N_c} r_\theta(\tilde{t}_j)^2$$

El primer término es el **error de datos** sobre las N_d observaciones; el segundo es la **penalización física** en los N_c puntos de colocación, con peso λ_{phys}. El residuo se penaliza, pero su cumplimiento exacto **no está garantizado**, y las condiciones iniciales deben imponerse cuando correspondan.

Problema de optimización

$$\theta^* \in \arg\min_{\theta\in\Theta} J(\theta)$$

$$\hat{\theta} \in \arg\min_{\theta\in\Theta} \widehat{J}(\theta)$$

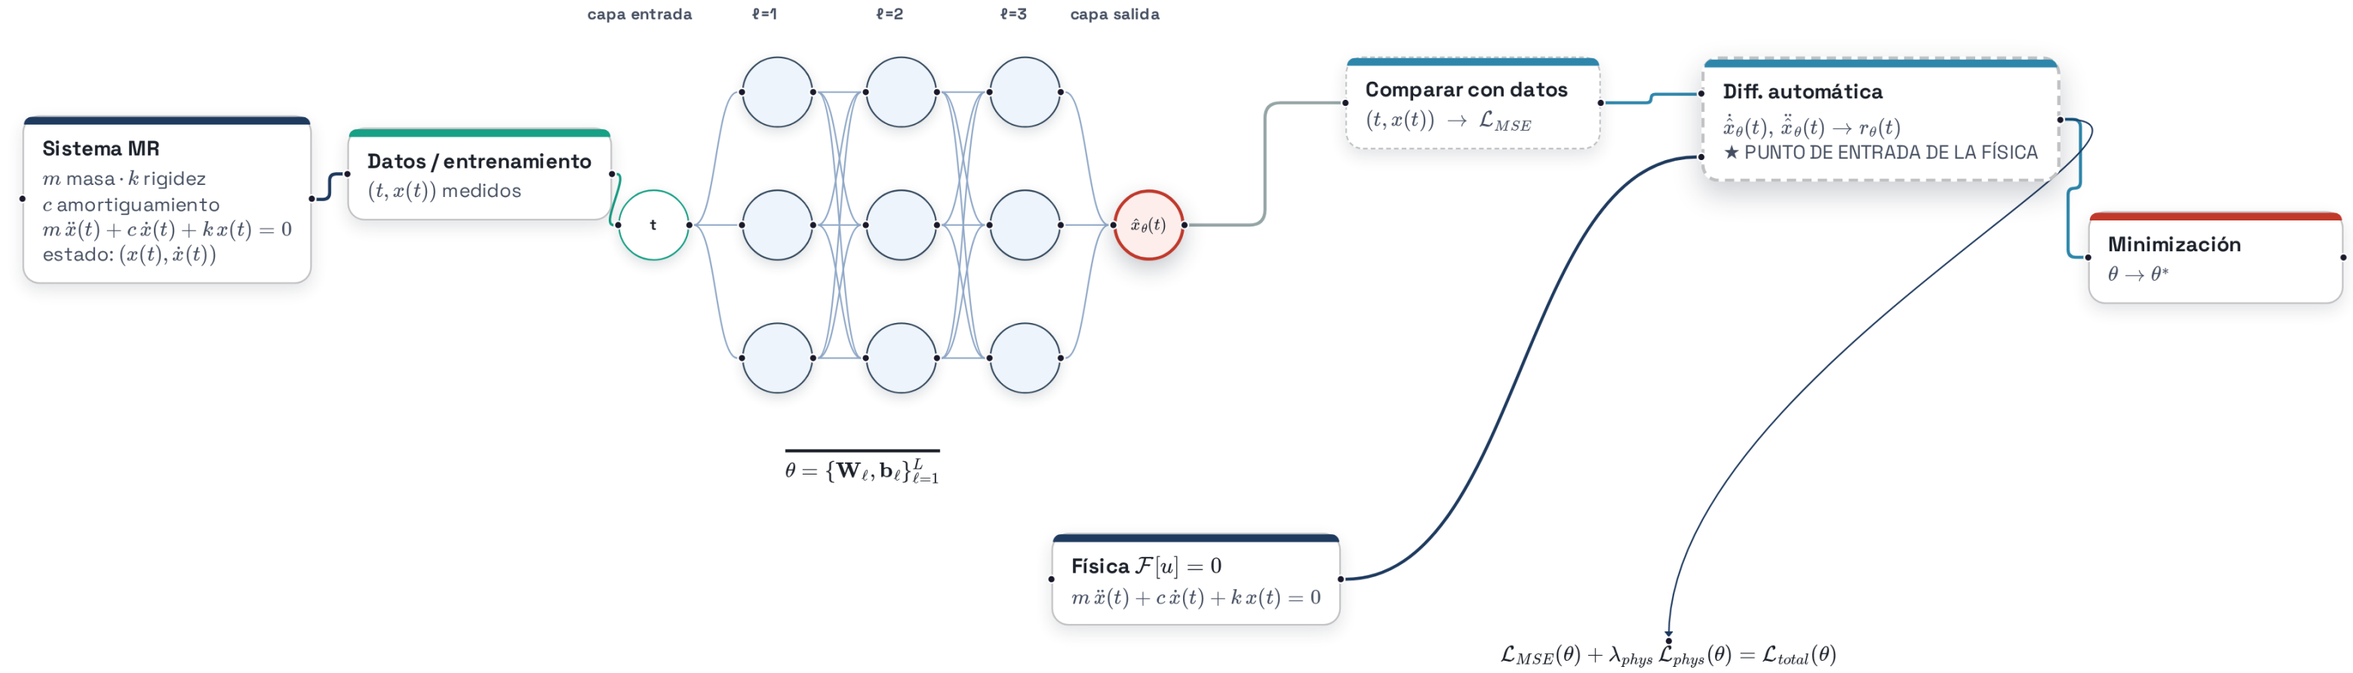
La forma poblacional define el objetivo; el entrenamiento resuelve la empírica. La física entra en la **pérdida**, no en la estructura de la red.

Raissi, Perdikaris, Karniadakis. Physics-informed neural networks. J. Comput. Phys. 378, 686–707, 2019.

Karniadakis et al. Physics-informed machine learning. Nat. Rev. Phys. 3(6), 422–440, 2021. DOI: 10.1038/s42254-021-00314-5.

Doumèche. Physics-informed ML: time series forecasting. Tesis Sorbonne, arXiv:2507.08906, 2025.

MR · Puerta ① — la física entra en la función de pérdida



Sistema MR / física · ① Pérdida (débil) · Modelo ML f_θ · Minimización → θ^*

Puerta ② — Del Hamiltoniano a la dinámica del masa-resorte

De dónde salen las ecuaciones que la puerta ② impone como estructura: cuatro pasos desde la energía hasta la EDO del MR ($c = 0$).

Paso 1 · Construcción del Hamiltoniano

$$\mathbf{z}(t) = \begin{bmatrix} q(t) \\ p(t) \end{bmatrix}, \quad p(t) = m\,\nabla_t q(t), \qquad T = \frac{p(t)^2}{2m}, \quad V = \frac{k\,q(t)^2}{2} \;\Rightarrow\; H = T + V$$

El Hamiltoniano es la **energía total** del sistema conservativo: cinética más potencial del resorte. $\mathbf{z}(t) = (q(t), p(t))^\top$ es el estado canónico; ∇_t ya quedó definida en la página del sistema.

Paso 2 · Ecuaciones de Hamilton

$$\nabla_t q(t) = \partial_p H = \frac{p(t)}{m}, \qquad \nabla_t p(t) = -\partial_q H = -k\,q(t) \qquad \Longleftrightarrow \qquad \nabla_t \mathbf{z}(t) = \mathbb{J}_s\,\nabla_{\mathbf{z}} H(\mathbf{z}(t))$$

Con la matriz simpléctica $\mathbb{J}_s = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}$, la dinámica es $\nabla_t \mathbf{z} = \mathbb{J}_s \nabla_{\mathbf{z}} H$: el gradiente del Hamiltoniano respecto al estado da la regla de evolución.

Paso 3 · Recuperación de la ecuación física

$$p(t) = m\,\nabla_t q(t) \;\Rightarrow\; \nabla_t p(t) = m\,\nabla_t^2 q(t) \;\Rightarrow\; m\,\nabla_t^2 q(t) + k\,q(t) = 0$$

Sustituyendo la primera ecuación de Hamilton en la segunda se recupera **exactamente** la EDO del masa-resorte conservativo: la dinámica sale de H por derivación, no se aprende.

Paso 4 · Conservación de energía

$$\frac{dH}{dt} = (\nabla_{\mathbf{z}} H)^\top \mathbb{J}_s\,\nabla_{\mathbf{z}} H = 0 \;\Rightarrow\; H(t) = \text{constante}$$

La conservación aparece **por construcción**, porque $\mathbb{J}_s$ es antisimétrica. Vale para el caso conservativo $c = 0$, sin amortiguamiento ni fuerza externa.

Esta página es una derivación física: no tiene función de costo ni optimización. La página siguiente toma estas mismas ecuaciones y las impone como **estructura** de una red.

Greydanus, Dzamba, Yosinski. Hamiltonian Neural Networks. NeurIPS 2019.
Cranmer et al. Lagrangian Neural Networks. arXiv:2003.04630, 2020.
Chen et al. Neural Ordinary Differential Equations. NeurIPS 2018.

Puerta ② — Arquitectura (Hamiltonian NN)

La física entra en la **estructura del modelo**: se cumple **por construcción** para todo θ.

$(q(t), p(t))$ → f_θ — red neuronal → $\hat{H}_\theta(q(t), p(t))$ → $\nabla_{\mathbf{z}} \hat{H}_\theta$ (autodiff) → $\mathbb{J}_s \nabla_{\mathbf{z}} \hat{H}_\theta$ → dinámica

Entrada, salida y modelo

$$\mathbf{z}(t) = (q(t), p(t))^\top, \qquad \hat{H}_\theta(\mathbf{z}(t)) = f_\theta(\mathbf{z}(t)), \qquad \theta \in \Theta$$

La red aprende una **función escalar** del estado canónico: no predice la trayectoria y **no requiere etiquetas de energía**. La entrada es $\mathbf{z} = (q, p)^\top$ y la salida es un escalar.

Estructura Hamiltoniana (la física por construcción)

$$\hat{\mathbf{v}}_\theta(\mathbf{z}) = \mathbb{J}_s \, \nabla_{\mathbf{z}} \hat{H}_\theta(\mathbf{z}), \qquad \nabla_t q = \partial_p \hat{H}_\theta, \quad \nabla_t p = -\partial_q \hat{H}_\theta$$

Son las ecuaciones de Hamilton de la página anterior aplicadas al Hamiltoniano **aprendido**: la física no entra como penalización, entra en la estructura y se cumple para todo θ.

Función de costo: riesgo esperado

$$J_{\mathrm{HNN}}(\theta) = \mathbb{E}_{(\mathbf{z},\mathbf{v})\sim p_{\mathrm{datos}}}\left[\|\mathbf{v} - \hat{\mathbf{v}}_\theta(\mathbf{z})\|_2^2\right], \qquad \mathbf{v} = (\nabla_t q, \nabla_t p)^\top$$

El criterio compara las **derivadas temporales observadas** $\mathbf{v}$ con las que predice el gradiente del Hamiltoniano aprendido.

Aproximación empírica

$$\widehat{J}_{\mathrm{HNN},N}(\theta) = \frac{1}{N} \sum_{n=1}^{N} \left[\left(\nabla_t q(t_n) - \partial_p \hat{H}_\theta(\mathbf{z}_n) \right)^2 + \left(\nabla_t p(t_n) + \partial_q \hat{H}_\theta(\mathbf{z}_n) \right)^2 \right]$$

Promedio sobre las N observaciones; si las velocidades no se miden, se estiman por diferencias finitas.

Problema de optimización

$$\theta^* \in \arg\min_\theta J_{\mathrm{HNN}}(\theta), \qquad \hat{\theta} \in \arg\min_\theta \widehat{J}_{\mathrm{HNN},N}(\theta)$$

La forma poblacional define el objetivo; el entrenamiento resuelve la empírica. La estructura se cumple por construcción, pero reproducir la dinámica real depende del **entrenamiento y los datos**.

Mensaje clave: la HNN no aprende la trayectoria: aprende $\hat{H}_\theta$ y sus derivadas determinan la dinámica; un integrador recupera $(q(t), p(t))$.

Greydanus, Dzamba, Yosinski. Hamiltonian Neural Networks. NeurIPS 2019.
Cranmer et al. Lagrangian Neural Networks. arXiv:2003.04630, 2020.
Chen et al. Neural Ordinary Differential Equations. NeurIPS 2018.

Puerta ② — Del Lagrangiano a la dinámica del masa-resorte

De dónde sale la regla de evolución que la LNN impone como estructura: cuatro pasos desde $L = T - V$ hasta la EDO del MR ($c = 0$).

Paso 1 · Construcción del Lagrangiano

$$T = \frac{m\,(\nabla_t q(t))^2}{2}, \qquad V = \frac{k\,q(t)^2}{2}, \qquad L = T - V = \frac{m\,(\nabla_t q(t))^2}{2} - \frac{k\,q(t)^2}{2}$$

El Lagrangiano es energía cinética **menos** potencial, con las mismas m, k y la misma trayectoria del sistema. $\nabla_t q(t)$ es la velocidad (el $\dot{q}$ clásico); ∇_t ya quedó definida en la página del sistema.

Paso 2 · Ecuación de Euler–Lagrange

$$\nabla_t(\partial_{\nabla_t q} L) - \partial_q L = 0, \qquad \partial_{\nabla_t q} L = m\,\nabla_t q(t), \quad \partial_q L = -k\,q(t)$$

La regla de evolución es el principio de acción: las derivadas parciales de L respecto a la posición y a la velocidad determinan la dinámica.

Paso 3 · Recuperación de la ecuación física

$$\nabla_t(m\,\nabla_t q(t)) + k\,q(t) = 0 \;\Rightarrow\; m\,\nabla_t^2 q(t) + k\,q(t) = 0$$

Es exactamente la EDO del masa-resorte **conservativo** ($c = 0$, sin amortiguamiento ni fuerza externa): la dinámica sale de L por derivación, no se aprende.

Paso 4 · Equivalencia hamiltoniana (transformada de Legendre)

$$p(t) = \partial_{\nabla_t q} L = m\,\nabla_t q(t) \;\Rightarrow\; H = p(t)\,\nabla_t q(t) - L = \frac{p(t)^2}{2m} + \frac{k\,q(t)^2}{2}$$

La transformada de Legendre pasa de L a H y recupera el Hamiltoniano de la página anterior: para el caso conservativo ambas formulaciones son equivalentes.

Esta página es un desarrollo físico: no tiene función de costo ni optimización. La página siguiente toma esta misma regla y la impone como **estructura** de una red.

Cranmer, Greydanus, Hoyer, Battaglia, Spergel, Ho. Lagrangian Neural Networks. ICLR, 2020.
Greydanus, Dzamba, Yosinski. Hamiltonian Neural Networks. NeurIPS 2019.
Chen et al. Neural Ordinary Differential Equations. NeurIPS 2018.

Puerta ② — Arquitectura (Lagrangian NN)

La física entra en la **estructura del modelo**: se cumple **por construcción** para todo θ, ahora a través del principio de acción.

$(q(t), \nabla_t q(t))$ → f_θ — red neuronal → $\hat{L}_\theta(q(t), \nabla_t q(t))$ → $\partial \hat{L}_\theta$ (autodiff) → Euler–Lagrange → aceleración

Entrada, salida y modelo

$$\mathbf{z}(t) = (q(t), \nabla_t q(t))^\top, \qquad \hat{L}_\theta(\mathbf{z}(t)) = f_\theta(\mathbf{z}(t)), \qquad \theta \in \Theta$$

La red aprende un **Lagrangiano escalar**: no predice la trayectoria y **no requiere etiquetas** del Lagrangiano físico.

Modelo dinámico: Euler–Lagrange y aceleración predicha

$$\hat{a}_\theta(\mathbf{z}) = \left(\partial^2_{(\nabla_t q)(\nabla_t q)} \hat{L}_\theta\right)^{-1} \left[\partial_q \hat{L}_\theta - \partial^2_{q(\nabla_t q)} \hat{L}_\theta \, \nabla_t q\right]$$

Sale de imponer $\nabla_t(\partial_{\nabla_t q} \hat{L}_\theta) - \partial_q \hat{L}_\theta = 0$ y despejar la aceleración; se requiere una derivada segunda respecto a la velocidad **no nula**, $\partial^2_{(\nabla_t q)(\nabla_t q)} \hat{L}_\theta \neq 0$.

Función de costo: riesgo esperado

$$J_{\mathrm{LNN}}(\theta) = \mathbb{E}_{\mathbf{z} \sim p_{\text{datos}}}\left[\left(a - \hat{a}_\theta(\mathbf{z})\right)^2\right], \qquad a = \nabla_t^2 q$$

El objetivo es la **aceleración**: se compara la observada a con la que induce el Lagrangiano aprendido.

Aproximación empírica

$$\widehat{J}_{\mathrm{LNN},N}(\theta) = \frac{1}{N} \sum_{n=1}^{N} \left(a_n - \hat{a}_\theta(\mathbf{z}_n)\right)^2$$

Promedio sobre las N observaciones; si sólo hay posición medida, la aceleración se estima por diferencias finitas.

Problema de optimización

$$\theta^* \in \arg\min_\theta J_{\mathrm{LNN}}(\theta), \qquad \hat{\theta} \in \arg\min_\theta \widehat{J}_{\mathrm{LNN},N}(\theta)$$

La estructura Euler–Lagrange se impone **por construcción**; reproducir la dinámica real depende del entrenamiento. No se añade una penalización física separada.

Mensaje clave: la LNN tampoco aprende la trayectoria: aprende $\hat{L}_\theta$ y Euler–Lagrange convierte sus derivadas en la aceleración; un integrador recupera $(q(t), \nabla_t q(t))$.

Cranmer, Greydanus, Hoyer, Battaglia, Spergel, Ho. Lagrangian Neural Networks. ICLR, 2020.
Greydanus, Dzamba, Yosinski. Hamiltonian Neural Networks. NeurIPS 2019.
Chen et al. Neural Ordinary Differential Equations. NeurIPS 2018.

Hamiltoniano vs Lagrangiano: cuándo usar una u otra

Criterio	Hamiltoniano $H(q,p)$	Lagrangiano $L(q,\dot{q})$
Variables de estado	Coordenadas canónicas $(q(t), p(t))$: el momento $p = m\,\dot{q}(t)$ hay que construirlo.	Coordenadas generalizadas $(q(t), \dot{q}(t))$ directas de los datos; el momento se deriva después: $p = \partial L / \partial \dot{q}$.
Función escalar	$H = T + V$ — energía total (cinética + potencial).	$L = T - V$ — densidad de acción (cinética - potencial).
Regla de evolución	Dos ecuaciones de primer orden: $\dot{q}(t) = \partial H/\partial p$, $\dot{p}(t) = -\partial H/\partial q$ (forma matricial $\mathbb{J}\,\nabla H$).	Una ecuación de Euler-Lagrange de segundo orden: $\frac{d}{dt}\frac{\partial L}{\partial \dot{q}} - \frac{\partial L}{\partial q} = 0$.
Marco y conservación	Espacio de fases simpléctico; $H(t) =$ constante por construcción (integradores simplécticos).	Principio de acción (extremizar la acción); la conservación se hereda de la simetría temporal.
Red equivalente (puerta ②)	HNN: $f_\theta(q(t), p(t)) \mapsto H_\theta$; pérdida sobre $(\dot{q}, \dot{p})$ en t_n.	LNN: $f_\theta(q(t), \dot{q}(t)) \mapsto L_\theta$; pérdida sobre las aceleraciones $\ddot{q}(t_n)$.
Paso de una a otra (Legendre)	$H(q,p) = p\,\dot{q} - L(q,\dot{q})$ con $p = \partial L/\partial \dot{q}$ (inversa: $\dot{q} = \partial H/\partial p$).	Para el MR ($c = 0$): $p = m\,\dot{q}(t) \Rightarrow L = T - V \Leftrightarrow H = T + V$ — misma trayectoria.
Cuándo recomendarla	Sistema conservativo con (q,p) a mano o construibles; predicción a largo plazo donde importa la energía exacta (órbitas, osciladores, estructura simpléctica).	Datos en $(q,\dot{q})$ o coordenadas generalizadas con restricciones/vínculos; cuando los momentos deben derivarse y no se miden.

- **Regla práctica:** si necesitas momento y espacio de fases explícitos → **hamiltoniano**; si trabajas con posiciones y velocidades (o coordenadas con vínculos) → **lagrangiano**.
- **Advertencia:** las dos formas estándar asumen $c = 0$ (sin disipación); con amortiguamiento hay que añadir fuerzas generalizadas o disipación de Rayleigh — fuera del alcance de la puerta ② en este deck.

Paso de una a otra: transformada de Legendre

$$p = \frac{\partial L}{\partial \dot{q}} \iff \dot{q} = \frac{\partial H}{\partial p}, \qquad H(q,p) = p\,\dot{q} - L(q,\dot{q})$$

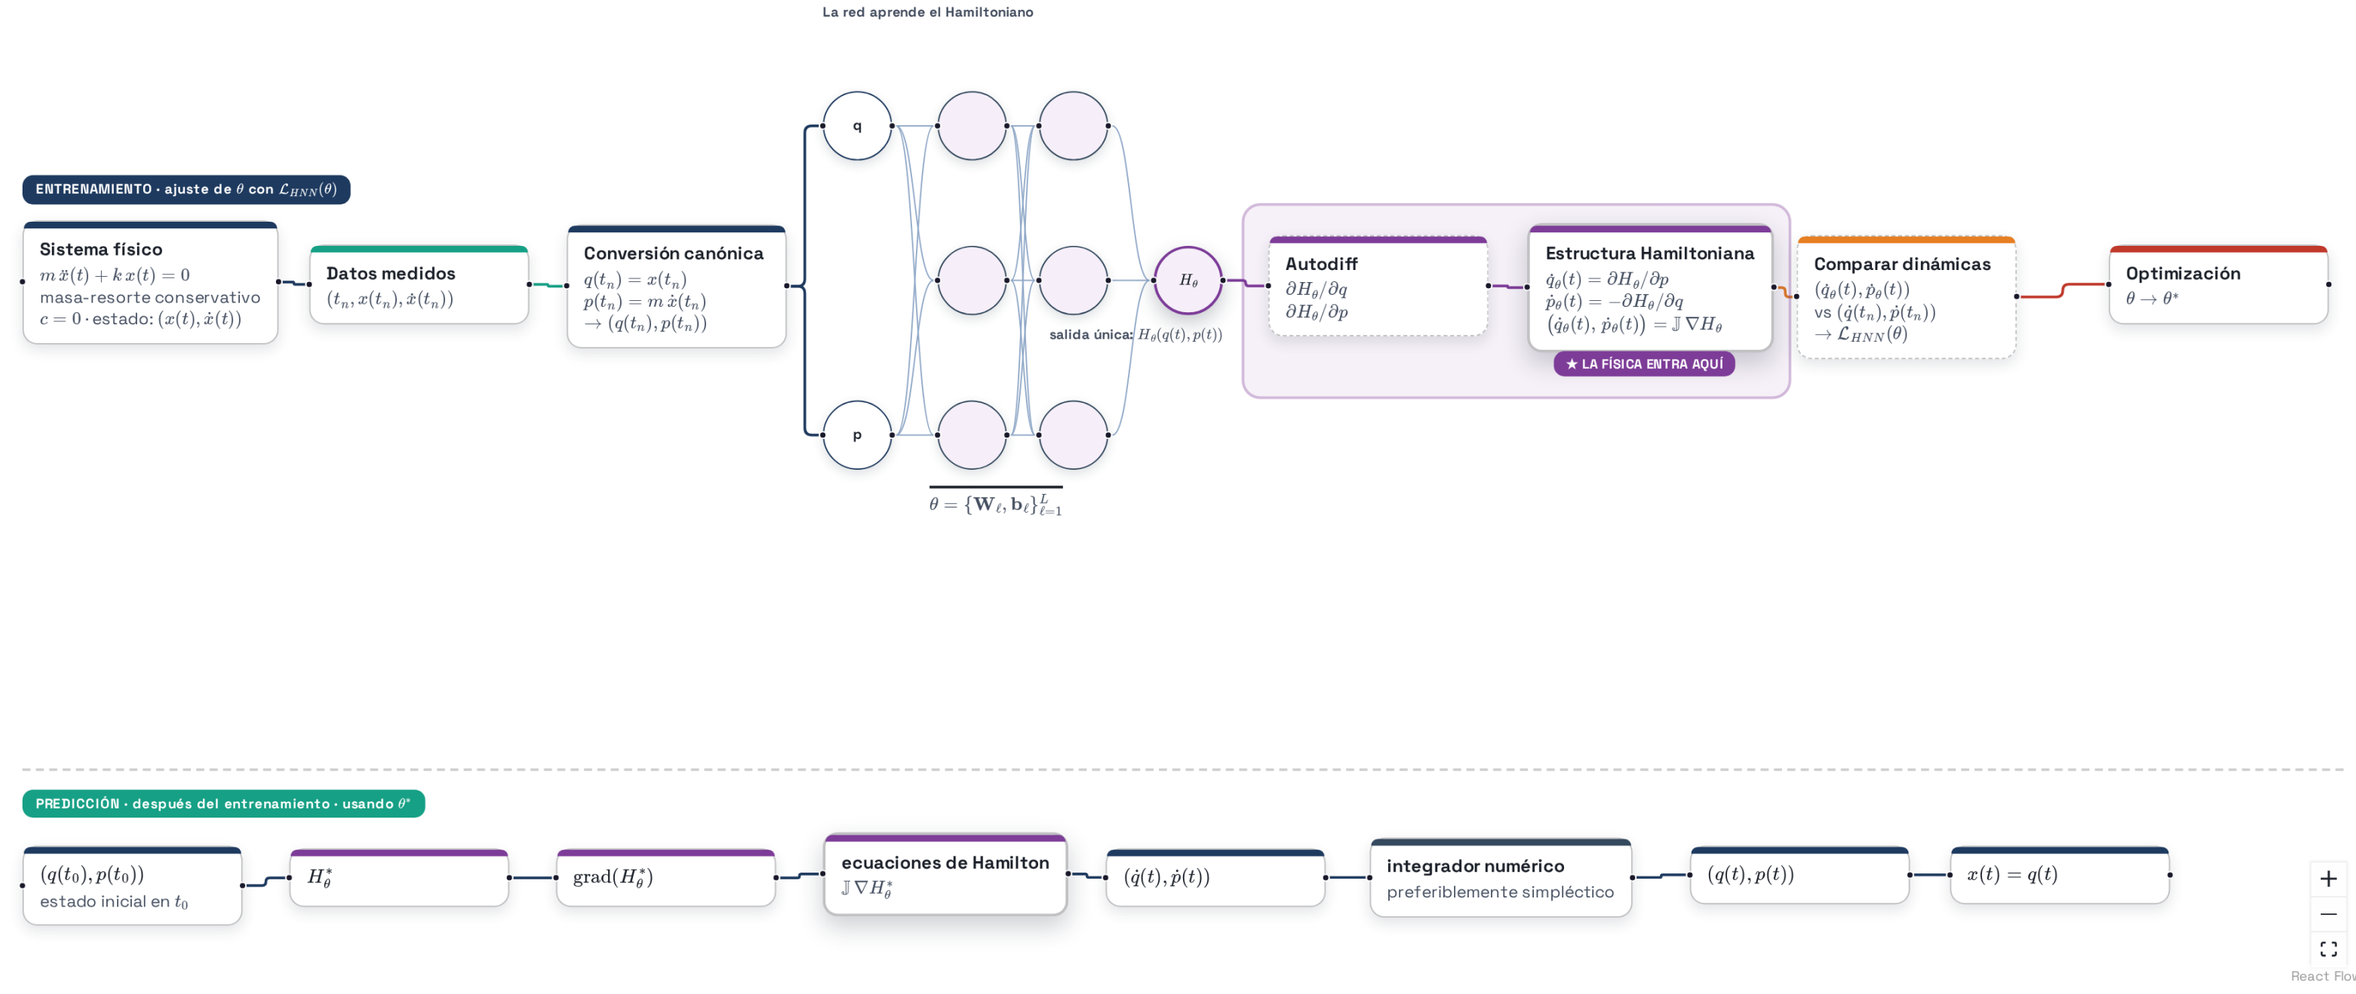
Conexión: puente exacto entre las dos columnas — para el MR ($c = 0$), $p = m\,\dot{q}(t)$ lleva de $L = T - V$ a $H = T + V$ y ambas producen la misma trayectoria $x(t)$.

Greydanus, Dzamba, Yosinski. Hamiltonian Neural Networks. NeurIPS 2019.

Cranmer et al. Lagrangian Neural Networks. arXiv:2003.04630, 2020.

Goldstein, Poole, Safko. Classical Mechanics — coordenadas canónicas y transformada de Legendre.

MR · Puerta ② — flujo de una HNN · la física entra en la estructura



Puerta ③ — Física en los datos / features

La física entra **en los datos/features**: indirectamente, antes del modelo.

Modelo (entrada aumentada)

$$\tilde{\mathbf{x}} = [\mathbf{x},\ \psi_{fis}(\mathbf{x})], \qquad \psi_{fis} = [\,x(t),\ \dot{x}(t),\ E(t)\,], \qquad E(t) = \tfrac{1}{2} m \dot{x}(t)^2 + \tfrac{1}{2} k\, x(t)^2$$

Conexión: para el MR las features son el espacio de fases y la energía; el bloque "Features ψ_fis" transforma la entrada antes de f_θ.

Función de pérdida (sobre datos aumentados)

$$\mathcal{L}_{MSE}(\theta) = \frac{1}{N_d} \sum_{i=1}^{N_d} |f_\theta(\tilde{\mathbf{x}}_i) - y(t_i)|^2$$

Conexión: la física no aparece como término de penalización: vive en la entrada aumentada $\tilde{\mathbf{x}}$ y en las features ψ_{fis}.

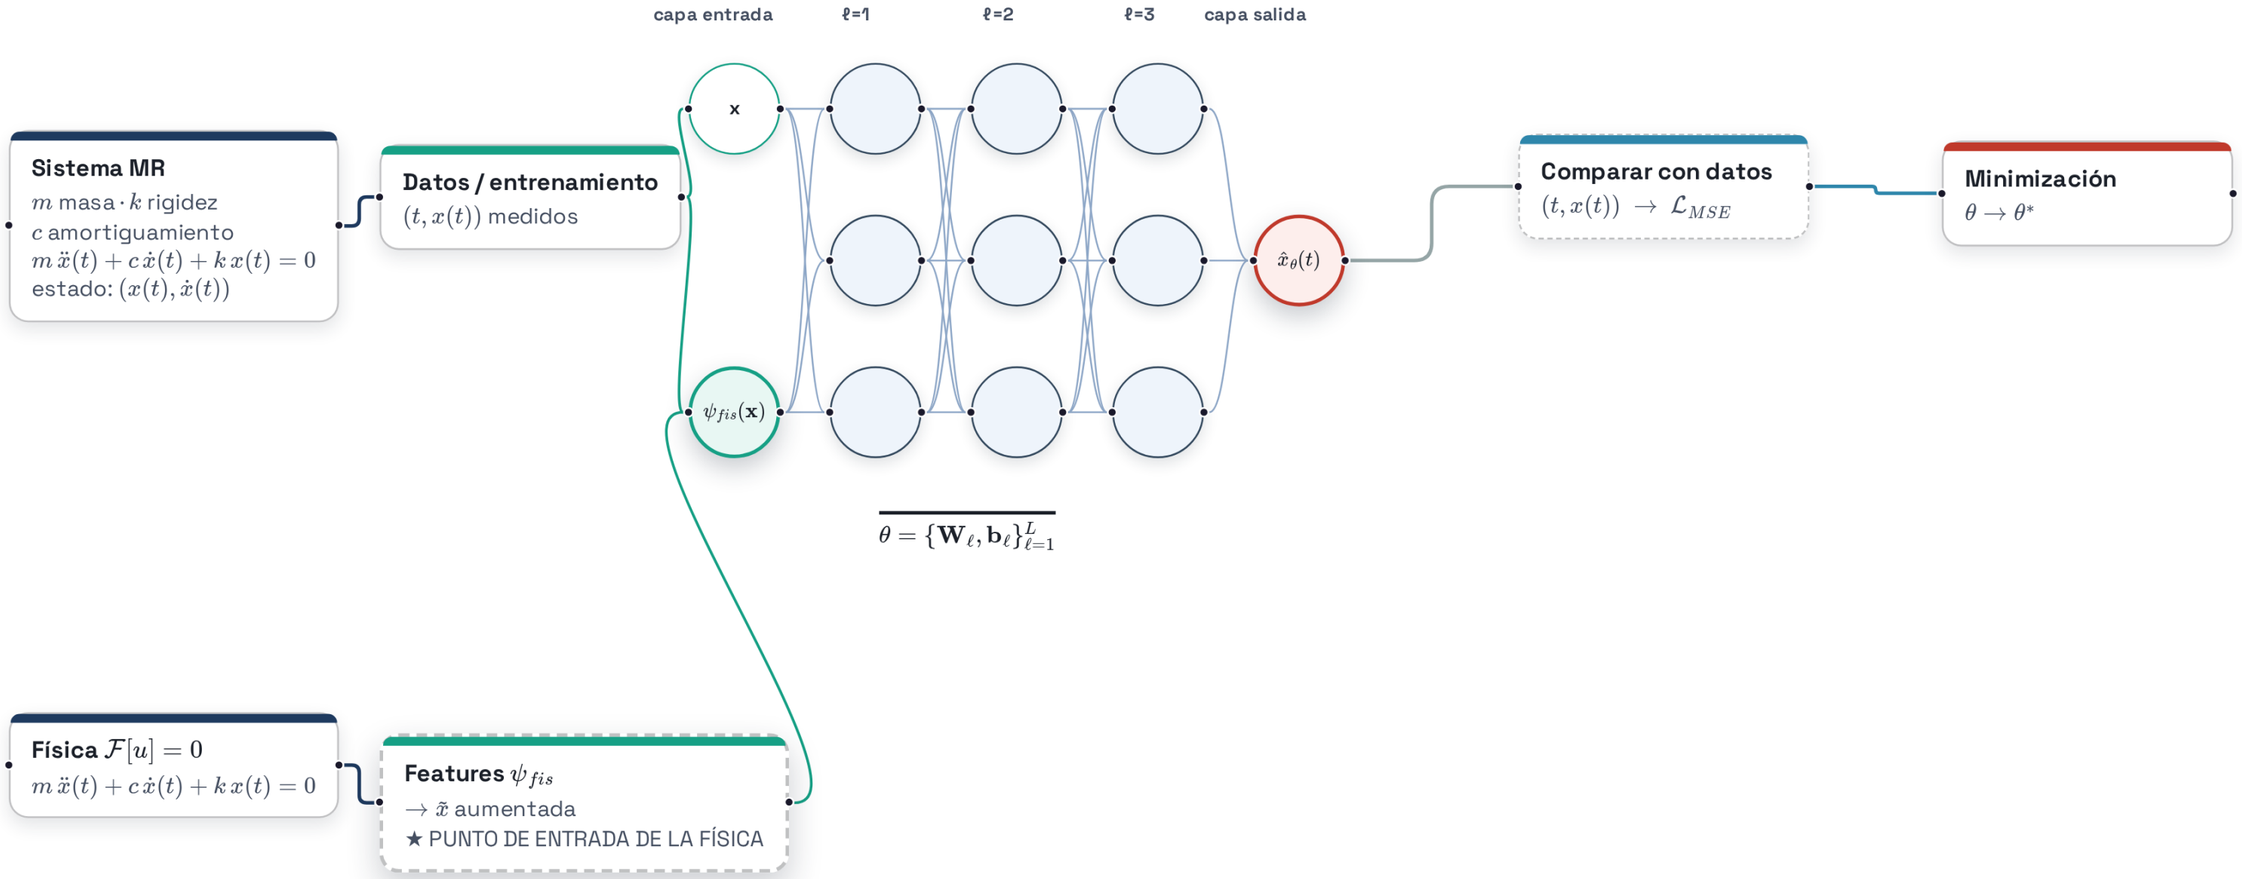
Problema de optimización (sobre $\tilde{\mathbf{x}}$ aumentado, + bottleneck)

$$\theta^* = \arg\min_{\theta \in \Theta}\ \mathcal{L}_{MSE}(\theta; \tilde{\mathbf{x}}), \qquad \mathbf{z}_{bot} = E(t)$$

Conexión: el problema se plantea sobre la entrada aumentada $\tilde{\mathbf{x}}$; en la variante con bottleneck la latente $\mathbf{z}_{bot}$ queda restringida a un significado físico explícito (Hao 2022).

Hao et al. PIML: A Survey on Problems, Methods and Applications. arXiv:2211.08064, 2022.
Willard et al. ACM Computing Surveys, 2022.
Machine Learning with Physics Knowledge for Prediction: A Survey. arXiv:2408.09840.

MR · Puerta ③ — la física entra en los datos / features



$\mathcal{L}_{MSE}(\theta)$ sobre $\tilde{x}$ aumentado — la física entró antes, en los datos

Sistema MR / física · ③ Datos / features · Modelo ML f_θ · Minimización → θ^*

Puerta ④ — Híbrido simulador + red (grey-box)

- **¿Por qué existen?:** un simulador confiable **subvenciona** a la red: f_{fis} da la predicción base —interpretable y físicamente correcta— y g_θ aprende solo el residuo.
- **¿Cuándo se eligen sobre la PINN pura?:** cuando existe un simulador/ley confiable y el riesgo de soluciones no físicas del entrenamiento PINN es alto; hereda la tradición grey-box de identificación de parámetros.

④ Híbrido simulador + red (grey-box)

$$\hat{y} = \underbrace{f_{fis}(\mathbf{x})}_{\text{predicción base física}} + \underbrace{g_\theta(\mathbf{x})}_{\text{residuo aprendido}} \quad \text{o} \quad \hat{y} = g_\theta\big(\mathbf{x},\, f_{fis}(\mathbf{x})\big)$$

Conexión: residual learning y feature stacking; tradición grey-box (Bacher & Madsen 2011).

Bacher & Madsen. Identifying suitable models for the heat dynamics of buildings. Energy and Buildings 43, 2011.

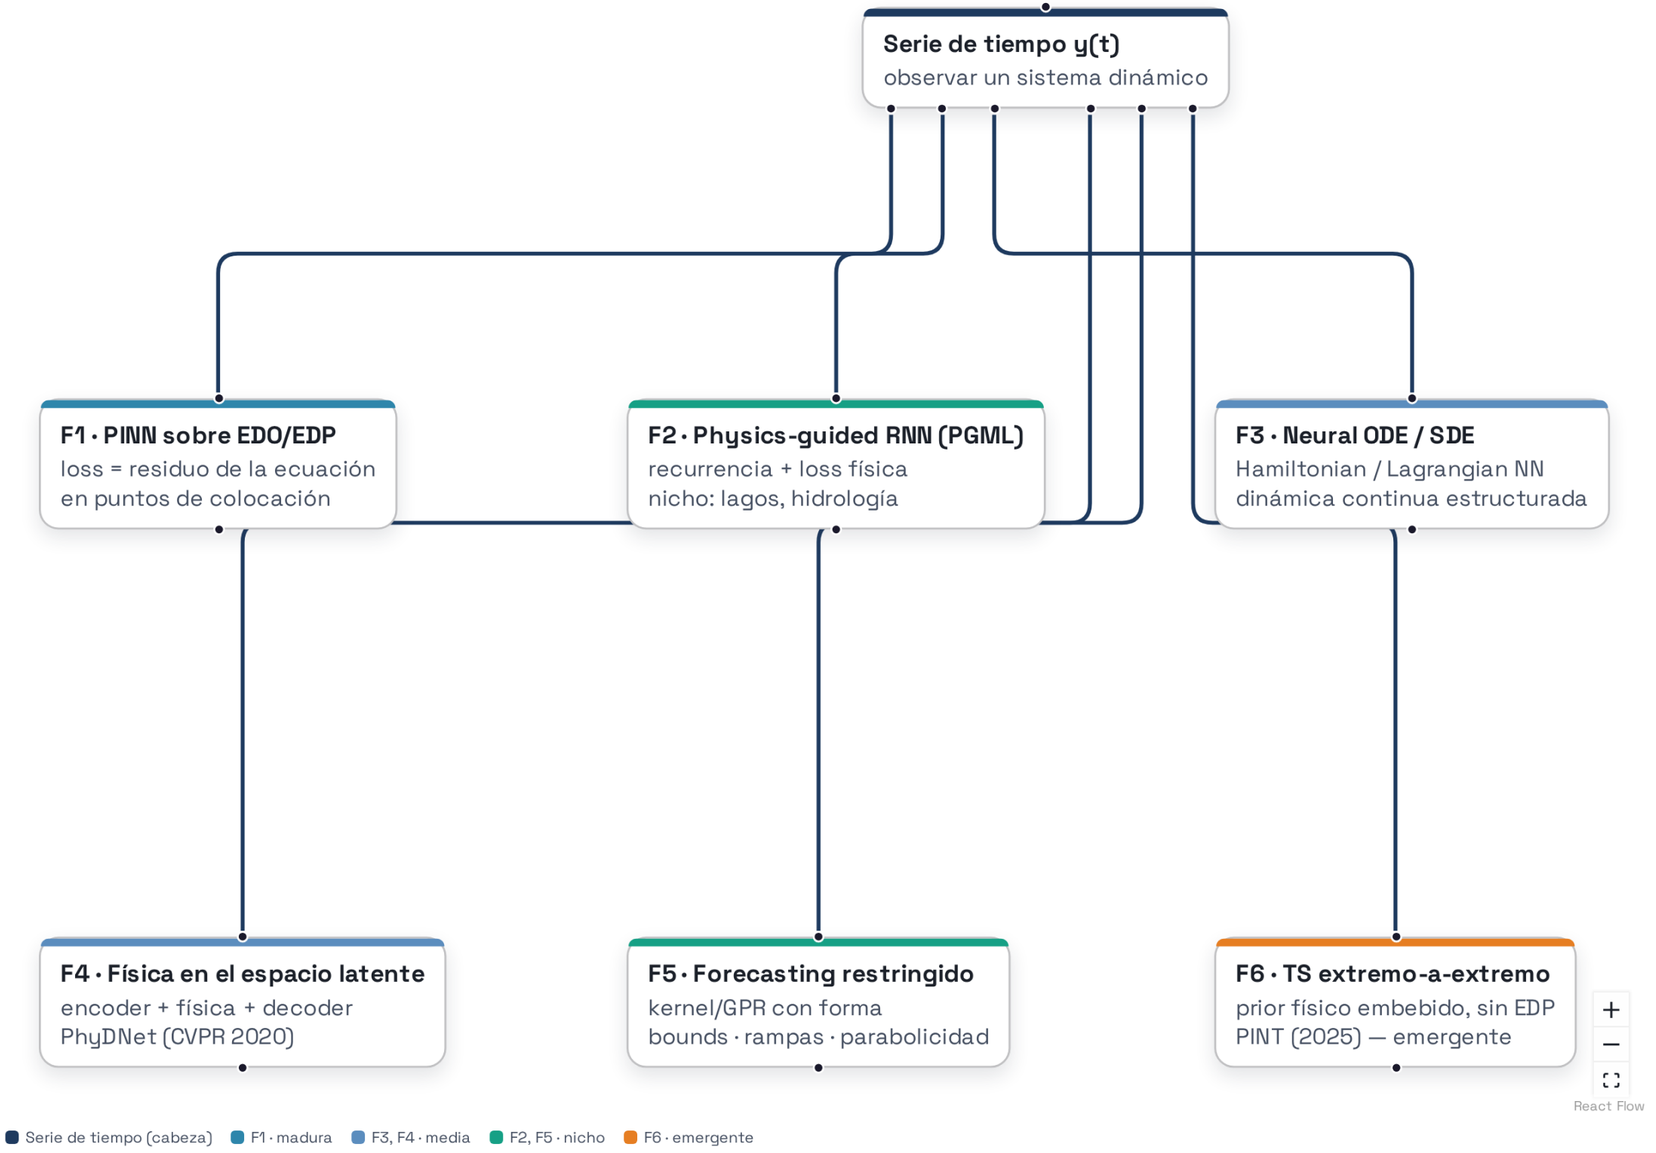
4 · DIAGRAMA 2

Familias PIML para series de tiempo (todas las aplicaciones)

- Punto de partida común: la serie $y[t]$ observa un sistema dinámico gobernado por una ley $\mathcal{F}[u] = 0$ total o parcialmente conocida.
- **F1** PINN · **F2** PG-RNN · **F3** Neural ODE/SDE · **F4** física latente (PhyDNet) · **F5** kernel/GPR · **F6** física embebida (PINT/RFF).

Raissi et al., J. Comp. Physics 378, 2019 (F1) · Karpatne et al., arXiv:1710.11431 (F2) · Greydanus NeurIPS 2019 / Chen NeurIPS 2018 (F3) · Le Guen & Thome, CVPR 2020 (F4) · Doumèche 2025 / Tartakovsky IJF 2023 (F5) · PINT, arXiv:2502.04018 (F6).

Diagrama 2 · Seis familias PIML para series de tiempo



4 · MATEMÁTICA DEL DIAGRAMA 2

F1 — PINN sobre EDO/EDP · F2 — Physics-guided RNN

F1 · La red aproxima la solución del sistema dinámico

$$\partial_t u + \mathcal{F}[u] = 0 \ \text{ en } \Omega_T, \qquad r_\theta(t, \mathbf{x}) = \partial_t u_\theta + \mathcal{F}[u_\theta]$$

Conexión: "la red aprende LA SOLUCIÓN" ↔ $u_\theta(t, \mathbf{x})$; el residuo se evalúa en los N_c puntos de colocación $(t_j, \mathbf{x}_j)$.

F1 · Pérdida con puntos de colocación

$$\mathcal{L}_{PINN}(\theta) = \frac{1}{N_d}\sum_{i=1}^{N_d} \left|u_\theta(t_i, \mathbf{x}_i) - u(t_i, \mathbf{x}_i)\right|^2 + \lambda_{phys}\,\frac{1}{N_c}\sum_{j=1}^{N_c} \left\|r_\theta(t_j, \mathbf{x}_j)\right\|^2, \qquad \hat{\theta} = \arg\min_\theta \mathcal{L}_{PINN}(\theta)$$

F2 · Recurrencia estándar + término físico

$$\mathbf{h}[t] = f_{RNN}(\mathbf{x}[t], \mathbf{h}[t-1]; \theta_r), \qquad \hat{\mathbf{y}}_{T+1:T+\tau} = g_\theta(\mathbf{h}[T]) \in \mathbb{R}^\tau$$

Conexión: "recurrencia estándar" ↔ f_{RNN}; "consistencia temporal" ↔ $\mathcal{L}_{EC}$ (línea PGML de Karpatne).

F2 · Pérdida de consistencia temporal

$$\mathcal{L}_{PG}(\theta) = \frac{1}{N}\sum_{n=1}^{N} \|\mathbf{y}_{n+1:n+\tau} - \hat{\mathbf{y}}_{n+1:n+\tau}\|_2^2 + \lambda_{phys}\mathcal{L}_{EC}(\theta), \quad \mathcal{L}_{EC} = \sum_t \|r_{EC}(\hat{y}[t], \hat{y}[t-1], \mathbf{x}[t])\|^2, \quad \hat{\theta} = \arg\min_\theta \mathcal{L}_{PG}(\theta)$$

4 · MATEMÁTICA DEL DIAGRAMA 2

F3 — Neural ODE/SDE informados · F4 — Física en el espacio latente

F3 · Dinámica continua integrada con solver diferenciable

$$\frac{d\mathbf{h}(t)}{dt} = f_\theta(\mathbf{h}(t), t), \qquad \mathbf{h}(t_1) = \mathbf{h}(t_0) + \int_{t_0}^{t_1} f_\theta(\mathbf{h}(t), t)\, dt$$

Conexión: "estructura física parcial" ↔ forma hamiltoniana (puerta ② del D1) o lagrangiana Euler–Lagrange (siguiente ecuación); variante estocástica con dW_t.

F3 · Lagrangian NN (Euler–Lagrange)

$$\frac{d}{dt}\frac{\partial L_\theta}{\partial \dot{q}} - \frac{\partial L_\theta}{\partial q} = 0$$

Conexión: $q = q(t)$ y $\dot{q} = \dot{q}(t)$ dependen del tiempo; las derivadas parciales son respecto a esas variables (puerta ②, formulación lagrangiana).

F4 · PhyDNet: latente descompuesta física + residual

$$\mathbf{z}[t] = \mathbf{z}[t]^{phys} + \mathbf{z}[t]^{res}, \qquad \hat{y}[t] = \mathrm{Dec}(\mathbf{z}[t]), \qquad \mathbf{z}[t]^{phys} = \mathrm{PhyCell}(\mathbf{z}[t-1]^{phys})$$

Conexión: "encoder → latente donde actúa la física → decoder" ↔ Enc, PhyCell, Dec; "física + residual" ↔ $\mathbf{z}[t]^{phys} + \mathbf{z}[t]^{res}$.

F5 — Forecasting restringido · F6 — TS con física embebida

F5 · Kernel ridge con restricciones de forma

$$\hat{f}_{\boldsymbol{\theta}}(\mathbf{x}) = \sum_{i=1}^{N} \theta_i \, \kappa(\mathbf{x}, \mathbf{x}_i), \qquad \hat{\boldsymbol{\theta}} = (\mathbf{K} + \lambda_{rk}\mathbf{I})^{-1}\mathbf{y}$$

Conexión: "bounds, rampas, parabolicidad, estacionalidad" ↔ las restricciones sobre f; GPR con prior físico (formulación de Doumèche 2025 / PhI-GPR).

F5 · GPR: distribución predictiva y estimación de hiperparámetros

$$p(\mathbf{y}_* \mid \mathbf{x}_*, \mathcal{D}) = \mathcal{N}(\boldsymbol{\mu}_*, \boldsymbol{\Sigma}_*), \quad \boldsymbol{\mu}_* = \mathbf{K}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I})^{-1}\mathbf{y}, \quad \boldsymbol{\Sigma}_* = \mathbf{K}_{**} - \mathbf{K}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I})^{-1}\mathbf{K}_*$$

La media es la predicción puntual; $\boldsymbol{\Sigma}_*$ cuantifica incertidumbre predictiva. Esta forma corresponde a GP gaussiano con ruido gaussiano y kernel fijado. Los hiperparámetros se pueden estimar maximizando la verosimilitud marginal, no minimizando un MSE genérico.

F5 · Verosimilitud marginal para hiperparámetros

$$\hat{\boldsymbol{\eta}} = \arg\max_{\boldsymbol{\eta}} p(\mathbf{y} \mid \mathbf{X}, \boldsymbol{\eta})$$

$\boldsymbol{\eta}$ reúne parámetros del kernel y del ruido. Si se incorpora un prior sobre estos hiperparámetros, la estimación MAP maximiza $p(\mathbf{y} \mid \mathbf{X}, \boldsymbol{\eta})p(\boldsymbol{\eta})$; no se confunde con la distribución predictiva posterior.

F6 · Prior físico cableado, sin EDP explícita

$$\hat{\mathbf{y}} = g_\theta\big(\mathbf{X};\, \mathcal{P}_{fis}\big)$$

Conexión: "inductive biases específicas" ↔ $\mathcal{P}_{fis}$ dentro de g_θ; el RFF multibanda (Ecuación 24) es una instancia con prior espectral.

F6 · RFF multibanda del artículo guía (Ecuación 24)

$$\boldsymbol{\phi}_{\boldsymbol{\omega}}(\mathbf{x}[t]) = \sqrt{\frac{2}{\quad}} \cos\big(\mathrm{softplus}(\boldsymbol{\omega})\, \mathbf{W}^\top \mathbf{x}[t] + \mathbf{b}\big)$$

Neural ODE/SDE, PhyDNet y física embebida: salida y estimación

- La estructura común identifica entradas, salidas y estimación; no borra las diferencias entre una trayectoria determinista, una dinámica estocástica y una arquitectura con prior físico.
- La pérdida de datos depende del tipo de salida y del modelo probabilístico; la física puede estar en la dinámica o la arquitectura, sin una penalización residual explícita.

F3 · SDE y estimación probabilística

$$d\mathbf{h}(t) = f_\theta(\mathbf{h}(t), t)dt + \mathbf{G}_\theta(\mathbf{h}(t), t)d\mathbf{W}_t, \quad \hat{\theta} = \arg\min_\theta[-\log p_\theta(\mathbf{y}_{T+1:T+\tau} \mid \mathbf{X}^{win}_{T-L+1:T})]$$

La distribución predictiva se induce por la dinámica estocástica y el modelo de observación; si la verosimilitud no es tractable, se requiere el estimador aproximado correspondiente. Para la variante ODE determinista se usa la pérdida compatible con las observaciones, no se asume automáticamente una predictiva gaussiana.

F4 · PhyDNet: ventana, latente físico/residual y salida

$$\mathbf{z} = \mathrm{Enc}_\theta(\mathbf{X}^{win}), \quad \hat{\mathbf{y}}_{T+1:T+\tau} = \mathrm{Dec}_\theta(\mathbf{z}^{phys}_{T+\tau}, \mathbf{z}^{res}_{T+\tau}), \quad \hat{\theta} = \arg\min_\theta \frac{1}{N}\sum_{n=1}^{N} \|\mathbf{y}_{n+1:n+\tau} - f_\theta(\mathbf{X}^{win}_n)\|_2^2$$

La evolución de los estados latentes mantiene las recurrencias física y residual descritas en la diapositiva anterior. La función de pérdida mostrada es el ajuste empírico de una predicción puntual; no afirma que sea el único objetivo posible de la familia.

F6 · Física embebida en la arquitectura

$$\hat{\mathbf{Y}} = g_\theta(\mathbf{X}^{win}; \mathcal{P}_{fis}), \qquad \hat{\theta} = \arg\min_\theta \frac{1}{N}\sum_{n=1}^{N} \mathcal{L}(\mathbf{y}_{n+1:n+\tau}, g_\theta(\mathbf{X}^{win}_n; \mathcal{P}_{fis}))$$

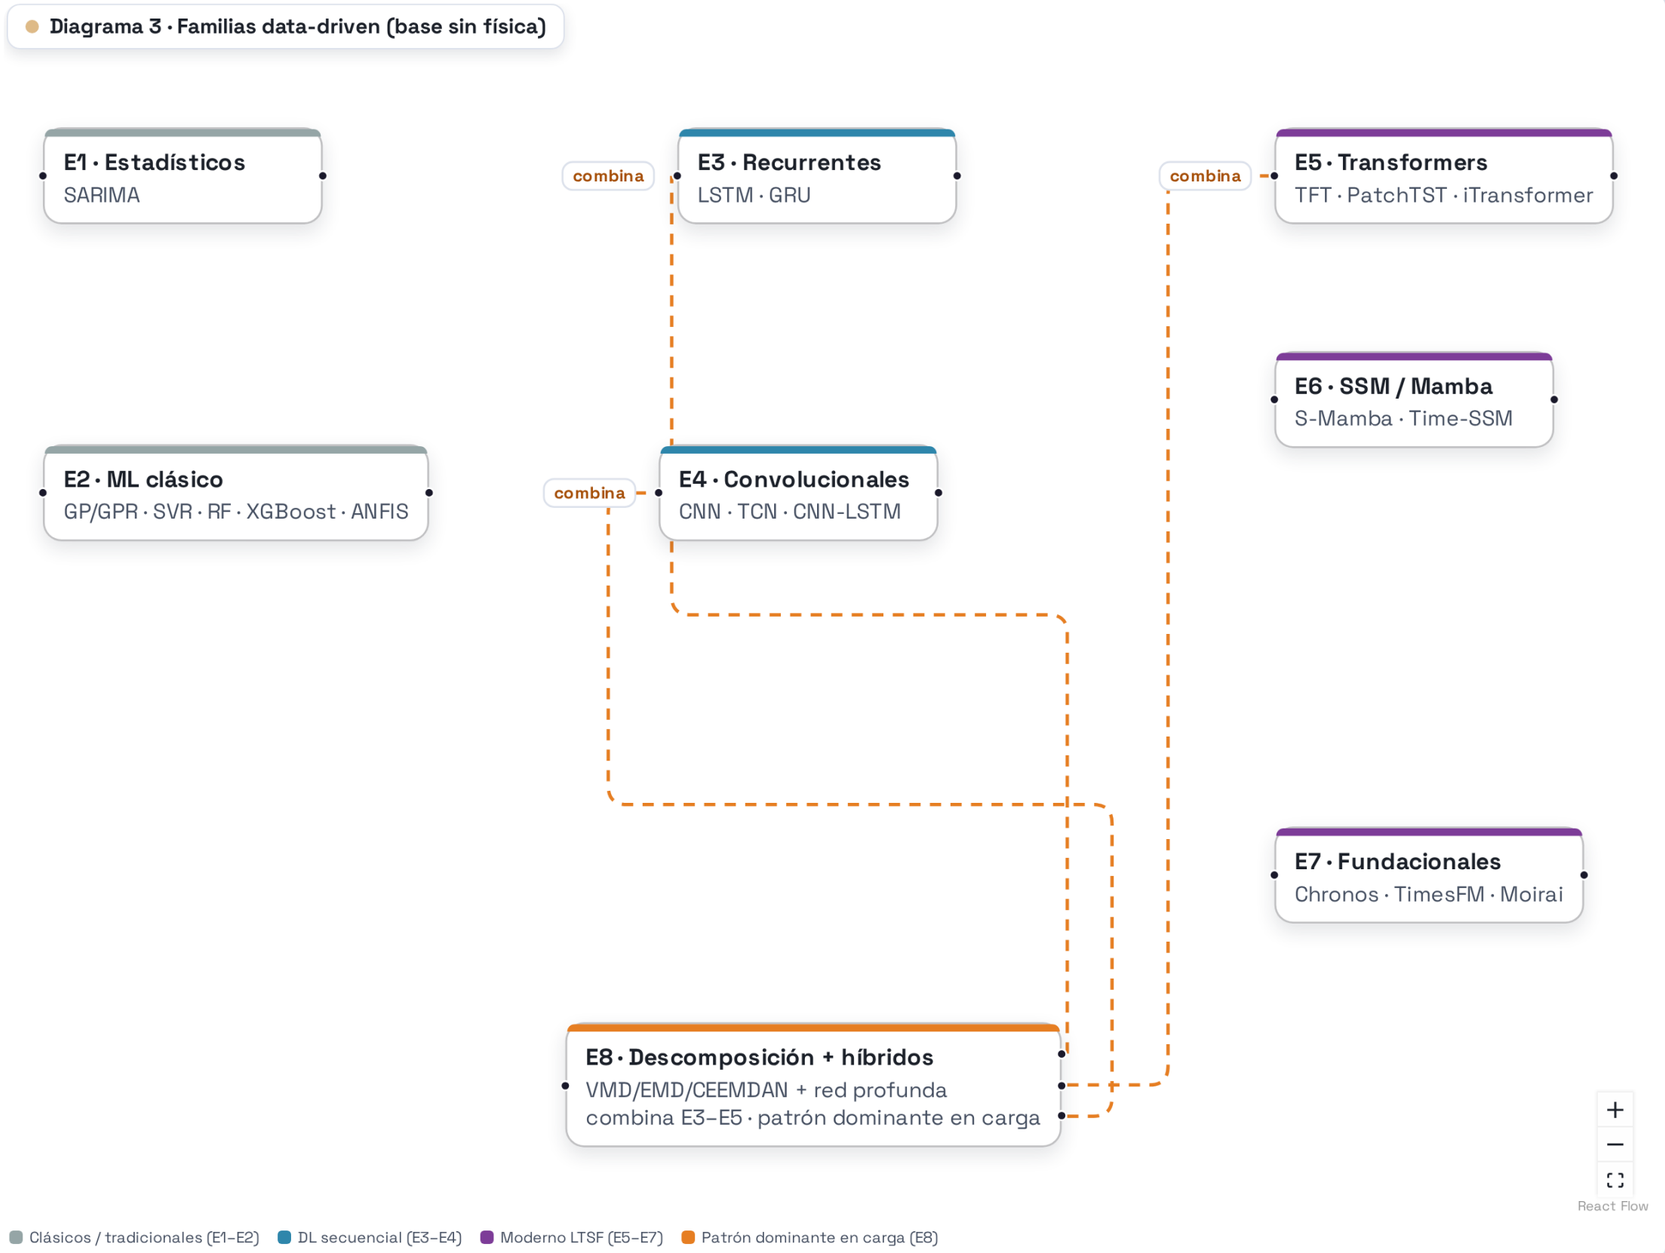
El prior físico $\mathcal{P}_{fis}$ forma parte de la arquitectura (como el embedding espectral RFF); si no hay residuo de ley física, no se inventa una pérdida PINN separada. La penalización convencional, si existe, se declara aparte.

5A · DIAGRAMA 3

Familias data-driven en sistemas energéticos (SIN física)

- El contraste necesario: la base contra la que se mide todo PIML energético — las 8 familias de la matriz SOTA 2022–2026.
- **E1** Estadísticos · **E2** ML clásico · **E3** Recurrentes · **E4** TCN · **E5** Transformers LTSF · **E6** SSM/Mamba · **E7** Fundacionales · **E8** Descomposición + híbridos (patrón dominante en carga).

Matriz interna (32 papers ≥2022; hoja "Matriz Energia" con 25) · Kim et al., arXiv:2411.05793 · Kong et al., IJMLC 16, 2025 · Benchmark KIT-IAI, arXiv:2607.15705, 2026.



5A · MATEMÁTICA DEL DIAGRAMA 3

E1 — ARIMA: autorregresivo integrado de medias móviles

- **Definición:** ARIMA(p, d, q) modela la serie diferenciada d veces con una parte autorregresiva (orden p) y una de medias móviles (orden q).
- Cambia el punto de partida: no hay $\hat{\mathbf{Y}} = \mathbf{XW}$, sino dependencia de la propia serie y de sus errores pasados.

Entrada y salida

$$y[1:T] = (y[1], \ldots, y[T]), \qquad \hat{y}_\eta[t] = \mathbb{E}_\eta[y[t] \mid y[1:t-1]], \qquad \hat{\mathbf{y}}_{T+1:T+\tau} \in \mathbb{R}^\tau$$

La entrada es la serie observada hasta T; la salida es la predicción condicional a su propio pasado, no una matriz de características. τ es el horizonte, como en el resto del diagrama.

Modelo ARIMA(p, d, q)

$$\phi_p(\mathcal{B})\,(1-\mathcal{B})^d\, y[t] = c + \theta_q(\mathcal{B})\,\varepsilon[t], \qquad \varepsilon[t] \sim \mathcal{N}(0, \sigma_\varepsilon^2)$$
$$\phi_p(\mathcal{B}) = 1 - \phi_1\mathcal{B} - \cdots - \phi_p\mathcal{B}^p, \qquad \theta_q(\mathcal{B}) = 1 + \theta_1\mathcal{B} + \cdots + \theta_q\mathcal{B}^q$$

El operador de rezago cumple $\mathcal{B}\,y[t] = y[t-1]$. La parte AR captura la dependencia con los rezagos, $(1-\mathcal{B})^d$ remueve tendencia y la parte MA modela los errores pasados. Los parámetros se agrupan en $\eta = \phi, \theta, c, \sigma_\varepsilon^2$ y d es el orden de diferenciación.

Función de costo: riesgo esperado

$$J(\eta) = \mathbb{E}\Big[\big(y[t] - \hat{y}_\eta[t]\big)^2\Big]$$
$$\mathbb{E}\big[-\log L(\eta, \sigma_\varepsilon^2)\big] = \frac{1}{2\sigma_\varepsilon^2} J(\eta) + \text{cte}$$

El criterio es el error cuadrático de predicción esperado. Con innovaciones gaussianas y varianza fija, la log-verosimilitud negativa esperada es proporcional a $J(\eta)$: los dos criterios están **relacionados**, pero no son idénticos en toda formulación de verosimilitud.

Aproximación empírica

$$\widehat{J}_{N_{\text{eff}}}(\eta) = \frac{1}{N_{\text{eff}}} \sum_{t=t_0}^{T} \big(y[t] - \hat{y}_\eta[t]\big)^2$$

$N_{\text{eff}} = T - t_0 + 1$ es el número de observaciones efectivas: la diferenciación y los rezagos consumen observaciones iniciales. La serie temporal **no** es i.i.d., así que el promedio es una aproximación de trabajo.

Problema de optimización

$$\hat{\eta} \in \arg\min_{\eta} \widehat{J}_{N_{\text{eff}}}(\eta)$$

En la práctica ARIMA se estima habitualmente por **máxima verosimilitud** —a menudo condicional a las primeras observaciones—, que con innovaciones gaussianas y varianza fija conduce al mismo óptimo que el criterio cuadrático, salvo constantes.

Familia E1: ARIMA es el modelo base del bloque estadístico; SARIMA añade la parte estacional sobre esta misma estructura y conserva el criterio de estimación.

Box, Jenkins, Reinsel, Ljung. Time Series Analysis: Forecasting and Control. Wiley, 5ª ed., 2015.

Hyndman & Athanasopoulos. Forecasting: Principles and Practice. OTexts, 3ª ed., 2021.

5A · MATEMÁTICA DEL DIAGRAMA 3

E1 — SARIMA: extensión estacional de ARIMA

- **Definición:** SARIMA$(p,d,q)(P,D,Q)_s$ añade a ARIMA un juego de operadores en el rezago estacional s; es el único método estadístico clásico nombrado en el diagrama 3.
- Es la línea base de comparación de la familia E2, que comienza en la diapositiva siguiente.

Entrada y salida

$$y[1:T] = (y[1], \ldots, y[T]), \qquad \hat{y}_\eta[t] = \mathbb{E}_\eta[y[t] \mid y[1:t-1]], \qquad \hat{\mathbf{y}}_{T+1:T+\tau} \in \mathbb{R}^\tau$$

Misma entrada y salida que ARIMA; aquí s es el período estacional (24 h diario, 168 h semanal) y la dependencia se repite cada s pasos.

Modelo SARIMA$(p,d,q)(P,D,Q)_s$

$$\phi_p(\mathcal{B})\,\Phi_P(\mathcal{B}^s)\,(1-\mathcal{B})^d\,(1-\mathcal{B}^s)^D\,y[t] = c + \theta_q(\mathcal{B})\,\Theta_Q(\mathcal{B}^s)\,\varepsilon[t]$$

$$\mathcal{B}^s y[t] = y[t-s], \qquad \Phi_P(\mathcal{B}^s) = 1 - \Phi_1\mathcal{B}^s - \cdots, \qquad \Theta_Q(\mathcal{B}^s) = 1 + \Theta_1\mathcal{B}^s + \cdots$$

SARIMA **extiende** ARIMA: a la parte simple se suma la estacional —AR $\Phi_P(\mathcal{B}^s)$, MA $\Theta_Q(\mathcal{B}^s)$ y la diferenciación $(1-\mathcal{B}^s)^D$—. El período s es local de esta ecuación. Todos los coeficientes se agrupan en η.

Función de costo: riesgo esperado

$$J(\eta) = \mathbb{E}\Big[\big(y[t] - \hat{y}_\eta[t]\big)^2\Big]$$

$$\mathbb{E}\big[-\log L(\eta, \sigma_\varepsilon^2)\big] = \frac{1}{2\sigma_\varepsilon^2} J(\eta) + \text{cte}$$

Idéntico al de ARIMA: la extensión estacional cambia el modelo, no el criterio de error cuadrático de predicción ni su relación con la log-verosimilitud gaussiana de varianza fija.

Aproximación empírica

$$\widehat{J}_{N_{\text{eff}}}(\eta) = \frac{1}{N_{\text{eff}}} \sum_{t=t_0}^{T} \big(y[t] - \hat{y}_\eta[t]\big)^2$$

Promedio sobre las $N_{\text{eff}} = T - t_0 + 1$ observaciones efectivas: la diferenciación, el rezago estacional y los órdenes AR consumen observaciones iniciales. Las observaciones temporales **no** son i.i.d.

Problema de optimización

$$\hat{\eta} \in \arg\min_\eta \widehat{J}_{N_{\text{eff}}}(\eta)$$

También se estima habitualmente por **máxima verosimilitud**; con innovaciones gaussianas y varianza fija el óptimo coincide con el del criterio cuadrático, salvo constantes.

Ejemplo reducido: SARIMA$(1,0,0)(0,0,0)_s$ es un AR(1) con constante, $\hat{y}[t] = c + \phi_1 y[t-1]$; con $c = 20$, $\phi_1 = 0.9$ y $y[t-1] = 140$ kWh, $\hat{y}[t] = 146$ kWh.

Box, Jenkins, Reinsel, Ljung. Time Series Analysis: Forecasting and Control. Wiley, 5ª ed., 2015.

Hyndman & Athanasopoulos. Forecasting: Principles and Practice. OTexts, 3ª ed., 2021.

SARIMA: historia, estimación y distribución de pronóstico

- **Entrada:** historia observada hasta T, con ventana histórica de longitud L; **salida:** distribución o pronóstico para los siguientes τ pasos.
- La dinámica de rezagos y diferencias del SARIMA se conserva; el horizonte no cambia sus órdenes p, d, q, P, D, Q, s.

Pronóstico condicional multi-paso

$$\hat{\mathbf{y}}_{T+1:T+\tau} = \mathbb{E}_{\hat{\psi}}[\mathbf{y}_{T+1:T+\tau} \mid y_{1:T}], \qquad \mathbf{y}_{T+1:T+\tau} \in \mathbb{R}^{\tau}$$

La media condicional da una predicción puntual; bajo innovaciones gaussianas el modelo también induce una distribución predictiva y sus intervalos. La varianza predictiva crece, en general, con el horizonte.

Estimación por verosimilitud (ejemplo condicional)

$$\hat{\psi}_{ML} = \arg\max_{\psi} p_{\psi}(y_{L+1:T} \mid y_{1:L}), \qquad \varepsilon[t] \overset{iid}{\sim} \mathcal{N}(0, \sigma_{\varepsilon}^2)$$

El conjunto ψ reúne parámetros AR, MA, estacionales y de varianza. Se maximiza la verosimilitud definida por la estructura temporal y el supuesto de innovaciones; no se reemplaza por MSE salvo que se justifique la equivalencia para el caso gaussiano correspondiente.

Entrada histórica y objetivo empírico de parámetros

$$\mathbf{x}_n^{win} = (y[n-L+1], \ldots, y[n]) \in \mathbb{R}^L, \qquad \hat{\psi} = \arg\min_{\psi} \left[-\log p_{\psi}(y_{L+1:T} \mid y_{1:L})\right]$$

L denota longitud de ventana histórica y no el horizonte; τ cuenta pasos pronosticados. En la práctica, la verosimilitud puede incluir el tratamiento de condiciones iniciales y efectos estacionales.

Box, Jenkins, Reinsel, Ljung. Time Series Analysis: Forecasting and Control. Wiley, 5ª ed., 2015.

Hyndman & Athanasopoulos. Forecasting: Principles and Practice. OTexts, 3ª ed., 2021.

E2 — Regresión lineal por mínimos cuadrados

- **Límites:** con colinealidad o con $P > N$ la solución puede no ser única; de esas dos condiciones nacen ridge y lasso.

E2 · Entrada y salida

$$\mathbf{x}_n \in \mathbb{R}^P, \quad \mathbf{X} \in \mathbb{R}^{N \times P}; \qquad \mathbf{y}_n \in \mathbb{R}^\tau, \quad \mathbf{Y} \in \mathbb{R}^{N \times \tau}$$

N observaciones, P características y τ salidas; con una sola respuesta $\tau = 1$ y se conserva τ para la extensión multi-salida. El intercepto entra como columna de unos en $\mathbf{X}$ o como sesgo explícito.

E2 · Modelo lineal

$$\hat{\mathbf{y}}_n = \mathbf{W}^\top \mathbf{x}_n, \quad \mathbf{W} \in \mathbb{R}^{P \times \tau}; \qquad \hat{\mathbf{Y}} = \mathbf{X}\mathbf{W}$$

La primera expresión predice las τ salidas de una observación; la segunda reúne las N predicciones. Con $\tau = 1$ se obtiene la regresión lineal escalar.

E2 · Función de costo: riesgo esperado y empírico

$$J(\mathbf{W}) = \mathbb{E}_{(\mathbf{x},\mathbf{y})\sim p_{\text{datos}}}\left[\|\mathbf{y} - \mathbf{W}^\top \mathbf{x}\|_2^2\right]$$

$$\widehat{J}_N(\mathbf{W}) = \frac{1}{N}\sum_{n=1}^{N} \|\mathbf{y}_n - \mathbf{W}^\top \mathbf{x}_n\|_2^2 = \frac{1}{N}\|\mathbf{Y} - \mathbf{X}\mathbf{W}\|_F^2$$

El costo poblacional promedia sobre la distribución de datos; la media sobre N muestras i.i.d. lo aproxima empíricamente. Dividir por N cambia la escala del costo, no su minimizador.

E2 · Problema de optimización

$$\mathbf{W}^* \in \arg\min_{\mathbf{W}} J(\mathbf{W})$$

$$\widehat{\mathbf{W}} \in \arg\min_{\mathbf{W}} \widehat{J}_N(\mathbf{W})$$

El óptimo poblacional es $\mathbf{W}^*$; el estimador $\widehat{\mathbf{W}}$ resuelve su versión empírica. Se usa $\in \arg\min$ porque con colinealidad puede haber más de un minimizador.

E2 · Solución por ecuaciones normales

$$\mathbf{X}^\top \mathbf{X}\hat{\mathbf{W}} = \mathbf{X}^\top \mathbf{Y}; \qquad \hat{\mathbf{W}} = \mathbf{X}^+ \mathbf{Y}$$

Las ecuaciones normales caracterizan el mínimo. Con rango columna completo, $\mathbf{X}^+ = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top$ y la solución es única; en general $\mathbf{X}^+$ es la pseudoinversa de Moore–Penrose y el residuo es ortogonal a las columnas de $\mathbf{X}$.

Idea central: mínimos cuadrados no elige el modelo, elige los coeficientes: la solución cerrada sale de igualar a cero el gradiente y deja el residuo ortogonal a las columnas de $\mathbf{X}$. Todo lo que sigue —verosimilitud, ridge, lasso— cambia el criterio o le añade un término, pero conserva esta lectura. Ojo con el vocabulario: $\mathbf{e}$ es residuo (observable), $\boldsymbol{\varepsilon}$ es error (no observable), y $R^2 = 1 - \|\mathbf{e}\|_2^2 / \|\mathbf{y} - \bar{y}\mathbf{1}\|_2^2$ crece siempre al añadir variables, por eso se reporta el ajustado.

5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — Máxima verosimilitud (MLE)

- La verosimilitud convierte un supuesto sobre el **ruido** en un criterio de estimación: no añade un modelo nuevo.
- Aporta $\hat{\sigma}^2$ —y con ella la inferencia— y la lectura bayesiana de ridge y lasso.

E2 · Modelo probabilístico

$$\mathbf{y}_n = \mathbf{W}^\top \mathbf{x}_n + \boldsymbol{\varepsilon}_n, \qquad \boldsymbol{\varepsilon}_n \overset{iid}{\sim} \mathcal{N}\big(\mathbf{0}, \sigma^2 \mathbf{I}_\tau\big)$$
$$\mathbf{y}_n \mid \mathbf{x}_n, \mathbf{W}, \sigma^2 \sim \mathcal{N}\big(\mathbf{W}^\top \mathbf{x}_n, \sigma^2 \mathbf{I}_\tau\big)$$

Supuesto sobre el ruido, no un modelo nuevo: el predictor sigue siendo $\hat{\mathbf{y}}_n = \mathbf{W}^\top \mathbf{x}_n$. Con $\tau = 1$ se recupera $\varepsilon_n \overset{iid}{\sim} \mathcal{N}(0, \sigma^2)$; la varianza común y la independencia entre muestras forman parte del supuesto. $\boldsymbol{\varepsilon}_n$ es error no observable, distinto del residuo $\mathbf{e} = \mathbf{Y} - \mathbf{X}\hat{\mathbf{W}}$.

E2 · Función de verosimilitud

$$L(\mathbf{W}, \sigma^2) = \prod_{n=1}^{N} p\big(\mathbf{y}_n \mid \mathbf{x}_n, \mathbf{W}, \sigma^2\big)$$
$$= \big(2\pi\sigma^2\big)^{-N\tau/2} \exp\left[-\frac{1}{2\sigma^2}\|\mathbf{Y} - \mathbf{X}\mathbf{W}\|_F^2\right]$$

Las N muestras son i.i.d., así que la verosimilitud conjunta es el producto de las densidades. Tomar logaritmo no cambia el maximizador: $\log L = -\frac{N\tau}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\|\mathbf{Y} - \mathbf{X}\mathbf{W}\|_F^2$.

E2 · Problema de optimización

$$\mathcal{R}(\mathbf{W}, \sigma^2) = -\mathbb{E}_{(\mathbf{x},\mathbf{y})\sim p_{\text{datos}}}\big[\log p(\mathbf{y} \mid \mathbf{x}, \mathbf{W}, \sigma^2)\big]$$
$$\widehat{\mathcal{R}}_N(\mathbf{W}, \sigma^2) = -\frac{1}{N}\sum_{n=1}^{N} \log p(\mathbf{y}_n \mid \mathbf{x}_n, \mathbf{W}, \sigma^2)$$
$$(\widehat{\mathbf{W}}, \hat{\sigma}^2) \in \arg\min_{\mathbf{W},\, \sigma^2 > 0} \widehat{\mathcal{R}}_N(\mathbf{W}, \sigma^2)$$

El riesgo logarítmico negativo poblacional se aproxima por su media muestral bajo muestras i.i.d.; minimizarlo equivale a maximizar $\log L$. La varianza es un parámetro más del criterio: $\hat{\sigma}^2$ describe la dispersión del ruido.

E2 · Relación con mínimos cuadrados

$$\arg\max_{\mathbf{W}} \log L(\mathbf{W}, \sigma^2) = \arg\min_{\mathbf{W}} \frac{1}{N}\|\mathbf{Y} - \mathbf{X}\mathbf{W}\|_F^2 \qquad (\sigma^2 \text{ fija})$$

Con errores gaussianos independientes y homocedásticos, MLE y mínimos cuadrados comparten el estimador de $\mathbf{W}$: MLE es un criterio, no un modelo nuevo. Añade $\hat{\sigma}^2$ —sesgado; el insesgado usa $(N - P)\tau$ grados de libertad— para la inferencia.

Idea central: MLE no cambia a $\hat{\theta}$; justifica el criterio, da varianza e inferencia, y abre el punto de vista bayesiano. **Puente:** un prior sobre θ más esta verosimilitud produce un estimador MAP —gaussiano da ridge, Laplace da lasso—; regularizar es declarar una creencia previa.

E2 — Máximo a posteriori (MAP)

- MAP es un criterio de estimación: incorpora información previa sobre los parámetros, no un modelo nuevo.

E2 · Modelo probabilístico y prior

$$\mathbf{y}_n \mid \mathbf{x}_n, \mathbf{W}, \sigma^2 \sim \mathcal{N}\big(\mathbf{W}^\top \mathbf{x}_n, \sigma^2 \mathbf{I}_\tau\big), \qquad \mathbf{W} \sim p(\mathbf{W})$$

Se conserva la verosimilitud gaussiana de MLE y se añade un prior sobre los parámetros. σ^2 es la varianza del ruido y σ_0^2 la escala del prior: son dispersiones distintas.

E2 · Teorema de Bayes

$$p(\mathbf{W} \mid \mathbf{X}, \mathbf{Y}) \;\propto\; p(\mathbf{Y} \mid \mathbf{X}, \mathbf{W})\, p(\mathbf{W})$$

La posterior combina verosimilitud y prior; la evidencia $p(\mathbf{Y} \mid \mathbf{X})$ no depende de $\mathbf{W}$ y desaparece al optimizar.

E2 · Función de costo: esperanza y aproximación empírica

$$J_{\text{MAP}}(\mathbf{W}) = \mathbb{E}_{(\mathbf{x},\mathbf{y})\sim p_{\text{datos}}}[-\log p(\mathbf{y} \mid \mathbf{x}, \mathbf{W})] + \lambda\, \mathcal{R}(\mathbf{W})$$

$$\widehat{J}_{\text{MAP},N}(\mathbf{W}) = -\frac{1}{N}\sum_{n=1}^{N} \log p(\mathbf{y}_n \mid \mathbf{x}_n, \mathbf{W}) + \lambda\, \mathcal{R}(\mathbf{W})$$

El término de datos es el riesgo logarítmico de MLE; el prior entra como penalización, salvo constantes que no dependen de $\mathbf{W}$. Al promediar el término de datos por N, el prior también se divide: $\lambda\, \mathcal{R}(\mathbf{W}) \equiv \frac{1}{N}[-\log p(\mathbf{W})]$; con la suma de log-verosimilitudes ese $1/N$ no aparece.

E2 · Problema de optimización

$$\begin{aligned}\widehat{\mathbf{W}}_{\text{MAP}} &\in \arg\max_{\mathbf{W}} p(\mathbf{W} \mid \mathbf{X}, \mathbf{Y}) \\ &= \arg\min_{\mathbf{W}} [-\log p(\mathbf{Y} \mid \mathbf{X}, \mathbf{W}) - \log p(\mathbf{W})]\end{aligned}$$

Maximizar la posterior equivale a minimizar su logaritmo negativo; MAP es la moda de la posterior, no su esperanza.

E2 · Conexión con Ridge y Lasso

$$p(\mathbf{W}) \propto e^{-\|\mathbf{W}\|_F^2/(2\sigma_0^2)} \Rightarrow -\log p(\mathbf{W}) = \frac{\|\mathbf{W}\|_F^2}{2\sigma_0^2} + C$$

$$p(\mathbf{W}) \propto e^{-\|\mathbf{W}\|_1/b} \Rightarrow -\log p(\mathbf{W}) = \frac{\|\mathbf{W}\|_1}{b} + C$$

El prior gaussiano induce la penalización ℓ_2 de Ridge y el Laplace independiente la ℓ_1 de Lasso. Con el término de datos promediado, el peso escala como $\lambda \propto \sigma^2/(N\sigma_0^2)$ y $\lambda \propto \sigma^2/(Nb)$.

Idea central: MAP no reemplaza la verosimilitud: le añade una creencia previa sobre $\mathbf{W}$. Regularizar es exactamente eso, y Ridge y Lasso se desarrollan en las páginas siguientes con esta lectura.

Bishop, Pattern Recognition and Machine Learning, Springer, 2006, cap. 3; Hastie, Tibshirani & Friedman, The Elements of Statistical Learning, 2.ª ed., 2009, cap. 3.

5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — Ridge (L2): penalización cuadrática

- Penaliza la **magnitud** de los coeficientes: los contrae hacia cero **sin anularlos**.
- Es el estimador **MAP** con prior gaussiano; con $\lambda_{reg} > 0$ el problema siempre es invertible.

E2 · Modelo lineal (igual que OLS)

$$\hat{\mathbf{Y}} = \mathbf{X}\mathbf{W}$$

Se conserva el modelo y el predictor de OLS: cambia el criterio de estimación, no el modelo. El intercepto se incorpora con una columna de unos en $\mathbf{X}$ y habitualmente **no** se penaliza.

E2 · Función de costo: riesgo esperado regularizado

$$J_{\text{Ridge}}(\mathbf{W}) = \mathbb{E}_{(\mathbf{x},\mathbf{y})\sim p_{\text{datos}}}\left[\|\mathbf{y} - \mathbf{W}^\top \mathbf{x}\|_2^2\right] + \lambda_{reg}\|\mathbf{W}\|_F^2$$

El primer término es el riesgo de mínimos cuadrados; el segundo penaliza la magnitud global de los coeficientes. Con $\lambda_{reg} = 0$ se recupera OLS.

E2 · Aproximación empírica (muestras i.i.d.)

$$\widehat{J}_{\text{Ridge},N}(\mathbf{W}) = \frac{1}{N}\|\mathbf{Y} - \mathbf{X}\mathbf{W}\|_F^2 + \lambda_{reg}\|\mathbf{W}\|_F^2$$

Media muestral en notación matricial: $\|\mathbf{W}\|_F^2 = \sum_{p,k} W_{pk}^2$ suma los cuadrados de **todos** los coeficientes.

E2 · Problema de optimización

$$\widehat{\mathbf{W}}_{\text{Ridge}} \in \arg\min_{\mathbf{W}\in\mathbb{R}^{P\times\tau}} \widehat{J}_{\text{Ridge},N}(\mathbf{W})$$

El costo es estrictamente convexo para $\lambda_{reg} > 0$, así que el minimizador existe y es único.

E2 · Solución analítica exacta

$$\mathbf{X}^\top\mathbf{X}\widehat{\mathbf{W}} + N\lambda_{reg}\widehat{\mathbf{W}} = \mathbf{X}^\top\mathbf{Y}$$

$$\widehat{\mathbf{W}}_{\text{Ridge}} = \left(\mathbf{X}^\top\mathbf{X} + N\lambda_{reg}\mathbf{I}_P\right)^{-1}\mathbf{X}^\top\mathbf{Y}$$

Con el costo promediado aparece el factor N; si el ajuste se escribe como suma de cuadrados, la forma habitual es $(\mathbf{X}^\top\mathbf{X} + \lambda_{reg}\mathbf{I}_P)^{-1}\mathbf{X}^\top\mathbf{Y}$. Sumar $\lambda_{reg}\mathbf{I}_P$ desplaza todos los autovalores a $\mu_k + N\lambda_{reg} > 0$: la matriz es **siempre** invertible y los coeficientes quedan estables incluso con colinealidad, sin que ninguna dirección se anule.

Sesgo–varianza: OLS es insesgado y de varianza mínima dentro de su clase lineal; ridge acepta sesgo a cambio de menos varianza, y gana cuando $\mathbf{X}^\top\mathbf{X}$ está mal condicionada. **Frente a lasso:** reparte el peso entre variables correlacionadas y nunca produce un modelo esparso: un coeficiente puede quedar diminuto, pero no exactamente cero.

5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — Lasso (L1): penalización en valor absoluto

- Favorece soluciones **dispersas**: puede llevar coeficientes **exactamente a cero**.
- Es el estimador **MAP** con prior Laplace; λ_1 controla la intensidad de la regularización.

E2 · Modelo lineal (igual que OLS)

$$\hat{\mathbf{Y}} = \mathbf{X}\mathbf{W}$$

Como en OLS y ridge: la diferencia está en el criterio de estimación, no en el modelo. El intercepto se suele dejar fuera de la penalización.

E2 · Función de costo: riesgo esperado regularizado

$$J_{\text{Lasso}}(\mathbf{W}) = \mathbb{E}_{(\mathbf{x},\mathbf{y})\sim p_{\text{datos}}}\left[\|\mathbf{y} - \mathbf{W}^\top \mathbf{x}\|_2^2\right] + \lambda_1 \|\mathbf{W}\|_1$$

Cambia la norma: $\|\mathbf{W}\|_1 = \sum_{p=1}^{P}\sum_{k=1}^{\tau} |W_{pk}|$ en lugar de la suma de cuadrados. No es diferenciable en cero, y de ahí la esparsidad.

E2 · Aproximación empírica (muestras i.i.d.)

$$\widehat{J}_{\text{Lasso},N}(\mathbf{W}) = \frac{1}{N}\|\mathbf{Y} - \mathbf{X}\mathbf{W}\|_F^2 + \lambda_1 \|\mathbf{W}\|_1$$

Media muestral i.i.d. en notación matricial; la penalización es la suma de valores absolutos de los coeficientes. Con $\lambda_1 = 0$ se recupera OLS.

E2 · Problema de optimización

$$\widehat{\mathbf{W}}_{\text{Lasso}} \in \arg\min_{\mathbf{W}\in\mathbb{R}^{P\times\tau}} \widehat{J}_{\text{Lasso},N}(\mathbf{W})$$

Problema convexo pero no diferenciable en cero: no hay fórmula matricial cerrada general equivalente a las ecuaciones normales.

E2 · Solución: métodos numéricos

$$\arg\min_{\mathbf{W}} \left\{ \frac{1}{N}\|\mathbf{Y} - \mathbf{X}\mathbf{W}\|_F^2 + \lambda_1 \|\mathbf{W}\|_1 \right\} \quad \text{(sin forma cerrada general)}$$

La penalización ℓ_1 no es diferenciable en cero, así que no existe una fórmula matricial cerrada general equivalente a las ecuaciones normales. Se resuelve por **programación convexa**: descenso por coordenadas, métodos proximales o LARS.

Límites de lasso: con $P > N$ selecciona a lo sumo N variables y ante variables correlacionadas elige de forma inestable; la red elástica ($\ell_1 + \ell_2$) corrige ambos casos.

Tibshirani, JRSS-B 58(1), 1996 (lasso) · Hoerl & Kennard, Technometrics 12(1), 1970 (ridge) · Zou & Hastie, JRSS-B 67(2), 2005 (red elástica) · Hastie, Tibshirani & Friedman, ESL, 2.ª ed., 2009, cap. 3.

5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — Elastic Net: regularización $\ell_1 + \ell_2$

- Combina la **selección de variables** de Lasso con la **contracción** de Ridge.
- Con variables correlacionadas reparte el peso entre ellas, en lugar de elegir una al azar.

E2 · Modelo lineal (igual que OLS)

$$\hat{\mathbf{y}}_n = \mathbf{W}^\top \mathbf{x}_n, \qquad \hat{\mathbf{Y}} = \mathbf{X}\mathbf{W}$$

Se conserva el modelo y el predictor de OLS: Elastic Net cambia el criterio de estimación, no el modelo. El intercepto se suele dejar fuera de la penalización.

E2 · Función de costo: riesgo esperado regularizado

$$J_{\mathrm{EN}}(\mathbf{W}) = \mathbb{E}_{(\mathbf{x},\mathbf{y})\sim p_{\text{datos}}}\left[\|\mathbf{y} - \mathbf{W}^\top \mathbf{x}\|_2^2\right] + \lambda_1 \|\mathbf{W}\|_1 + \lambda_2 \|\mathbf{W}\|_F^2$$

El primer término mide el error esperado; $\lambda_1\|\mathbf{W}\|_1$ regulariza en L1 y $\lambda_2\|\mathbf{W}\|_F^2$ en L2. Con $\lambda_1 = 0$ se recupera Ridge y con $\lambda_2 = 0$, Lasso.

E2 · Aproximación empírica (muestras i.i.d.)

$$\widehat{J}_{\mathrm{EN},N}(\mathbf{W}) = \frac{1}{N}\|\mathbf{Y} - \mathbf{X}\mathbf{W}\|_F^2 + \lambda_1 \|\mathbf{W}\|_1 + \lambda_2 \|\mathbf{W}\|_F^2$$

Media muestral en notación matricial, con pesos independientes $\lambda_1 \geq 0$ y $\lambda_2 \geq 0$ para cada penalización.

E2 · Problema de optimización

$$\widehat{\mathbf{W}}_{\mathrm{EN}} \in \arg\min_{\mathbf{W}\in\mathbb{R}^{P\times\tau}} \widehat{J}_{\mathrm{EN},N}(\mathbf{W})$$

El objetivo es convexo; el término L1 lo vuelve no diferenciable en cero, y el minimizador puede tener coeficientes exactamente nulos.

E2 · Solución y propiedades

$$\lambda_1, \lambda_2 \geq 0, \qquad \lambda_2 > 0 \;\Rightarrow\; \widehat{J}_{\mathrm{EN},N} \text{ es estrictamente convexa}$$

No existe una solución matricial cerrada general análoga a la de Ridge: se resuelve con **descenso por coordenadas** o métodos proximales. Con $\lambda_2 > 0$ la solución es única, y el término L2 reparte el peso entre variables correlacionadas en lugar de seleccionar una al azar.

Cierre del bloque penalizado: OLS, MLE, Ridge, Lasso y Elastic Net comparten el esqueleto —ajuste más castigo— y se distinguen por el término que se suma; ese mismo esqueleto reaparece en $\mathcal{L}_{MSE} + \lambda_{phys}\mathcal{L}_{phys}$. **En el protocolo:** Ridge y Elastic Net comparten el espacio de búsqueda del peso de regularización, con la mezcla ρ_{en} como dimensión extra.

Zou & Hastie, JRSS-B 67(2), 301–320, 2005 · Hastie, Tibshirani & Friedman, The Elements of Statistical Learning, 2.ª ed., 2009, cap. 3.

5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — Gaussian Process Regression: modelo y optimización

- GPR define una **distribución sobre funciones**, no sólo coeficientes como OLS.
- Los **hiperparámetros** θ —longitud de escala, amplitud y varianza del ruido— se estiman por verosimilitud marginal negativa.

Entrada y salida

$$\mathbf{x}_n \in \mathbb{R}^P, \quad \mathbf{X} \in \mathbb{R}^{N\times P}, \qquad y_n \in \mathbb{R}, \qquad y_* \mid \mathbf{X}, \mathbf{y} \sim \mathcal{N}\left(\mu_*, \sigma_*^2\right)$$

Misma entrada tabular que la familia E2, pero la salida es una **distribución predictiva**: media μ_* y varianza σ_*^2 en el punto de prueba $\mathbf{x}_*$.

Modelo probabilístico

$$f \sim \mathcal{GP}(m_\theta, k_\theta), \qquad y_n = f(\mathbf{x}_n) + \varepsilon_n, \qquad \varepsilon_n \sim \mathcal{N}(0, \sigma_n^2)$$
$$\mathbf{K}_\theta \in \mathbb{R}^{N\times N}, \quad (\mathbf{K}_\theta)_{ij} = k_\theta(\mathbf{x}_i, \mathbf{x}_j), \qquad \mathbf{C} = \mathbf{K}_\theta + \sigma_n^2 \mathbf{I}_N$$

La **media** m_θ y el **kernel** k_θ definen la familia de funciones; $\mathbf{C}$ es la covarianza de las observaciones, con el ruido en la diagonal. Con $m_\theta = 0$ el modelo queda descrito por k_θ y σ_n^2.

Función de costo: riesgo predictivo esperado

$$J_{\mathrm{GPR}}(\theta) = \mathbb{E}_{(\mathbf{x}_*, y_*)}\left[(y_* - \mu_\theta(\mathbf{x}_*))^2 + \sigma_\theta^2(\mathbf{x}_*)\right]$$

El criterio predictivo castiga el error cuadrático **y** la incertidumbre declarada; no es el criterio con el que se entrena. El entrenamiento no minimiza este riesgo, sino la verosimilitud marginal negativa del bloque siguiente.

Verosimilitud marginal negativa

$$-\log p_\theta(\mathbf{y} \mid \mathbf{X}) = \underbrace{\tfrac{1}{2}\mathbf{y}^\top \mathbf{C}^{-1}\mathbf{y}}_{\text{ajuste}} + \underbrace{\tfrac{1}{2}\log\det \mathbf{C}}_{\text{complejidad}} + \underbrace{\tfrac{N}{2}\log 2\pi}_{\text{cte}}$$

El primer término mide el **ajuste** a los datos, el segundo penaliza la **complejidad** a través del determinante de la covarianza —evita que una longitud de escala diminuta pase por ajustar todo— y el tercero es una **constante** que no depende de θ.

Problema de optimización

$$\hat{\theta} \in \arg\min_{\theta\in\Theta} \left[-\log p_\theta(\mathbf{y} \mid \mathbf{X})\right]$$

Se estiman los hiperparámetros del kernel y del ruido por optimización derivable (gradiente) del criterio anterior, sin solución analítica cerrada. Los coeficientes no se estiman: se integran analíticamente.

Diferencia con OLS: OLS aprende un vector de coeficientes; GPR aprende una distribución sobre funciones y devuelve incertidumbre. **Relación con la física:** el kernel impone suavidad y estructura; un kernel físico convierte este modelo en la puerta ⑤ (kernel/GPR).

Rasmussen & Williams. Gaussian Processes for Machine Learning. MIT Press, 2006, caps. 2 y 5.

Williams & Rasmussen. Gaussian Processes for Regression. NeurIPS, 1996.

5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — GPR: predicción e incertidumbre

- La media predictiva hereda la estructura del kernel; la varianza predictiva **depende de la distancia a los datos**.
- Lejos de las observaciones la banda se ensancha y vuelve a la varianza previa $k_\theta(\mathbf{x}_*, \mathbf{x}_*)$.

Media predictiva

$$\mu_* = \mathbf{k}_*^\top \mathbf{C}^{-1}\mathbf{y}, \qquad \mathbf{k}_* = \left[k_\theta(\mathbf{x}_1, \mathbf{x}_*), \ldots, k_\theta(\mathbf{x}_N, \mathbf{x}_*)\right]^\top$$

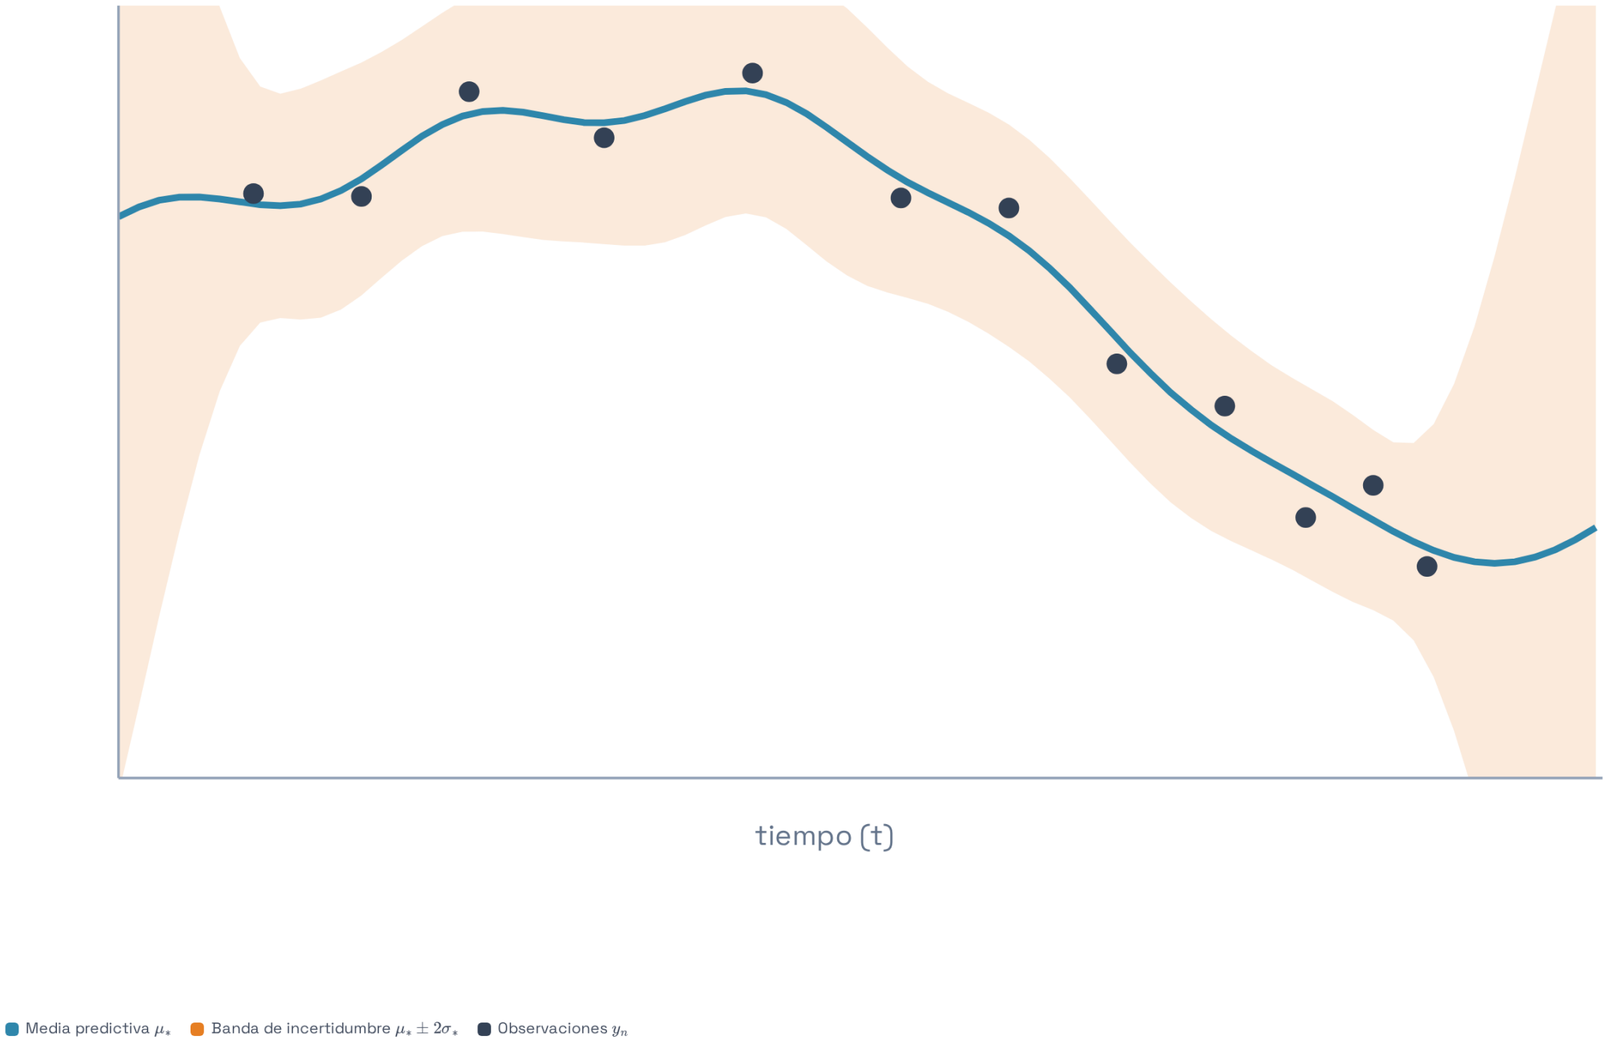
Es el mejor estimador puntual: combina las observaciones $\mathbf{y}$ ponderadas por la similitud $\mathbf{k}_*$ entre el punto de prueba y cada observación.

Varianza predictiva

$$\sigma_*^2 = k_\theta(\mathbf{x}_*, \mathbf{x}_*) - \mathbf{k}_*^\top \mathbf{C}^{-1}\mathbf{k}_*, \qquad \tilde{\sigma}_*^2 = \sigma_*^2 + \sigma_n^2$$

Mide la incertidumbre de la media; en un punto observado casi se anula. Para predecir una **observación** ruidosa se añade la varianza del ruido, $\tilde{\sigma}_*^2$.

Lectura: donde hay datos la banda se cierra; en los huecos se abre y la media vuelve a la previa. Esa varianza es la materia prima de la **UQ** y del criterio de adquisición en diseño experimental.



5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — DLinear: descomposición lineal y baseline obligatorio

- Separa la ventana en **tendencia** y **resto** con un promedio móvil.
- Proyecta cada componente con su propia capa lineal: dos proyecciones, no una.
- El protocolo del proyecto lo resuelve por mínimos cuadrados: determinista, sin semillas.

E2 · Descomposición de la ventana

$$x^{tend}[t] = \frac{1}{p_{ma}} \sum_{s=-\lfloor (p_{ma}-1)/2 \rfloor}^{\lfloor p_{ma}/2 \rfloor} x[t+s], \qquad x^{rem}[t] = x[t] - x^{tend}[t]$$

Conexión: p_{ma} es el período del promedio móvil (24 h en el protocolo) y los bordes se rellenan. La descomposición es la clásica tendencia más resto: x^{tend} captura el nivel lento y x^{rem} la estacionalidad y el ruido de alta frecuencia. Símbolos locales: p_{ma} (local: no es el momento $p(t)$ del MR), x^{tend}, x^{rem}, $\mathbf{W}_{tend}$, $\mathbf{W}_{rem}$.

E2 · El modelo: dos proyecciones lineales

$$\hat{\mathbf{y}}_{n+1:n+\tau} = \mathbf{W}_{tend}\,\mathbf{x}_n^{tend} + \mathbf{b}_{tend} + \mathbf{W}_{rem}\,\mathbf{x}_n^{rem} + \mathbf{b}_{rem}, \qquad \mathbf{W}_{tend}, \mathbf{W}_{rem} \in \mathbb{R}^{\tau \times L}$$

Conexión: cada componente de la ventana histórica de longitud L tiene su propia proyección $\mathbb{R}^L \to \mathbb{R}^\tau$. Los pesos son bloques de θ: $\theta = \{\mathbf{W}_{tend}, \mathbf{b}_{tend}, \mathbf{W}_{rem}, \mathbf{b}_{rem}\}$. La tendencia y el resto se proyectan al mismo horizonte futuro y se suman.

E2 · El ajuste: mínimos cuadrados directos

$$\hat{\theta} = \arg\min_{\theta} \; \|\mathbf{Y} - \hat{\mathbf{Y}}(\theta)\|_F^2$$

Conexión: el artículo original entrena con descenso de gradiente; el protocolo del proyecto resuelve cada proyección con **mínimos cuadrados cerrados** (SVD y pseudo-inversa), que es la solución exacta del problema cuadrático. De ahí dos consecuencias: es **determinista** —sin semillas ni épocas— y es la cota lineal moderna del benchmark. $\|\cdot\|_F$ es la norma de Frobenius.

Por qué está en el deck: es el baseline obligatorio: ningún modelo nuevo se reporta sin superarlo. **Su tesis:** un modelo lineal bien descompuesto iguala o supera a los Transformers en LTSF. **Contraste:** extrapola (es lineal) y es determinista; no modela interacciones no lineales.

Referencias: Zeng, Chen, Zhang & Xu, Are Transformers Effective for Time Series Forecasting?, AAAI 2023 · protocolo interno del benchmark de regresión (§1, Tabla A).

5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — SVR: pérdida ε_{svr}-insensible y margen máximo

- **Entrada/salida:** predictor sobre $\mathbf{x}_n \in \mathbb{R}^P$; la formulación mostrada es escalar ($\tau = 1$). Para $\tau > 1$ se requiere estrategia multi-salida explícita.
- No penaliza todo error: sólo el que excede un tubo de tolerancia ε_{svr}.
- Margen y violaciones conviven en un problema **convexo**; el dual sólo necesita productos internos, de ahí el truco del kernel.

E2 · El modelo y la pérdida ε_{svr}-insensible

$$f_\theta(\mathbf{x}) = \langle \theta, \varphi(\mathbf{x}) \rangle, \qquad \ell_{\varepsilon_{svr}}\big(y_i, f_\theta(\mathbf{x}_i)\big) = \max\left(0,\ |y_i - f_\theta(\mathbf{x}_i)| - \varepsilon_{svr}\right)$$

Conexión: $\varphi(\mathbf{x})$ es el mapa al espacio de características y ε_{svr} el radio del tubo: los errores menores que ε_{svr} no cuestan nada, así que es robusto al ruido pequeño —a diferencia del residuo cuadrático de $\mathcal{L}_{MSE}$—. Símbolos locales: φ, $\xi_i^{(*)}$, $\alpha_i^{(*)}$.

E2 · El problema de optimización (primal)

$$\min_{\theta,\, \boldsymbol{\xi},\, \boldsymbol{\xi}^*} \ \frac{1}{2}\|\theta\|_2^2 + \lambda_{svr} \sum_{i=1}^{N} (\xi_i + \xi_i^*) \quad \text{s.a. } |y_i - f_\theta(\mathbf{x}_i)| \le \varepsilon_{svr} + \xi_i^{(*)}, \quad \xi_i^{(*)} \ge 0$$

Conexión: $\xi_i^{(*)}$ son las holguras por debajo y por encima del tubo. El objetivo minimiza dos cosas a la vez: la norma $\|\theta\|_2^2$ —el **margen**, que controla la capacidad— y la suma de violaciones. λ_{svr} pesa el error frente al margen, con el mismo papel que λ_{reg} en ridge y lasso. Es un primal **convexo**: el óptimo es único.

E2 · El dual y el truco del kernel

$$\hat{f}_\theta(\mathbf{x}) = \sum_{i=1}^{N} (\alpha_i - \alpha_i^*)\kappa(\mathbf{x}, \mathbf{x}_i), \qquad \kappa(\mathbf{x}, \mathbf{x}_i) = \langle \varphi(\mathbf{x}), \varphi(\mathbf{x}_i) \rangle, \qquad 0 \le \alpha_i^{(*)} \le \lambda_{svr}$$

Conexión: el dual sólo usa productos internos κ, así que φ nunca se calcula explícitamente: ése es el **truco del kernel**. Se cumple $\alpha_i^{(*)} = 0$ para los puntos dentro del tubo; sólo los que lo violan —los **vectores de soporte**— definen la solución.

Idea central: SVR no minimiza el error cuadrático; minimiza margen más violaciones del tubo. **Puente:** es el mismo esqueleto ajuste más castigo de OLS, ridge y lasso, con la pérdida ε_{svr}-insensible. **Contraste:** es programación cuadrática, no una ecuación normal: no hay forma cerrada general.

Referencias: Vapnik, The Nature of Statistical Learning Theory, 2.ª ed., 2000 · Smola & Schölkopf, Statistics and Computing 14, 199–222, 2004 · Hastie, Tibshirani & Friedman, The Elements of Statistical Learning, 2.ª ed., 2009, cap. 12.

5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — Árbol de regresión (CART): partición recursiva

- **Entrada:** características tabulares $\mathbf{x}_n \in \mathbb{R}^P$; esta ecuación muestra una salida escalar ($\tau = 1$).
- No supone linealidad: aproxima f con **cajas** del espacio de entrada; dentro de cada hoja predice la media de sus muestras.
- Para $\tau > 1$, la implementación debe especificar salida vectorial o un predictor por horizonte; no se presume equivalencia.
- Buscar el árbol óptimo es NP-duro; en la práctica se crece **greedy** y se poda.

E2 · El modelo: función escalón sobre una partición

$$\hat{y}(\mathbf{x}) = \sum_{j=1}^{J_{arb}} c_j \, \mathbb{1}[\mathbf{x} \in R_j], \qquad c_j = \frac{1}{|R_j|} \sum_{\mathbf{x}_i \in R_j} y_i$$

Conexión: R_j es la caja (región) de la hoja j, J_{arb} el número de hojas (local: no son los modos J de la familia E8) y c_j la **media** de las muestras que caen en ella (local: no es el término constante c del SARIMA). La predicción es una función escalón: constante por caja y discontinua en los cortes. Símbolos locales de esta slide: J_{arb}, R_j, c_j, k, s; i sigue siendo el índice de muestra y nunca tiempo.

E2 · El criterio del split (búsqueda greedy)

$$\min_{k,\,s} \left[\min_{c_1} \sum_{\mathbf{x}_i \in R_1(k,s)} (y_i - c_1)^2 + \min_{c_2} \sum_{\mathbf{x}_i \in R_2(k,s)} (y_i - c_2)^2 \right]$$

Conexión: k es la variable (un rezago) y s el umbral del corte que parte el nodo en $R_1(k,s)$ y $R_2(k,s)$. El criterio es la **suma de cuadrados intra-hoja**, equivalente a maximizar la suma de cuadrados entre los dos grupos: en cada paso se busca el par (k, s) que más reduce el error de ajuste, con las medias c_1, c_2 recalculadas. Optimizar la partición completa es **NP-duro** y el árbol **no extrapola**: su predicción queda dentro del rango de y de sus hojas.

Sesgo–varianza: un árbol profundo tiene varianza alta y sesgo bajo; uno poco profundo, lo contrario. Ése es el compromiso que atacan los dos ensambles siguientes: **bagging** para la varianza y **boosting** para el sesgo. El árbol es determinista; lo estocástico llega con los ensambles.

Referencias: Breiman, Friedman, Olshen & Stone, Classification and Regression Trees, 1984 · Hastie, Tibshirani & Friedman, The Elements of Statistical Learning, 2.ª ed., 2009, cap. 9.

5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — Random Forest: bagging sobre árboles

- Promedia M_{arb} árboles entrenados sobre **muestras bootstrap**.
- Cada split considera sólo m_{try} variables al azar: así baja la correlación entre árboles.
- No reduce el sesgo del árbol base: su objetivo es la **varianza**.

E2 · El modelo: promedio de árboles bootstrap

$$\hat{y}(\mathbf{x}) = \frac{1}{M_{arb}} \sum_{m=1}^{M_{arb}} T_m(\mathbf{x}), \qquad T_m \sim \text{bootstrap}\,(\mathbf{X}, N) \quad \text{con } m_{try} \text{ variables por split}$$

Conexión: cada T_m es un árbol CART completo, entrenado sobre una **remuestra con reemplazo** de las N filas de $\mathbf{X}$ (bootstrap) y decidido con sólo m_{try} variables candidatas en cada split (en regresión, típicamente $d/3$). El promedio reduce la varianza sin cambiar la forma del modelo por árbol. Símbolos locales: M_{arb}, T_m, m_{try}, ρ_{arb} (local: no es el ancho espectral ρ_k), σ^2_{arb}.

E2 · Por qué promediar reduce la varianza

$$\text{Var}\left(\hat{y}(\mathbf{x})\right) = \rho_{arb}\,\sigma^2_{arb} + \frac{1-\rho_{arb}}{M_{arb}}\,\sigma^2_{arb}$$

Conexión: si cada árbol tiene varianza σ^2_{arb} y la correlación media entre pares es ρ_{arb}, el promedio elimina **sólo** la parte no correlacionada: el segundo término desaparece con $M_{arb} \to \infty$, pero el primero se queda. De ahí el **piso** $\rho_{arb}\sigma^2_{arb}$ y el papel de m_{try}: bajar ρ_{arb} a cambio de algo de sesgo.

Bagging frente a boosting: el bosque promedia en paralelo para bajar varianza; el boosting suma en serie para bajar sesgo. **Multi-salida:** el criterio del split puede sumar el RSS de las τ componentes, así que un solo bosque predice todo el horizonte. **Protocolo:** `n_estimators` en 200/500/1000 y `max_depth` en None/8/16/32; al ser estocástico, se reporta media y desviación sobre semillas.

Referencias: Breiman, Machine Learning 45(1), 5–32, 2001 · Hastie, Tibshirani & Friedman, The Elements of Statistical Learning, 2.ª ed., 2009, cap. 15.

5A · MATEMÁTICA DEL DIAGRAMA 3

E2 — Gradient Boosting (XGBoost): ajustar el residuo

- **Salida:** la formulación escalar se interpreta por salida ($\tau = 1$); el caso multi-horizonte requiere una estrategia vectorial o modelos separados.
- Construye el modelo **aditivamente**: cada árbol corrige lo que dejó el anterior.
- Cada T_m ajusta el **gradiente negativo** de la pérdida, no y directamente.

E2 · El modelo aditivo y los pseudo-residuos

$$F_0(\mathbf{x}) = \bar{y}, \qquad F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \nu\, T_m(\mathbf{x}), \qquad r_{im} = -\frac{\partial \ell\left(y_i, F(\mathbf{x}_i)\right)}{\partial F(\mathbf{x}_i)}\bigg|_{F=F_{m-1}} = y_i - F_{m-1}(\mathbf{x}_i)$$

Conexión: el ensamble arranca en la media $\bar{y}$ y cada paso suma un árbol escalado por el **shrinkage** $\nu \in (0, 1]$. r_{im} es el **pseudo-residuo**: el gradiente negativo de la pérdida por muestra, evaluado en el modelo anterior.

E2 · El objetivo del ensamble y su aproximación por iteración

$$\mathcal{L}\left(F\right) = \sum_{i=1}^{N} \ell\left(y_i, F(\mathbf{x}_i)\right) + \sum_{m=1}^{M_{arb}} \Omega\left(T_m\right), \qquad \text{Obj}^{(m)} = \sum_{i=1}^{N} \left[g_i\, T_m(\mathbf{x}_i) + \frac{1}{2}\, \eta_i\, T_m(\mathbf{x}_i)^2 \right] + \Omega\left(T_m\right)$$

Conexión: el objetivo global es pérdida de datos **más** castigo por complejidad de cada árbol. Como minimizar $\mathcal{L}$ directamente es intratable, XGBoost expande $\mathcal{L}$ a **segundo orden** alrededor de F_{m-1} y minimiza $\text{Obj}^{(m)}$, con g_i el gradiente y η_i la curvatura (segunda derivada) por muestra. Símbolo local: η_i es curvatura por muestra y no representa el horizonte τ.

E2 · Peso óptimo de hoja y ganancia del split

$$\Omega\left(T\right) = \gamma_{arb}\, J_{arb} + \frac{1}{2}\, \lambda_{arb} \sum_{j=1}^{J_{arb}} w_j^2, \qquad w_j^* = -\frac{G_j}{E_j + \lambda_{arb}}$$

Conexión: con $G_j = \sum_{i \in R_j} g_i$ y $E_j = \sum_{i \in R_j} \eta_i$ (sumas de gradiente y curvatura en la hoja), el peso óptimo sale **cerrado**: w_j^* es el paso de Newton regularizado y λ_{arb} lo encoge. La **ganancia** del split se mide con esos mismos términos y γ_{arb} exige un mínimo para crear la hoja: es una poda automática. λ_{arb} y γ_{arb} son locales.

Contraste: el bosque reduce **varianza** promediando en paralelo; el boosting reduce **sesgo** sumando en serie, y puede sobreajustar: lo controlan ν, M_{arb} y la parada temprana. **LightGBM** cambia la implementación, no la matemática. **Sin extrapolación:** sus hojas son constantes.

5A · MATEMÁTICA DEL DIAGRAMA 3

E3 — RNN simple: estado oculto recurrente

- Base de la familia recurrente: un solo estado oculto $\mathbf{h}[t]$ que resume el pasado.
- LSTM y GRU cambian la arquitectura interna de f_θ; la formulación del aprendizaje es la misma.

Entrada y salida de secuencias

$$\mathbf{X}_n = (\mathbf{x}[1], \ldots, \mathbf{x}[T]) \in \mathbb{R}^{T \times P}, \qquad \mathbf{y}_n \in \mathbb{R}^{\tau}, \qquad \hat{\mathbf{y}}_n = f_\theta(\mathbf{X}_n)$$

T es el número de pasos de la secuencia de entrada —la ventana de longitud L de la página de forecasting—, P las características por paso y τ el horizonte. t indexa el tiempo dentro de la secuencia y n la muestra: no son el mismo eje.

Modelo recurrente: actualización del estado oculto

$$\mathbf{h}[t] = \varphi(\mathbf{W}_h \mathbf{x}[t] + \mathbf{U}_h \mathbf{h}[t-1] + \mathbf{b}_h), \qquad \mathbf{h}[0] = \mathbf{0}$$
$$\hat{\mathbf{y}}_n = \mathbf{W}_{out} \mathbf{h}[T] + \mathbf{b}_{out} = f_\theta(\mathbf{X}_n)$$

φ es una no linealidad (por ejemplo $\tanh$) y $\mathbf{h}[t] \in \mathbb{R}^H$. Todos los pesos y sesgos entrenables se agrupan en $\theta = \{\mathbf{W}_h, \mathbf{U}_h, \mathbf{b}_h, \mathbf{W}_{out}, \mathbf{b}_{out}\}$.

Función de costo: riesgo esperado

$$J(\theta) = \mathbb{E}_{(\mathbf{X},\mathbf{y}) \sim p_{\text{datos}}} \left[\|\mathbf{y} - f_\theta(\mathbf{X})\|_2^2 \right]$$

Misma forma que en OLS y la familia penalizada: el objeto es el riesgo esperado del error de pronóstico.

Aproximación empírica

$$\widehat{J}_N(\theta) = \frac{1}{N} \sum_{n=1}^{N} \|\mathbf{y}_n - f_\theta(\mathbf{X}_n)\|_2^2$$

Promedio sobre las N ventanas de entrenamiento. Si las ventanas se solapan **no son independientes**: el promedio es una aproximación práctica, no una esperanza bajo muestras i.i.d.

Problema de optimización

$$\hat{\theta} \in \arg\min_\theta \widehat{J}_N(\theta)$$

Se entrena con **BPTT** y optimizadores basados en gradientes (SGD, Adam); no existe solución analítica cerrada general. El gradiente atraviesa la recurrencia paso a paso, de ahí el desvanecimiento.

Común a la familia: RNN, LSTM y GRU comparten $J(\theta)$, $\widehat{J}_N(\theta)$ y $\hat{\theta} \in \arg\min$; sólo cambia la arquitectura interna de f_θ. Las páginas siguientes detallan esa parte interna y conservan esta misma formulación.

5A · MATEMÁTICA DEL DIAGRAMA 3

E3 — LSTM: memoria celular y compuertas

- La LSTM mantiene dos estados: memoria celular $\mathbf{c}[t]$ y estado oculto $\mathbf{h}[t]$.
- Las compuertas de olvido, entrada y salida controlan qué información conserva, incorpora y expone en cada paso.

Compuertas de olvido y entrada

$$\mathbf{f}[t] = \sigma(\mathbf{W}_f \mathbf{x}[t] + \mathbf{U}_f \mathbf{h}[t-1] + \mathbf{b}_f)$$
$$\mathbf{i}[t] = \sigma(\mathbf{W}_i \mathbf{x}[t] + \mathbf{U}_i \mathbf{h}[t-1] + \mathbf{b}_i)$$

Cada compuerta evalúa la entrada actual y el estado oculto anterior; σ es la sigmoide. $\mathbf{x}[t] \in \mathbb{R}^P$ es el paso t de la secuencia $\mathbf{X}_n$.

Candidato y actualización de la memoria celular

$$\tilde{\mathbf{c}}[t] = \tanh(\mathbf{W}_c \mathbf{x}[t] + \mathbf{U}_c \mathbf{h}[t-1] + \mathbf{b}_c)$$
$$\mathbf{c}[t] = \mathbf{f}[t] \odot \mathbf{c}[t-1] + \mathbf{i}[t] \odot \tilde{\mathbf{c}}[t]$$

La ruta de memoria $\mathbf{c}[t]$ conserva información a través de muchos pasos: la compuerta de olvido decide qué se descarta y la de entrada qué se incorpora. $\odot$ es el producto elemento a elemento.

Compuerta de salida y estado expuesto

$$\mathbf{o}[t] = \sigma(\mathbf{W}_o \mathbf{x}[t] + \mathbf{U}_o \mathbf{h}[t-1] + \mathbf{b}_o), \qquad \mathbf{h}[t] = \mathbf{o}[t] \odot \tanh(\mathbf{c}[t])$$

El estado expuesto $\mathbf{h}[t]$ es lo que lee la capa de salida: $\hat{\mathbf{y}}_n = \mathbf{W}_{out}\mathbf{h}[T] + \mathbf{b}_{out}$, igual que en la página de la RNN.

Función de costo y aproximación empírica

$$J(\theta) = \mathbb{E}_{(\mathbf{X},\mathbf{y})\sim p_{\text{datos}}}\left[\|\mathbf{y} - f_\theta(\mathbf{X})\|_2^2\right]$$
$$\widehat{J}_N(\theta) = \frac{1}{N}\sum_{n=1}^{N} \|\mathbf{y}_n - f_\theta(\mathbf{X}_n)\|_2^2$$

Mismo riesgo que en la RNN; θ reúne ahora $\mathbf{W}_{(\cdot)}, \mathbf{U}_{(\cdot)}, \mathbf{b}_{(\cdot)}$ de las tres compuertas y el candidato. Con ventanas solapadas el promedio no es una esperanza bajo muestras i.i.d.

Problema de optimización

$$\hat{\theta} \in \arg\min_{\theta} \widehat{J}_N(\theta)$$

Entrenamiento por **BPTT** con optimizadores basados en gradientes. La memoria celular atenúa el desvanecimiento del gradiente, pero no hay solución analítica cerrada general.

5A · MATEMÁTICA DEL DIAGRAMA 3

E3 — GRU: actualización y reinicio del estado

- La GRU mantiene un solo estado oculto; combina memoria y representación sin una celda separada.
- La actualización mezcla el estado anterior con un candidato, mientras el reinicio regula qué pasado entra en ese candidato.

Compuertas de actualización y reinicio

$$\mathbf{u}[t] = \sigma(\mathbf{W}_u \mathbf{x}[t] + \mathbf{U}_u \mathbf{h}[t-1] + \mathbf{b}_u)$$
$$\mathbf{r}[t] = \sigma(\mathbf{W}_r \mathbf{x}[t] + \mathbf{U}_r \mathbf{h}[t-1] + \mathbf{b}_r)$$

La compuerta de actualización $\mathbf{u}[t]$ decide cuánto estado nuevo entra; la de reinicio $\mathbf{r}[t]$ decide cuánto pasado se usa para proponerlo. La notación $\mathbf{u}[t]$ evita la colisión con el embedding espectral.

Estado candidato

$$\tilde{\mathbf{h}}[t] = \tanh(\mathbf{W}_h \mathbf{x}[t] + \mathbf{U}_h (\mathbf{r}[t] \odot \mathbf{h}[t-1]) + \mathbf{b}_h)$$

El reinicio modula el estado previo **antes** de combinarlo con la entrada actual: es la diferencia de fondo con la LSTM, que usa una memoria celular aparte.

Actualización del estado oculto

$$\mathbf{h}[t] = (1 - \mathbf{u}[t]) \odot \mathbf{h}[t-1] + \mathbf{u}[t] \odot \tilde{\mathbf{h}}[t]$$

Con la convención de esta diapositiva, $\mathbf{u}[t]$ pondera el candidato y $1 - \mathbf{u}[t]$ conserva el estado anterior; algunas referencias intercambian los factores. La capa de salida es la misma de la RNN: $\hat{\mathbf{y}}_n = \mathbf{W}_{out}\mathbf{h}[T] + \mathbf{b}_{out}$.

Función de costo y aproximación empírica

$$J(\theta) = \mathbb{E}_{(\mathbf{X},\mathbf{y})\sim p_{\text{datos}}}\left[\|\mathbf{y} - f_\theta(\mathbf{X})\|_2^2\right]$$
$$\widehat{J}_N(\theta) = \frac{1}{N}\sum_{n=1}^{N} \|\mathbf{y}_n - f_\theta(\mathbf{X}_n)\|_2^2$$

Idéntico al de la LSTM: θ contiene los pesos y sesgos de las dos compuertas, del candidato y de la salida. Con ventanas solapadas el promedio no es una esperanza bajo muestras i.i.d.

Problema de optimización

$$\hat{\theta} \in \arg\min_{\theta} \widehat{J}_N(\theta)$$

También por **BPTT** con optimizadores basados en gradientes: menos parámetros que la LSTM, misma ausencia de solución cerrada.

RNN, LSTM y GRU: de la ventana histórica al horizonte

- La ventana $L = T$ fija cuántos pasos pasados recibe la red; el horizonte τ fija cuántas salidas futuras produce. No son el mismo eje.
- Las tres arquitecturas comparten entrada, salida, costo y optimización: sólo cambia la celda interna de f_θ.

Entrada secuencial y estado recurrente

$$\mathbf{X}_n^{win} = (\mathbf{x}[n-L+1], \ldots, \mathbf{x}[n]) \in \mathbb{R}^{T \times P}, \quad T = L, \qquad \mathbf{h}[t] = g_\theta(\mathbf{x}[t], \mathbf{h}[t-1])$$

L es la longitud de ventana, T el número de pasos de la secuencia de entrada y H la dimensión del estado oculto; ninguno representa el horizonte τ. Las compuertas de LSTM y GRU definen el operador g_θ.

Lectura del estado y salida multi-paso

$$\hat{\mathbf{Y}}_{n+1:n+\tau} = \text{reshape}_{\tau \times Q}(\mathbf{W}_{out}\mathbf{h}[n] + \mathbf{b}_{out}) \in \mathbb{R}^{\tau \times Q}$$

La cabeza de salida puede ser una proyección directa o un decodificador autoregresivo; aquí se muestra la proyección directa, con $\mathbf{W}_{out} \in \mathbb{R}^{(\tau Q) \times H}$. Q es el número de variables objetivo y H la dimensión del estado oculto; para una variable, $Q = 1$.

Comparación: misma formulación, distinta celda

$$J(\theta) = \mathbb{E}\left[\|\mathbf{y} - f_\theta(\mathbf{X})\|_2^2\right], \qquad \hat{\theta} \in \arg\min_\theta \widehat{J}_N(\theta), \qquad f_\theta \in \{\text{RNN}, \text{LSTM}, \text{GRU}\}$$

Las tres comparten riesgo, promedio empírico y optimización; la diferencia está dentro de la celda: un estado recurrente, tres compuertas con celda, o dos compuertas. θ reúne los pesos y sesgos de cada celda y de $\mathbf{W}_{out}$, más los de cada capa cuando hay L_{cap} capas.

Común a la familia: RNN, LSTM y GRU comparten $J(\theta)$, $\widehat{J}_N(\theta)$ y $\hat{\theta} \in \arg\min$; se entrenan por **BPTT** con optimizadores de gradiente y no tienen solución analítica cerrada. Con ventanas solapadas, el promedio no es una esperanza bajo muestras i.i.d.

5A · MATEMÁTICA DEL DIAGRAMA 3

E4 — Convolucionales/TCN · E5 — Transformers LTSF

E4 · Convolución causal dilatada (campo receptivo exponencial en $\breve{d}$)

$$(\mathbf{s} *_{\breve{d}} \mathbf{f})[t] = \sum_{i=0}^{\breve{k}-1} f[i]\, s[t - \breve{d}\, i]$$

Conexión: "CNN, TCN, híbridos CNN-LSTM" ↔ la convolución dilatada compuesta con una recurrencia E3; el TSB del artículo guía es un bloque TCN (residual + GELU + LN).

E5 · Atención escalada y multi-cabeza

$$\mathrm{Att}(\mathbf{Q},\mathbf{K},\mathbf{V}) = \mathrm{softmax}\!\left(\frac{\mathbf{Q}\mathbf{K}^{\top}}{\sqrt{d_k}}\right)\mathbf{V}, \qquad \mathrm{MHA}(\mathbf{X}) = \mathrm{Concat}(\mathrm{head}_1,\ldots,\mathrm{head}_{n_{cab}})\,\mathbf{W}^{O}$$

Conexión: "TFT, Informer, PatchTST, iTransformer, TimeXer" ↔ variantes de Att con distinta tokenización; PatchTST trocea cada canal en parches (channel-independence).

5A · MATEMÁTICA DEL DIAGRAMA 3

E6 — SSM/Mamba · E7 — Fundacionales · E8 — Descomposición

E6 · Espacio de estados continuo y discretización (recurrencia lineal)

$$\mathbf{h}'(t) = \mathbf{A}\,\mathbf{h}(t) + \mathbf{B}\,x(t), \qquad y(t) = \mathbf{C}\,\mathbf{h}(t)$$

Discretización → recurrencia $\mathbf{h}[t] = \bar{\mathbf{A}}\,\mathbf{h}[t-1] + \bar{\mathbf{B}}\,x[t]$; Mamba (selective scan) vuelve los parámetros dependientes de la entrada: $\mathcal{O}(\tau)$ frente al $\mathcal{O}(\tau^2)$ de la atención.

E7 · Distribución predictiva pre-entrenada (zero/few-shot)

$$p_\theta\left(\mathbf{y}_{T+1:T+\tau} \mid \mathbf{X}^{win}_{T-L+1:T}\right) \quad \text{con } \theta \text{ fijado en pre-entrenamiento masivo externo}$$

Conexión: "zero/few-shot" ↔ evaluar p_θ sin re-entrenar θ (Chronos tokeniza valores; TimesFM parches; Moirai any-variate).

E8 · Descomposición (EMD: IMFs + residuo) y VMD variacional

$$y(t) = \sum_{j=1}^{J} c_j(t) + r(t)$$

Conexión: "VMD/EMD/CEEMDAN + red profunda" ↔ $\hat{c}_j = g_{\theta_j}(\mathbf{X}_j)$ por componente y $\hat{y} = \sum_j \hat{c}_j + \hat{r}$; la descomposición se implementa sobre la serie muestreada $y[t]$; preprocesamiento externo.

E8 · Problema variacional de la VMD

$$\min_{\{u_j\},\{\omega_j\}} \sum_{j=1}^{J} \left\| \partial_t \left[\left(\delta(t) + \frac{i}{\pi t}\right) * u_j(t) \right] e^{-i\omega_j t} \right\|_2^2 \qquad \text{s.a.} \sum_{j=1}^{J} u_j(t) = y(t)$$

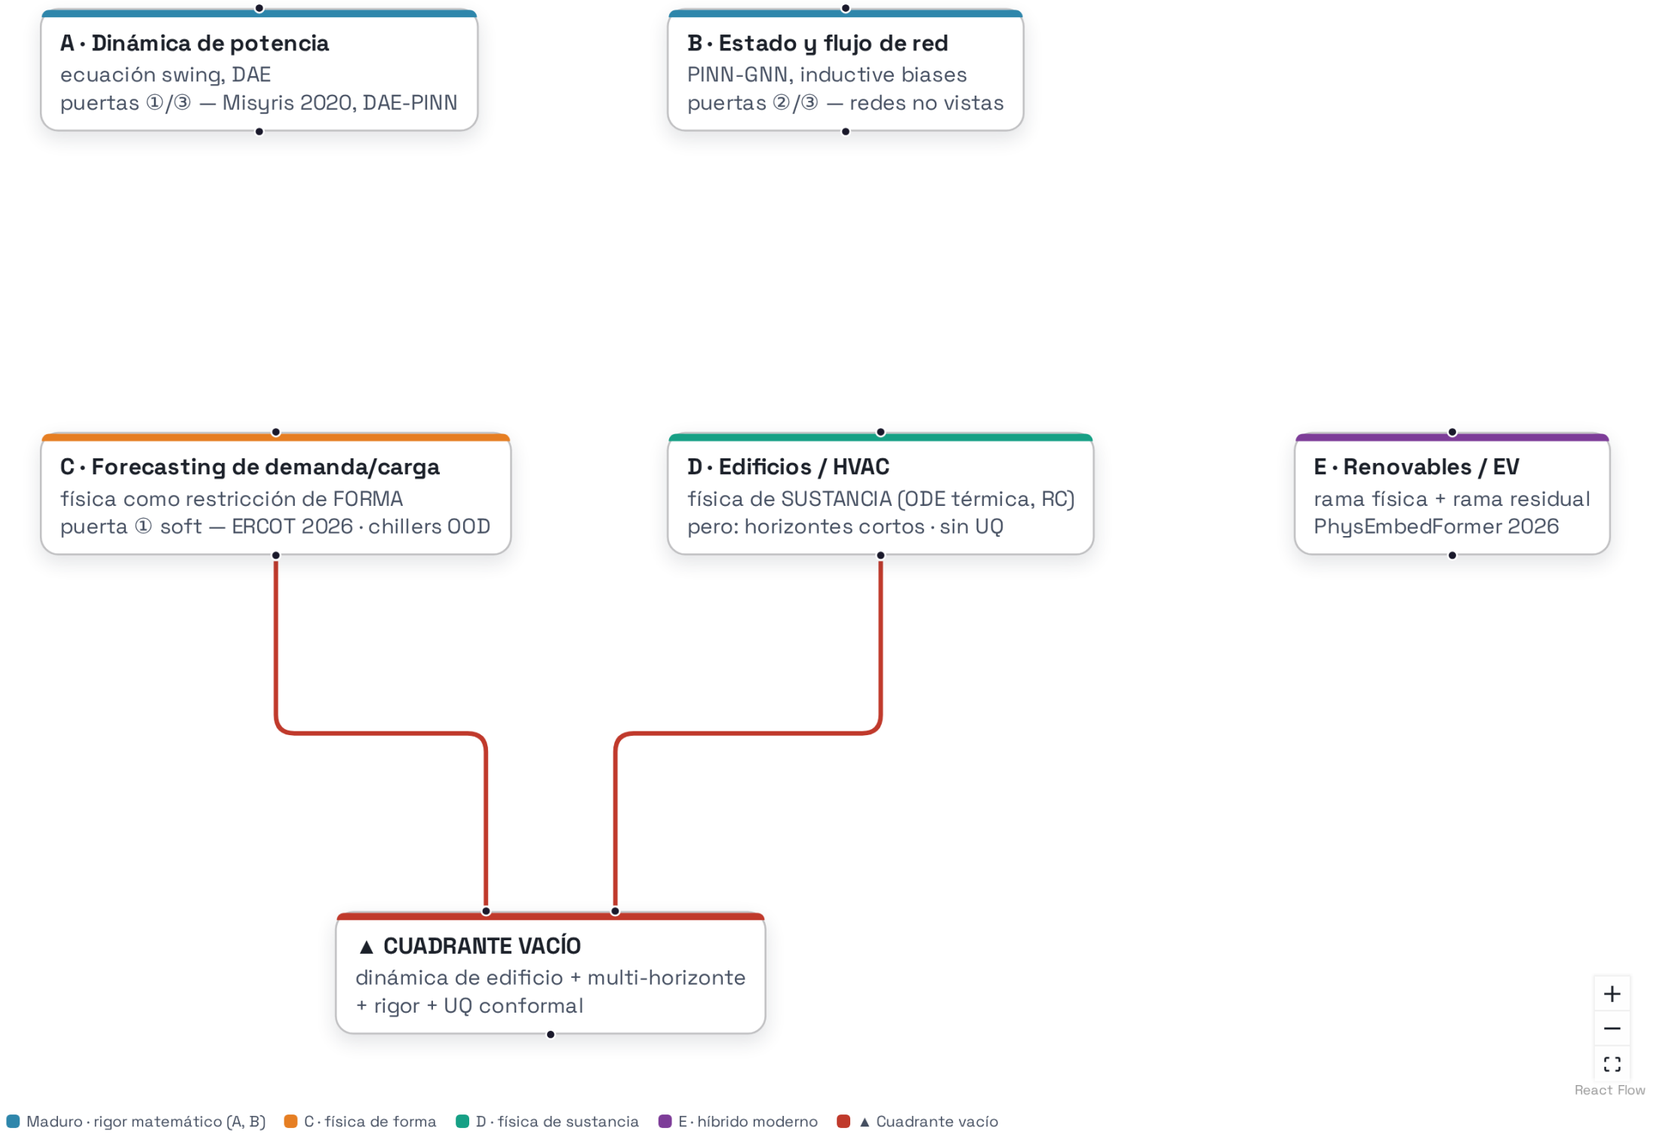
5B · DIAGRAMA 4

La intersección: TS + física en sistemas energéticos

- Dónde se cruzan las familias E1–E8 con las puertas ①–④: cinco patrones (A–E).
- **A** Dinámica de potencia (swing) · **B** Flujo de red · **C** Demanda (física de forma) · **D** Edificios (RC) · **E** Renovables (física + residual).
- **El cuadrante "dinámica de edificio + multi-horizonte + rigor + UQ conformal" está VACÍO.**

Misyris et al., IEEE PES GM 2020 (A) · Huang & Wang, IEEE TPS 38(1), 2023 (review A) · Tang et al., E&B 2026, DOI: 10.1016/j.enbuild.2026.117299 (C) · Loffa et al., ACM e-Energy 2025 (D) · PhysEmbedFormer, Sci. Reports 2026 (E).

Diagrama 4 · Dónde TS ∩ física ∩ energía se cruzan



5B · MATEMÁTICA DEL DIAGRAMA 4

Patrón A — Dinámica de potencia · Patrón B — Flujo de red

A · Ecuación de oscilación del generador síncrono

$$\dot{\delta}(t) = \omega(t) - \omega_s, \qquad M\,\dot{\omega}(t) = P_m - P_e(\delta) - D\left(\omega(t) - \omega_s\right)$$

Conexión: puerta ① — la PINN (Misyris 2020) penaliza el residuo $r_\theta(t)$ (ecuación siguiente); en modo inverso estima M y D; DAE-PINN añade $0 = g(\mathbf{x}_{dif}, \mathbf{y}_{alg})$.

A · Residuo físico sobre la trayectoria estimada

$$r_\theta(t) = M\,\frac{d\hat{\omega}(t)}{dt} - \left[P_m - P_e(\hat{\delta}) - D\left(\hat{\omega} - \omega_s\right)\right]$$

B · Ecuaciones nodales de flujo de potencia

$$P_i = \sum_{j=1}^{N_{bus}} |V_i||V_j|\left(G_{ij}\cos\theta_{ij} + B_{ij}\sin\theta_{ij}\right), \qquad Q_i = \sum_{j=1}^{N_{bus}} |V_i||V_j|\left(G_{ij}\sin\theta_{ij} - B_{ij}\cos\theta_{ij}\right)$$

Conexión: "voltajes, ángulos" ↔ $(|V_i|, \theta_i)$; las PINN-GNN usan el residuo de estas ecuaciones sobre el grafo de admitancias (puertas ②+①), con biases que generalizan a redes no vistas.

5B · MATEMÁTICA DEL DIAGRAMA 4

Patrón C — Demanda: física como restricción de forma

- No hay EDO del activo: la física entra como **regularizadores cualitativos** sobre $\hat{\mathbf{y}} \in \mathbb{R}^{\tau}$ (puerta ①, o ② si se cablea).

Penalización de rampas y de parabolicidad (ERCOT 2026)

$$\mathcal{L}_{rampa} = \sum_{j=1}^{\tau-1} \max\big(0,\ |\hat{y}[j+1] - \hat{y}[j]| - r_{max}\big), \qquad \mathcal{L}_{par} = \sum_{j=2}^{\tau-1} \big(\hat{y}[j-1] - 2\hat{y}[j] + \hat{y}[j+1]\big)^2$$

Conexión: "loss parabólica/ramp" ↔ $\mathcal{L}_{par}$, $\mathcal{L}_{rampa}$; monotonía para chillers (Tang 2026): $\frac{\partial \hat{y}}{\partial x_m} \geq 0$ penalizada con $\mathcal{L}_{mono}$.

Pérdida total del patrón C

$$\mathcal{L}_{total} = \mathcal{L}_{MSE} + \lambda_{phys}\left(\mathcal{L}_{rampa} + \mathcal{L}_{par} + \mathcal{L}_{mono}\right)$$

Ninguna contiene una EDO del activo: es el "REGULARIZADOR DE FORMA" del diagrama aplicado al forecast de demanda.

5B · MATEMÁTICA DEL DIAGRAMA 4

Patrón D — Física de sustancia (circuito RC) · Patrón E — rama física + residual

D · Circuito térmico equivalente 2R2C (formulación PINN-RC del proyecto)

$$C_{in}\frac{dT_{in}(t)}{dt} = \frac{T_{out}(t) - T_{in}(t)}{R_{ea}} + \frac{T_m(t) - T_{in}(t)}{R_{in}} + A_w I_{sol}(t) + \dot{Q}_{int}(t) + P_{HVAC}(t)$$

Segundo nodo (masa de la envolvente): $C_m\frac{dT_m(t)}{dt} = \frac{T_{in}(t)-T_m(t)}{R_{in}} + \frac{T_{out}(t)-T_m(t)}{R_{out}}$; "Modelos RC" ↔ $(R_{ea}, R_{in}, R_{out}, C_{in}, C_m)$.

D · Residuo físico y pérdida compuesta

$$r_\theta(t) = C_{in}\frac{df_\theta(t)}{dt} - \left[\frac{T_{out}(t) - f_\theta(t)}{R_{ea}} + \frac{T_m(t) - f_\theta(t)}{R_{in}} + A_w I_{sol}(t) + \dot{Q}_{int}(t) + P_{HVAC}(t)\right]$$

La pérdida física es $\mathbb{E}_{t\sim p_{phys}}[r_\theta(t)^2]$; su aproximación empírica promedia los residuos en puntos de colocación y pasos del horizonte τ. La función objetivo compuesta añade esta penalización al riesgo de datos con peso λ_{phys}. Las derivadas son respecto al tiempo de la salida de la red.

E · Rama física + rama residual + contexto (PhysEmbedFormer)

$$\hat{y} = \underbrace{f_{fis}(\mathbf{x}_{met})}_{\text{rama física}} + \underbrace{g_\theta(\mathbf{x}, \mathbf{c}_{met})}_{\text{rama residual + contexto}}$$

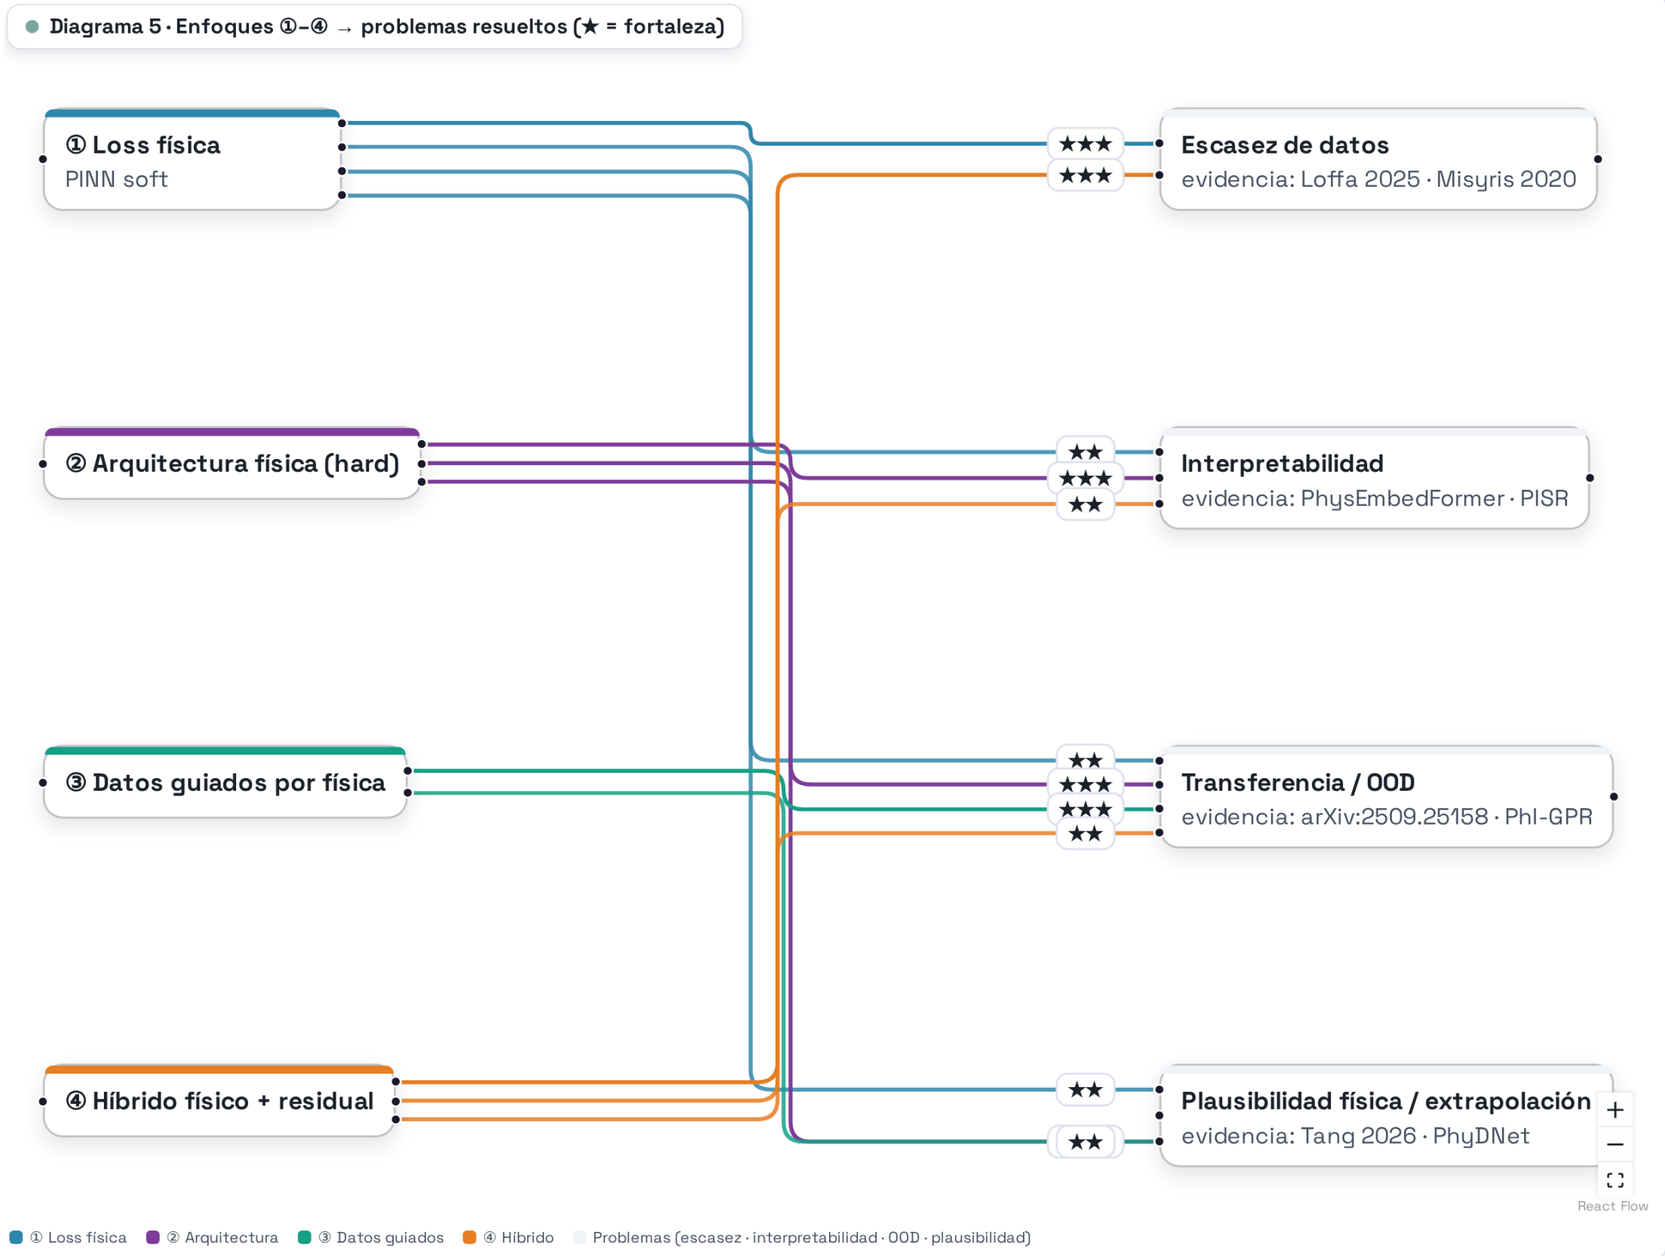
Conexión: puerta ④ con sabor de ② (rama física explícita e interpretable); la variante "PV con corrección de temperatura PINN" penaliza el residuo de $P_{pv}(t)$ (puerta ①).

6 · DIAGRAMA 5

¿Qué problema resuelve cada enfoque PIML en energía?

- Cada puerta ataca preferentemente un problema distinto: la decisión informativa del documento.
- Laterales abiertos (ninguna puerta los resuelve): **UQ**, eventos extremos, cómputo/escalabilidad.

Escasez ↔ Loffa et al. 2025 (DOI: 10.1145/3679240.3734642) y Misyris et al. 2020 · Extrapolación ↔ Tang et al. 2026 · Transferencia ↔ arXiv:2509.25158 · UQ ↔ Yang, Meng & Karniadakis, B-PINN, J. Comp. Physics 425, 2021.



6 · MATEMÁTICA DEL DIAGRAMA 5

Lectura matemática de las filas ①–④

- **① vs escasez:** $\lambda_{phys}\,\mathcal{L}_{phys}$ restringe las funciones admisibles a las que casi satisfacen $\mathcal{F}[u]=0$ → aumenta la muestra efectiva; la ganancia aparece "EXACTAMENTE con pocos datos" (Loffa 2025).
- **② y ④:** con $\hat{y}=f_{fis}(\mathbf{x}_{met})+g_\theta(\mathbf{x},\mathbf{c}_{met})$ cada término es inspeccionable, y fuera del dominio g_θ puede fallar pero f_{fis} sigue correcta (error acotado por el componente físico).

③ vs estados no observables: posterior del GP con prior físico

$$\bar{f}(\mathbf{x})=\mathbf{k}(\mathbf{x})^\top(\mathbf{K}_{GP}+\sigma_n^2\mathbf{I})^{-1}\mathbf{y}$$

Conexión: puerta ③ — con prior físico $f\sim\mathcal{GP}(m_{fis},\kappa_{fis})$ (PhI-GPR), la posterior reconstruye estados no medidos si el modelo dinámico está bien especificado.

6 · MATEMÁTICA DEL DIAGRAMA 5

Problemas laterales: UQ, eventos extremos y escalabilidad

- **Eventos extremos:** particionar el test en $\mathcal{E}$ y su complemento, reportando $\mathcal{L}_{MSE}|_{\mathcal{E}}$ por separado — ERCOT 2026: $\mathcal{L}_{par} + \mathcal{L}_{rampa}$ mejora la forma durante $\mathcal{E}$, no la magnitud del pico.
- **Cómputo:** evaluar $\mathcal{L}_{phys}$ crece con N_c y el orden de $\mathcal{N}$; no hay PINNs energéticas sobre datasets de $\sim 10^6$–10^7 muestras.

UQ bayesiana (B-PINN): posterior sobre parámetros y predictiva marginal

$$p(\Theta \mid \mathcal{D}) = \frac{p(\mathcal{D} \mid \Theta)\, p(\Theta)}{p(\mathcal{D})}, \qquad p(y^* \mid \mathbf{x}^*, \mathcal{D}) = \int p(y^* \mid \mathbf{x}^*, \Theta)\, p(\Theta \mid \mathcal{D})\, d\Theta$$

Muestreada con HMC o variacional: costo prohibitivo para forecasting operativo; alternativa barata: **cuantiles conformales**.

Cuantiles conformales: cobertura $\geq 1 - \alpha$ sin supuestos distribucionales

$$\hat{q} = \text{Quantile}\left(\{s_i\}_{i=1}^{n};\ \frac{\lceil (n+1)(1-\alpha) \rceil}{n} \right), \qquad C(\hat{y}) = \left[\hat{y} - \hat{q},\ \hat{y} + \hat{q} \right]$$

Con puntajes $s_i = |y_i - \hat{y}_i|$ sobre calibración de tamaño n: $\mathbb{P}\{y \in C(\hat{y})\} \geq 1 - \alpha$ — el hueco más claro del mapa energético.

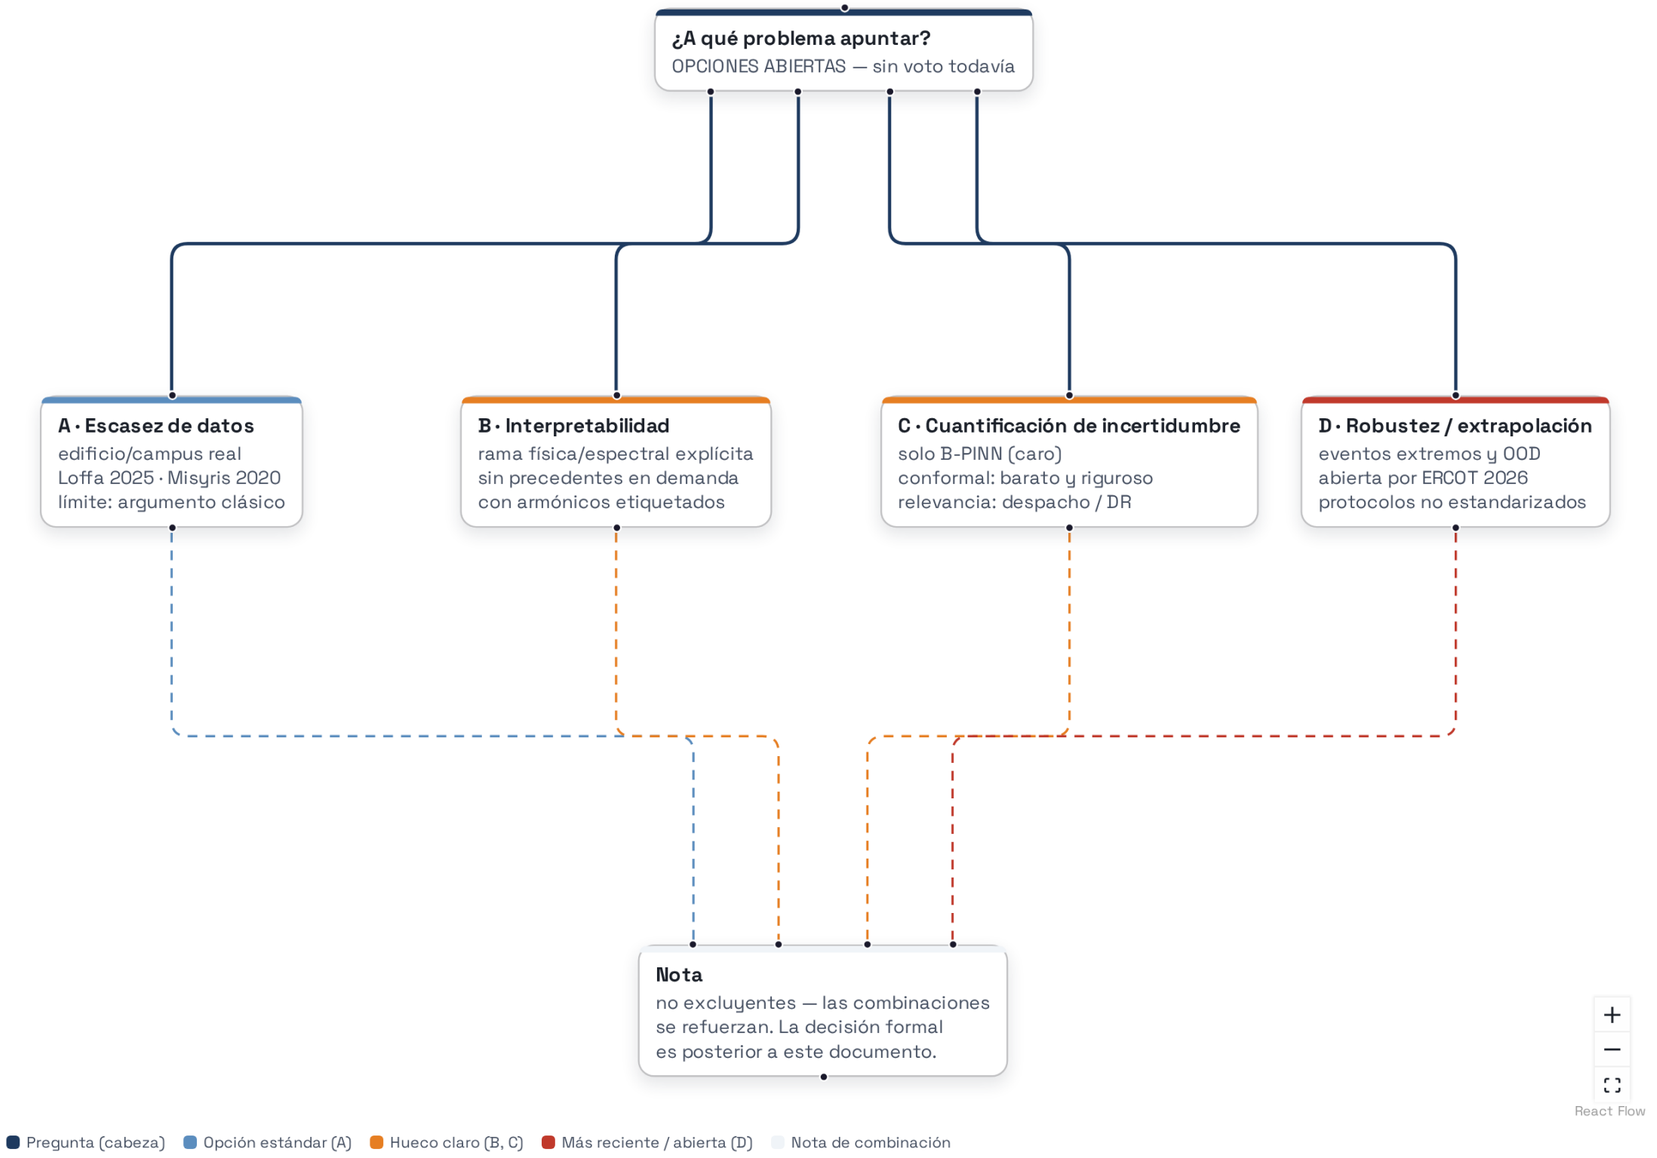
7 · DIAGRAMA 6

Árbol de opciones de problema (NO vinculado a ningún modelo)

- Opciones de problema que la tesis podría abarcar — **sin votar todavía**; la decisión es posterior.
- **A** Escasez de datos · **B** Interpretabilidad etiquetada · **C** UQ (conformal) · **D** Extremos/OOD.
- Las opciones **no son excluyentes**: las combinaciones se refuerzan.

Anclajes de evidencia por opción en §7 ("Matemática del Diagrama 6"); decisión informativa: Tabla 5 (§6) y opciones (§7); resolución posterior a este documento.

Diagrama 6 · ¿A qué problema apuntar? — opciones abiertas



7 · MATEMÁTICA DEL DIAGRAMA 6

Anclajes A y B — régimen de escasez y bandas etiquetadas

- **Opción A (escasez de datos):** con $\tilde{N}$ pequeño domina $\lambda_{phys}\,\mathcal{L}_{phys}$; existe un umbral donde el residuo RC (§5b-D) supera a $\mathcal{L}_{MSE}$ sola (Loffa 2025).

B · Descomposición por bandas espectralmente etiquetadas

$$\mathbf{z}[t] = [\boldsymbol{\phi}_1(\mathbf{x}[t]), \ldots, \boldsymbol{\phi}_K(\mathbf{x}[t])] \in \mathbb{R}^F, \qquad F = K\,N_f$$

Conexión: cada banda $\boldsymbol{\phi}_k$ queda *etiquetada* con su escala temporal ($B = (6, 24, 72)$ h o $(4, 24, 168)$ h): el análogo **aprendible** de la descomposición E8, dentro del modelo.

7 · MATEMÁTICA DEL DIAGRAMA 6

Anclajes C y D — conformal y evaluación por régimen

- **Opción C (UQ):** conformal — $C(\hat{y}) = [\hat{y} - \hat{q},\ \hat{y} + \hat{q}]$ con cobertura $\geq 1 - \alpha$ sobre cualquier predictor; B-PINN es prohibitivo en forecasting.
- **Opción D (robustez/extremos):** evaluación por régimen — $\mathcal{L}_{MSE}|_{\mathcal{E}}$ por separado, más $\mathcal{L}_{rampa}$ y $\mathcal{L}_{par}$ (§5b-C) durante el evento.

8 · LECTURA CONJUNTA

Los seis diagramas en una tabla

Diagrama	Pregunta que responde	Matemática asociada
1	Cómo entra la física (4 puertas)	$\mathcal{L}_{total}$, $\mathbb{J}\nabla H_\theta$, ψ_{fis}, $f_{fis} + g_\theta$ (§3)
2	Qué familias PIML existen para TS (general)	F1–F6: PINN, PG-RNN, Neural ODE/SDE, PhyDNet, kernel/GPR, PINT/RFF (§4)
3	Qué familias data-driven hay en energía (base)	E1–E8: SARIMA, SVR/XGBoost, LSTM/GRU, TCN, atención, SSM, fundacionales, VMD (§5a)
4	Dónde TS ∩ física ∩ energía (patrones A–E)	swing, flujo de potencia, pérdidas de forma, RC 2R2C + $\mathcal{R}_{phys}$, rama física+residual (§5b)
5	Qué problema resuelve cada enfoque	regularizador físico, posterior B-PINN, cuantiles conformales (§6)
6	Opciones de problema (sin conectar a modelo)	anclajes A–D: régimen de escasez, bandas etiquetadas, conformal, evaluación por régimen (§7)

10 · CIERRE

Gracias

Preguntas y discusión — el siguiente paso del documento es la formulación del modelo





Revisión PIML — Versión matemática · Series de tiempo y sistemas energéticos

Universidad Nacional de Colombia

2026